Гистограммная оценка

Постановка

Пусть, как и раньше,

$$a = \sqrt{3}, \qquad f(x) = \frac{1}{2a}\mathbf{1}_{\{|x|\le a\}}.$$

Обычная гистограмма — это способ изобразить выборку: ось разбивается на интервалы, и для каждого интервала показывается, сколько наблюдений туда попало. Такая картинка зависит от конкретной выборки.

Гистограммная оценка плотности использует ту же идею, но нормирует высоты столбцов так, чтобы получилась именно оценка плотности вероятности. Если в бин ширины h попало n_i наблюдений из n, то высота оценки на этом бине равна $n_i/(nh)$. Поэтому площадь столбца равна

$$h \cdot \frac{n_i}{nh} = \frac{n_i}{n},$$

то есть относительной частоте попадания в этот бин. Суммарная площадь всех столбцов равна 1, как и должно быть у плотности.

В этом разделе мы изучаем не одну случайную картинку-гистограмму, а среднее качество гистограммной оценки как метода. Для этого считаем математическое ожидание интегральной квадратической ошибки и затем нормируем его так же, как в разделе про ядерную оценку.

Рассмотрим гистограммную оценку с шириной бина h и со сдвигом сетки. Границы бинов задаются формулой

$$x_i = x_0 + ih, \qquad i \in \mathbb{Z}.$$

Чтобы исследовать влияние положения сетки относительно носителя плотности, будем писать

$$x_0 = -a + \Delta h, \qquad -\frac{1}{2} \le \Delta \le \frac{1}{2}.$$

При $\Delta = 0$ левая граница одного из бинов совпадает с левой границей носителя $[-a, a]$. Значения $\Delta = -1/2$ и $\Delta = 1/2$ дают одну и ту же сетку с точностью до перенумерации бинов.

Пусть n_i — число наблюдений, попавших в интервал (x_i, x_{i+1}). Гистограммная оценка имеет вид

$$\widehat{f}^H(x) = \frac{n_i}{nh}, \qquad x_i < x < x_{i+1}.$$

В точках разрыва можно задать любое конечное значение: на интегральную квадратическую ошибку это не влияет.

Точная формула для MISE

Чтобы посчитать среднюю ошибку гистограммы, нужно знать не сами случайные числа n_i, а вероятности попадания наблюдения в бины. Обозначим такую вероятность через p_i:

$$p_i = \mathbb{P}\{X \in (x_i, x_{i+1})\} = \int_{x_i}^{x_{i+1}} f(x)\,dx.$$

Тогда n_i — случайная величина с биномиальным распределением: в каждом из n независимых наблюдений есть вероятность p_i попасть в данный бин.

Для равномерной плотности это просто нормированная длина пересечения бина с носителем:

$$p_i = \frac{\ell_i}{2a}, \qquad \ell_i = \operatorname{length}\big((x_i, x_{i+1}) \cap [-a, a]\big).$$

Сумма по i фактически конечна, потому что $p_i = 0$ для всех бинов, не пересекающих $[-a, a]$.

Теперь раскладываем ошибку

$$\mathrm{MISE}_H = \mathbb{E} \int \big(\widehat{f}^H(x) - f(x)\big)^2\,dx$$

по формуле квадрата:

$$\mathbb{E} \int \big(\widehat{f}^H - f\big)^2 = \int f^2 - 2\int \mathbb{E}\widehat{f}^H\, f + \int \mathbb{E}(\widehat{f}^H)^2.$$

Первые два слагаемых отвечают за смещение оценки, а последнее содержит дисперсионный вклад из-за случайности выборки.

Найдём смешанное слагаемое. Внутри одного бина математическое ожидание оценки равно p_i/h, потому что $\mathbb{E}n_i = np_i$. Поэтому

$$\int \mathbb{E}\widehat{f}^H(x) f(x)\,dx = \sum_i \frac{p_i}{h} \int_{x_i}^{x_{i+1}} f(x)\,dx = \frac{1}{h}\sum_i p_i^2.$$

Теперь найдём второе среднее слагаемое. Так как n_i имеет биномиальное распределение с параметрами n и p_i,

$$\mathbb{E}n_i^2 = np_i(1 - p_i) + n^2 p_i^2.$$

Следовательно,

$$\begin{aligned}
\int \mathbb{E}\big(\widehat{f}^H(x)\big)^2\,dx &= \sum_i h\,\frac{\mathbb{E}n_i^2}{n^2h^2} \\
&= \frac{1}{nh}\sum_i p_i(1 - p_i) + \frac{1}{h}\sum_i p_i^2 \\
&= \frac{1}{nh} + \frac{n-1}{nh}\sum_i p_i^2.
\end{aligned}$$

Подставляя найденные выражения в разложение квадрата ошибки, получаем точную формулу:

$$\begin{aligned}
\mathrm{MISE}_H &= \mathbb{E} \int \big(\widehat{f}^H(x) - f(x)\big)^2\,dx \\
&= \int f^2(x)\,dx - 2\int \mathbb{E}\widehat{f}^H(x) f(x)\,dx + \int \mathbb{E}\big(\widehat{f}^H(x)\big)^2\,dx \\
&= \|f\|_2^2 + \frac{1}{nh} - \frac{n+1}{nh}\sum_i p_i^2.
\end{aligned}$$

Нормированная ошибка

Так как

$$\|f\|_2^2 = \int_{-a}^{a} \frac{1}{4a^2}\,dx = \frac{1}{2a},$$

нормированная ошибка равна

$$\mathrm{RMISE}_H(\xi, \Delta) = \frac{\mathrm{MISE}_H}{\|f\|_2^2} = 1 + \frac{2a}{nh} - \frac{2a(n+1)}{nh} \sum_i p_i^2.$$

Далее используем безразмерную ширину

$$\xi = \frac{h}{a}, \qquad h = a\xi.$$

Тогда

$$\mathrm{RMISE}_H(\xi, \Delta) = 1 + \frac{2}{n\xi} - \frac{2(n+1)}{n\xi} \sum_i p_i^2,$$

где p_i зависят от ξ и Δ через положение границ $x_i = -a + \Delta h + ih$.

Отдельно отметим особый случай. Если $\Delta = 0$ и $\xi = 2$, то $h = 2a$, а один из бинов совпадает с носителем $[-a, a]$. Тогда все наблюдения попадают в этот бин, $n_i = n$, и

$$\widehat{f}^H(x) = \frac{1}{2a} = f(x)$$

почти всюду. Поэтому

$$\mathrm{RMISE}_H(2, 0) = 0.$$

Это не противоречит общему поведению гистограмм: точное совпадение возникает из-за того, что истинная плотность сама является прямоугольной и границы бина идеально согласованы с её носителем.

Примеры самих гистограмм

Сначала построим обычные гистограммы по одной фиксированной выборке из равномерного распределения. Эти графики выглядят как привычные гистограммы: столбцы показывают нормированные частоты попадания в бины, а красная линия показывает истинную плотность $f(x)$.

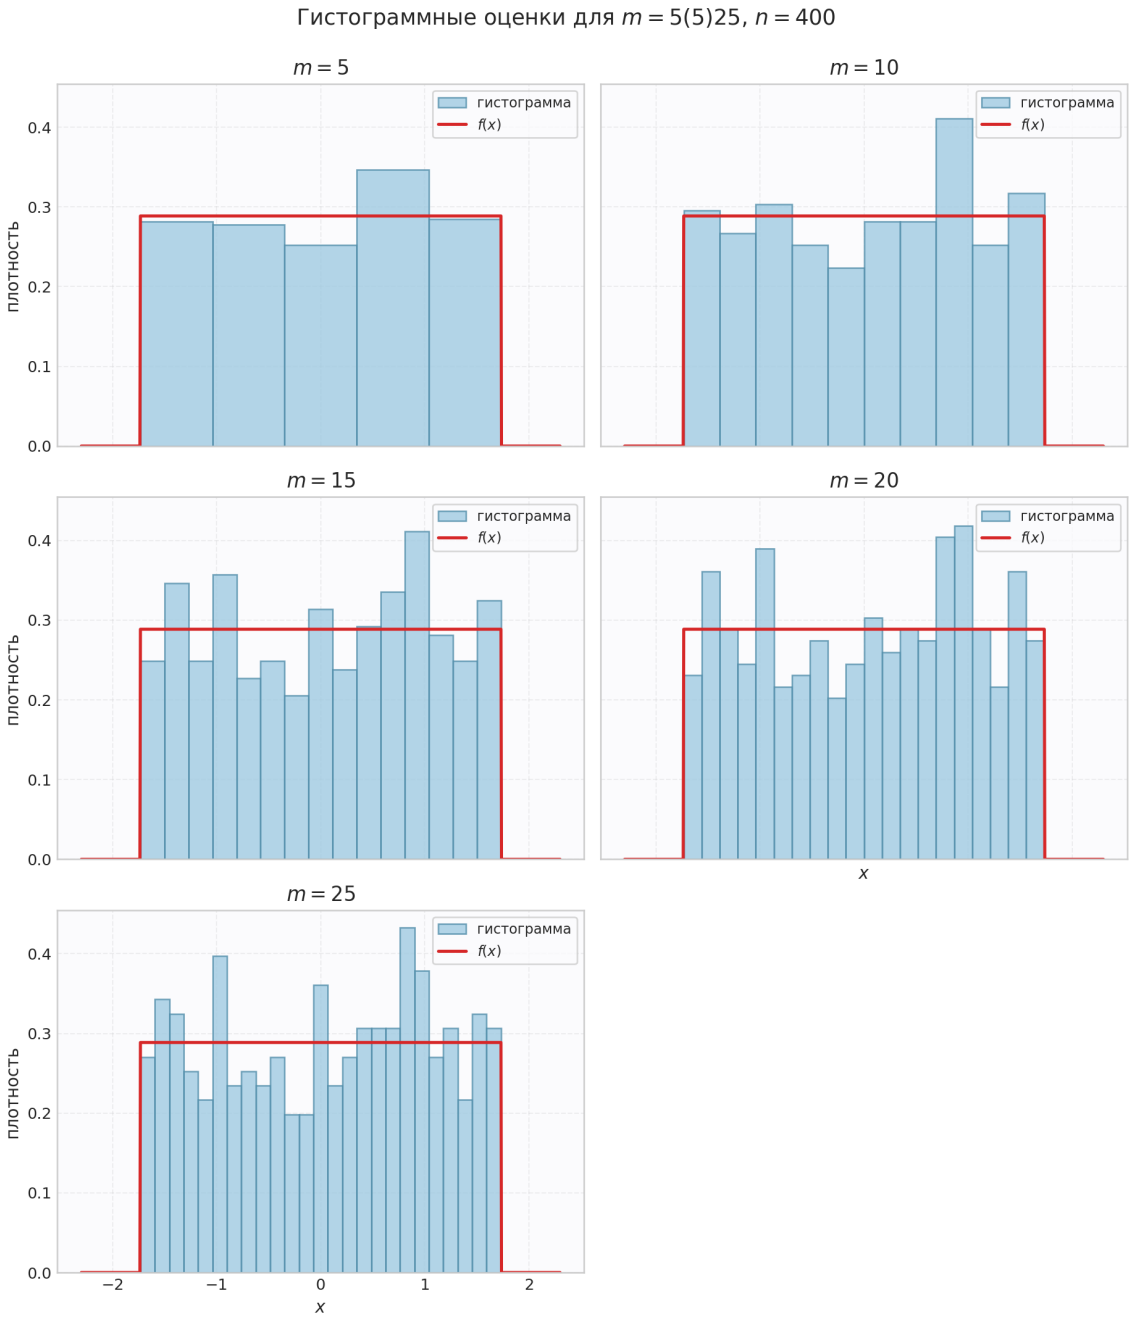

Рис. 1: Гистограммные оценки по одной выборке при разных числах бинов m.

На следующем графике число бинов фиксировано, но сетка сдвигается на Δh. Это иллюстрирует смысл записи $x_0 = -a + \Delta h$: меняется положение границ бинов относительно носителя истинной плотности.

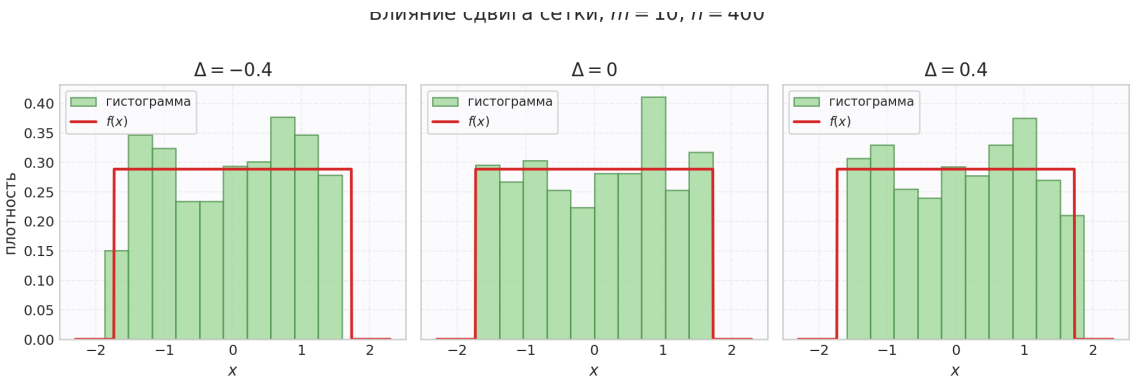

Рис. 2: Влияние сдвига сетки Δ на вид гистограммы.

Графики ошибки

Графики ниже уже не являются самими гистограммами. Это графики качества гистограммной оценки: значение RMISE_H считается по точной конечной сумме вероятностей p_i, без моделирования выборок. Они нужны, чтобы сравнивать разные ширины бина и разные сдвиги сетки.

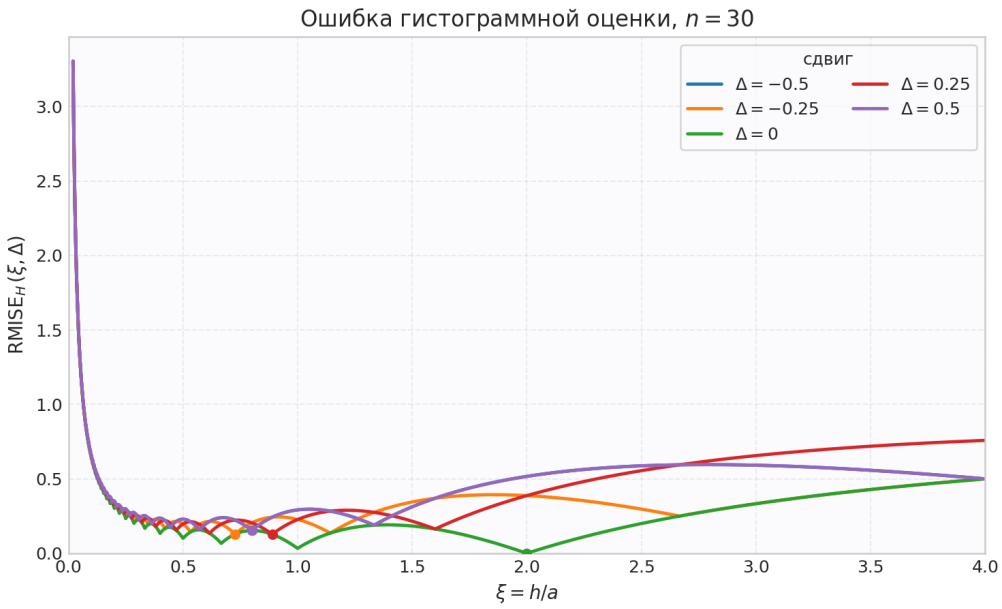

Рис. 3: Нормированная ОИСКО гистограммной оценки при $n = 30$ для разных сдвигов Δ.

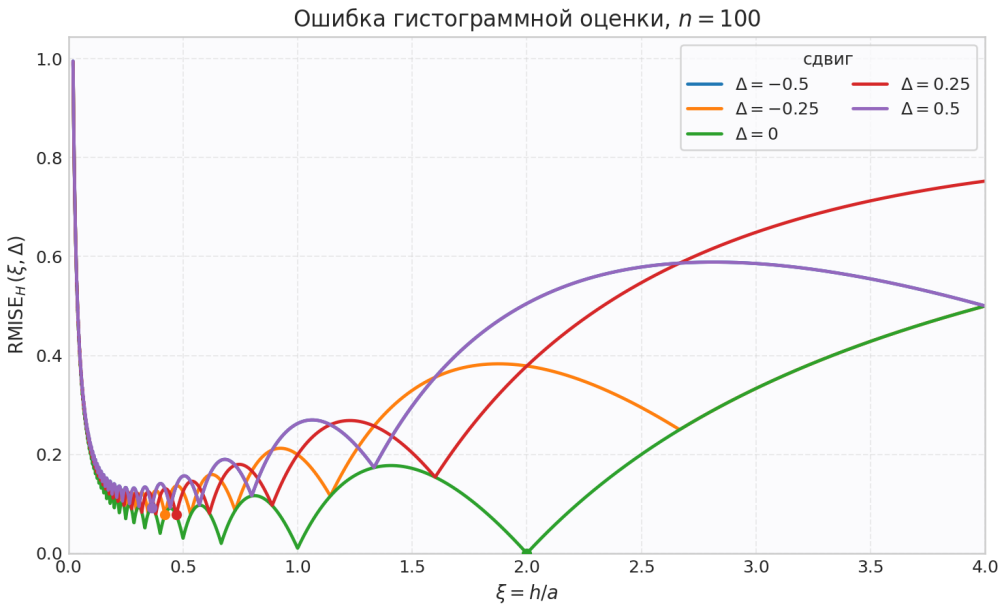

Рис. 4: Нормированная ОИСКО гистограммной оценки при $n = 100$ для разных сдвигов Δ.

Влияние сдвига особенно заметно тогда, когда границы бинов плохо согласованы с границами носителя истинной плотности. При $\Delta = 0$ один из бинов начинается ровно в точке $-a$, поэтому для ряда значений h часть граничной ошибки уменьшается.

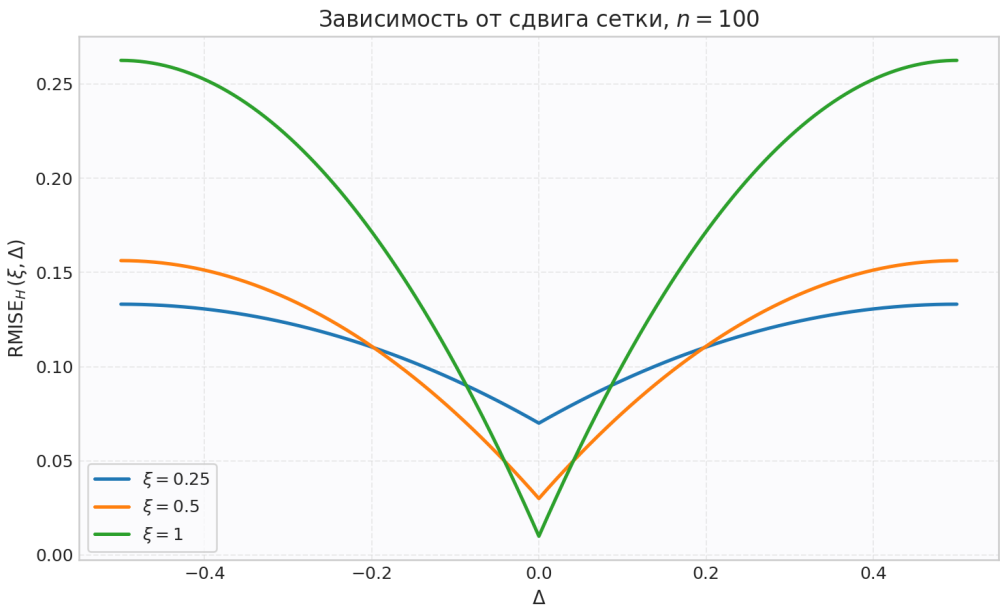

Рис. 5: Зависимость нормированной ОИСКО от сдвига Δ при $n = 100$ и фиксированных значениях ξ.

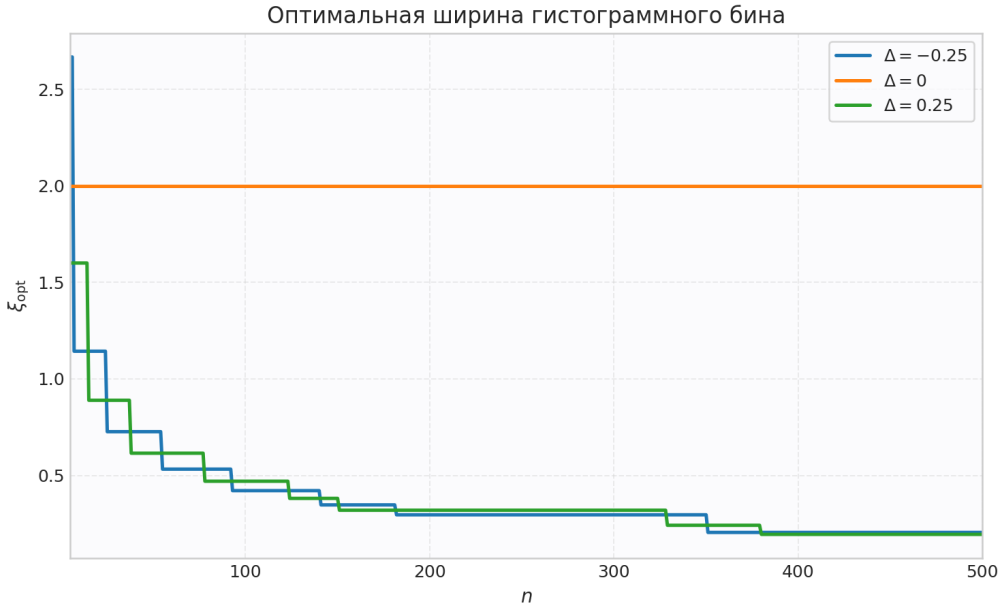

Рис. 6: Оптимальная ширина бина ξ_{opt} в зависимости от объёма выборки.

Слишком малое значение ξ приводит к большому дисперсионному вкладу, а слишком большое значение ξ обычно даёт грубую кусочно-постоянную аппроксимацию плотности. В нашем равномерном примере есть также специальный случай $\Delta = 0$, $\xi = 2$, когда один бин ровно совпадает с носителем и ошибка обращается в ноль. При других сдвигах сетки такого точного совпадения нет, поэтому зависимость имеет обычный компромисс между дисперсией и смещением.