Оценка максимального правдоподобия

Параметрическая модель

В предыдущих разделах плотность оценивалась непараметрически: ядерной оценкой или гистограммой. Теперь используем параметрический подход. Будем считать, что форма распределения известна заранее: это равномерное распределение, но его границы неизвестны.

Рассмотрим семейство плотностей

$$f(x; A, B) = \frac{1}{B - A} \mathbf{1}_{\{A \le x \le B\}}, \qquad A < B.$$

Истинная плотность из нашей задачи получается при

$$A = -a, \qquad B = a, \qquad a = \sqrt{3}.$$

Задача метода максимального правдоподобия состоит в следующем. По выборке

$$X_1, \ldots, X_n$$

сначала оцениваются параметры A и B, а затем эти оценки подставляются в параметрическую плотность.

ММП-оценки параметров

Функция правдоподобия равна

$$L(A, B) = \prod_{j=1}^{n} f(X_j; A, B) = \frac{1}{(B - A)^n} \mathbf{1}_{\{A \le X_{(1)},\, X_{(n)} \le B\}},$$

где

$$X_{(1)} = \min_{1 \le j \le n} X_j, \qquad X_{(n)} = \max_{1 \le j \le n} X_j.$$

Чтобы правдоподобие было ненулевым, интервал $[A, B]$ должен содержать всю выборку. При этом величина $(B - A)^{-n}$ тем больше, чем меньше длина интервала. Поэтому максимальное правдоподобие достигается на самом коротком интервале, содержащем выборку:

$$\widehat{A} = X_{(1)}, \qquad \widehat{B} = X_{(n)}.$$

Следовательно, ММП-оценка плотности имеет вид

$$\widehat{f}^{ML}(x) = \frac{1}{X_{(n)} - X_{(1)}} \mathbf{1}_{\{X_{(1)} \le x \le X_{(n)}\}}.$$

Это прямоугольная плотность на отрезке от минимального до максимального наблюдения.

Интегральная квадратическая ошибка

Обозначим случайный размах выборки через

$$R = X_{(n)} - X_{(1)}.$$

Поскольку все наблюдения лежат внутри истинного носителя, отрезок

$$[X_{(1)}, X_{(n)}] \subset [-a, a].$$

Поэтому ошибка состоит из двух частей: на отрезке $[X_{(1)}, X_{(n)}]$ отличаются высоты двух прямоугольников, а на оставшейся части истинного носителя оценка равна нулю.

При фиксированной выборке

$$\begin{aligned}\int_{-\infty}^{\infty} \left(\widehat{f}^{ML}(x) - f(x)\right)^2 dx &= R\left(\frac{1}{R} - \frac{1}{2a}\right)^2 + (2a - R)\left(\frac{1}{2a}\right)^2 \\ &= \frac{1}{R} - \frac{1}{2a}.\end{aligned}$$

Теперь нужно взять математическое ожидание по выборке.

Распределение размаха

Перейдём к нормированному размаху

$$W = \frac{R}{2a}.$$

Для выборки из равномерного распределения на отрезке плотность W равна

$$p_W(w) = n(n-1)w^{n-2}(1-w), \qquad 0 < w < 1.$$

Тогда при $n > 2$

$$\begin{aligned}\mathbb{E}\frac{1}{W} &= n(n-1)\int_0^1 w^{n-3}(1-w)\,dw \\ &= n(n-1)\left(\frac{1}{n-2} - \frac{1}{n-1}\right) = \frac{n}{n-2}.\end{aligned}$$

Так как $R = 2aW$,

$$\mathbb{E}\frac{1}{R} = \frac{1}{2a}\mathbb{E}\frac{1}{W} = \frac{1}{2a}\cdot\frac{n}{n-2}.$$

Значит,

$$\mathrm{MISE}_{ML} = \mathbb{E}\int (\widehat{f}^{ML}(x) - f(x))^2\,dx = \frac{1}{2a}\left(\frac{n}{n-2} - 1\right) = \frac{1}{a(n-2)}.$$

При $n \le 2$ величина $\mathbb{E}(1/R)$ бесконечна, поэтому средняя интегральная квадратическая ошибка не конечна.

Нормированная ОИСКО

Нормируем ошибку на $\|f\|_2^2$. Для равномерной плотности

$$\|f\|_2^2 = \int_{-a}^{a} \frac{1}{4a^2}\,dx = \frac{1}{2a}.$$

Следовательно, при $n > 2$

$$\mathrm{RMISE}_{ML}(n) = \frac{\mathrm{MISE}_{ML}}{\|f\|_2^2} = \frac{2}{n-2}.$$

Эта формула показывает, что ошибка ММП-оценки убывает как величина порядка $1/n$.

Графики

На первом графике показана точная формула $\mathrm{RMISE}_{ML}(n) = 2/(n-2)$.

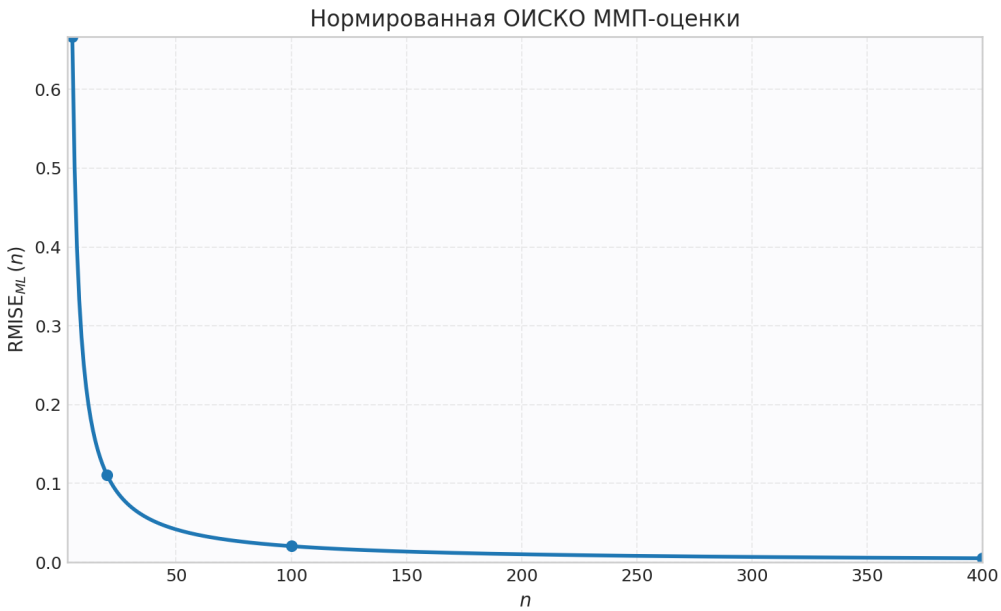

Рис. 1: Нормированная ОИСКО ММП-оценки в зависимости от объёма выборки.

Следующий график показывает, как выглядит сама ММП-оценка плотности. Синим показана оценка на отрезке от минимума до максимума выборки, красным — истинная плотность.

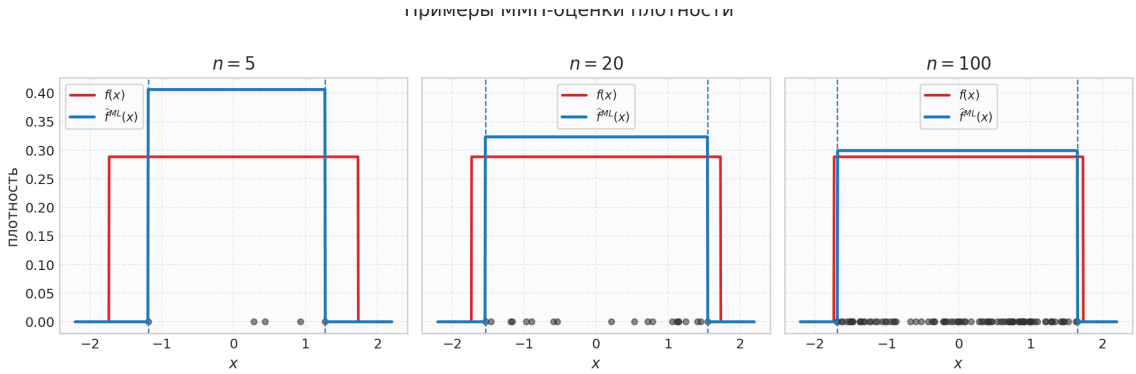

Рис. 2: Примеры ММП-оценки плотности для разных объёмов выборки.

Последний график является численной проверкой аналитической формулы: точная кривая сравнивается со средним значением нормированной ошибки, посчитанным по большому числу случайных выборок.

Рис. 3: Сравнение аналитической формулы с численной проверкой.

Сравнение с предыдущими оценками

Теперь сравним ММП-оценку с ранее рассмотренными непараметрическими оценками. Во всех случаях используется одна и та же нормированная ОИСКО, поэтому значения можно сравнивать напрямую.

n	ядерная	гист., $\Delta = 0.25$	ММП	гист., $\Delta = 0$
30	0.1206	0.1284	0.0714	0
100	0.0725	0.0778	0.0204	0

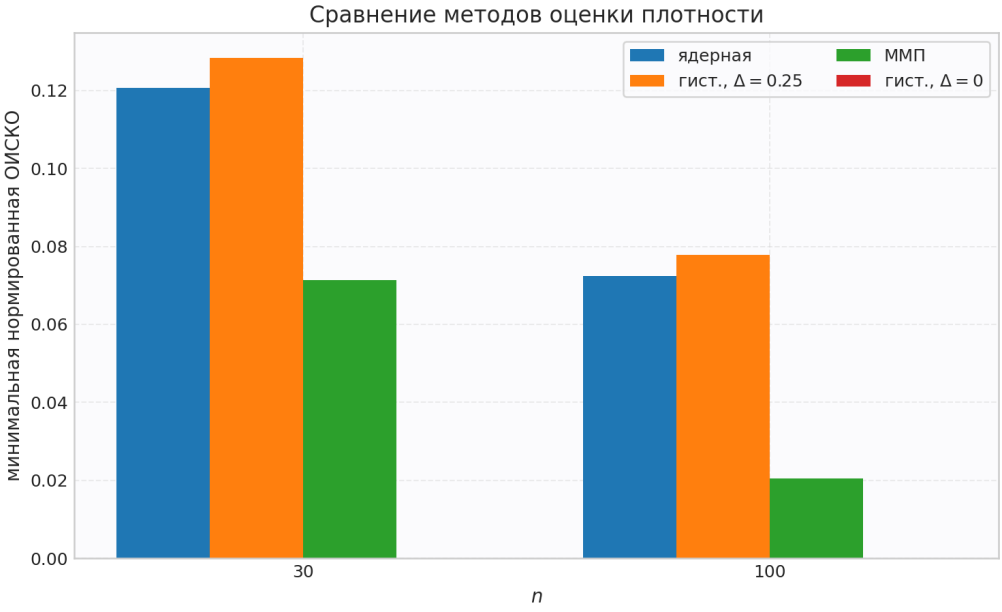

Рис. 4: Сравнение минимальной нормированной ОИСКО для разных методов оценки.

ММП-оценка лучше ядерной оценки и сдвинутой гистограммы, потому что она использует правильную параметрическую модель: заранее известно, что плотность равномерная, а неизвестны только границы носителя. Нулевые значения для гистограммы при $\Delta = 0$ являются специальным эффектом идеально согласованной сетки и не являются типичным поведением гистограмм.