Аналитический расчёт ОИСКО для прямоугольного ядра

Пусть

$$a = \sqrt{3}, \qquad K(x) = f(x) = \frac{1}{2a}\mathbf{1}_{\{|x|\le a\}}.$$

Рассматривается ядерная оценка

$$\widehat{f}_h(x) = \frac{1}{nh}\sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right), \qquad X_i \sim U[-a, a].$$

Обозначим

$$K_h(x) = \frac{1}{h}K\left(\frac{x}{h}\right) = \frac{1}{2ah}\mathbf{1}_{\{|x|\le ah\}}.$$

Тогда

$$\mathbb{E}\widehat{f}_h(x) = (K_h * f)(x),$$

и обычная интегральная среднеквадратическая ошибка равна

$$\mathrm{MISE}(h, n) = \mathbb{E}\int_{-\infty}^{\infty}\left(\widehat{f}_h(x) - f(x)\right)^2 dx.$$

Разложим её на дисперсионную часть и квадрат смещения:

$$\mathrm{MISE}(h, n) = \int_{-\infty}^{\infty}\mathrm{Var}\,\widehat{f}_h(x)\,dx + \int_{-\infty}^{\infty}\left(\mathbb{E}\widehat{f}_h(x) - f(x)\right)^2 dx.$$

Для одного наблюдения положим

$$Y_x = \frac{1}{h}K\left(\frac{x - X}{h}\right) = K_h(x - X).$$

Так как наблюдения независимы,

$$\mathrm{Var}\,\widehat{f}_h(x) = \frac{1}{n}\,\mathrm{Var}\,Y_x.$$

Поэтому

$$\int \mathrm{Var}\,\widehat{f}_h(x)\,dx = \frac{1}{n}\left(\int \mathbb{E}Y_x^2\,dx - \int\left(\mathbb{E}Y_x\right)^2 dx\right).$$

Первое слагаемое упрощается по теореме Фубини:

$$\int \mathbb{E}Y_x^2\,dx = \int f(t)\int K_h^2(x - t)\,dx\,dt = \int K_h^2(u)\,du = \frac{1}{h}R(K),$$

где

$$R(K) = \int K^2(u)\,du = \int_{-a}^{a}\frac{1}{4a^2}\,du = \frac{1}{2a}.$$

Кроме того,

$$\mathbb{E}Y_x = (K_h * f)(x).$$

Следовательно,

$$\mathrm{MISE}(h, n) = \frac{1}{n}\left(\frac{R(K)}{h} - \|K_h * f\|_2^2\right) + \|K_h * f - f\|_2^2.$$

Найдём свёртку. Она равна произведению высот двух прямоугольных плотностей на длину пересечения отрезков

$$[x - ah, x + ah] \quad \text{и} \quad [-a, a].$$

То есть

$$(K_h * f)(x) = \frac{1}{4a^2 h}\,\ell(x),$$

где

$$\ell(x) = \operatorname{length}\left([x - ah, x + ah] \cap [-a, a]\right).$$

Свёртка двух равномерных плотностей имеет форму трапеции при $h \neq 1$ и форму треугольника при $h = 1$.

Если $0 < h \leq 1$, то

$$(K_h * f)(x) = \begin{cases} \dfrac{1}{2a}, & |x| \leq a(1-h), \\ \dfrac{a(1+h) - |x|}{4a^2 h}, & a(1-h) < |x| \leq a(1+h), \\ 0, & |x| > a(1+h). \end{cases}$$

Тогда, используя чётность,

$$\begin{aligned} \|K_h * f\|_2^2 &= 2\int_0^{a(1-h)} \frac{1}{4a^2}\,dx + 2\int_{a(1-h)}^{a(1+h)} \left(\frac{a(1+h) - x}{4a^2 h}\right)^2 dx \\ &= \frac{1-h}{2a} + \frac{1}{8a^4 h^2}\int_{a(1-h)}^{a(1+h)} \big(a(1+h) - x\big)^2 dx \\ &= \frac{1-h}{2a} + \frac{1}{8a^4 h^2}\cdot\frac{(2ah)^3}{3} = \frac{3-h}{6a}. \end{aligned}$$

Если $h \geq 1$, то

$$(K_h * f)(x) = \begin{cases} \dfrac{1}{2ah}, & |x| \leq a(h-1), \\ \dfrac{a(1+h) - |x|}{4a^2 h}, & a(h-1) < |x| \leq a(1+h), \\ 0, & |x| > a(1+h). \end{cases}$$

Аналогично,

$$\begin{aligned} \|K_h * f\|_2^2 &= 2\int_0^{a(h-1)} \frac{1}{4a^2 h^2}\,dx + 2\int_{a(h-1)}^{a(1+h)} \left(\frac{a(1+h) - x}{4a^2 h}\right)^2 dx \\ &= \frac{h-1}{2ah^2} + \frac{1}{8a^4 h^2}\cdot\frac{(2a)^3}{3} = \frac{3h-1}{6ah^2}. \end{aligned}$$

Итак,

$$\|K_h * f\|_2^2 = \begin{cases} \dfrac{3-h}{6a}, & 0 < h \leq 1, \\ \dfrac{3h-1}{6ah^2}, & h \geq 1. \end{cases}$$

Теперь найдём квадрат смещения

$$\|K_h * f - f\|_2^2.$$

Так как $f(x) = 1/(2a)$ при $|x| \le a$ и $f(x) = 0$ вне этого отрезка, интегралы удобно считать отдельно на участках, где меняется вид свёртки.

При $0 < h \le 1$ внутри отрезка $[-a(1-h), a(1-h)]$ свёртка совпадает с f. Отличие есть только в двух граничных слоях и двух внешних хвостах:

$$\|K_h * f - f\|_2^2 = 2\int_{a(1-h)}^{a} \left(\frac{a(1+h)-x}{4a^2h} - \frac{1}{2a}\right)^2 dx + 2\int_{a}^{a(1+h)} \left(\frac{a(1+h)-x}{4a^2h}\right)^2 dx.$$

В первом интеграле числитель разности равен $a(1-h)-x$, а во втором линейная функция убывает от $1/(4a)$ до нуля. Поэтому

$$\|K_h * f - f\|_2^2 = 2\int_0^{ah} \left(\frac{u}{4a^2h}\right)^2 du + 2\int_0^{ah} \left(\frac{u}{4a^2h}\right)^2 du = \frac{h}{12a}.$$

При $1 < h \le 2$ свёртка имеет постоянный участок $|x| \le a(h-1)$, который лежит внутри носителя f. По чётности

$$\|K_h * f - f\|_2^2 = 2\int_0^{a(h-1)} \left(\frac{1}{2ah} - \frac{1}{2a}\right)^2 dx + 2\int_{a(h-1)}^{a} \left(\frac{a(1+h)-x}{4a^2h} - \frac{1}{2a}\right)^2 dx + 2\int_{a}^{a(1+h)} \left(\frac{a(1+h)-x}{4a^2h}\right)^2 dx.$$

После вычисления этих элементарных интегралов получаем

$$\|K_h * f - f\|_2^2 = \frac{3h^3 - 6h^2 + 6h - 2}{12ah^2}, \qquad 1 < h \le 2.$$

При $h \ge 2$ весь носитель f лежит внутри постоянного участка свёртки. Поэтому

$$\|K_h * f - f\|_2^2 = 2\int_0^{a} \left(\frac{1}{2ah} - \frac{1}{2a}\right)^2 dx + 2\int_{a}^{a(h-1)} \left(\frac{1}{2ah}\right)^2 dx + 2\int_{a(h-1)}^{a(1+h)} \left(\frac{a(1+h)-x}{4a^2h}\right)^2 dx = \frac{3h^2 - 3h - 1}{6ah^2}.$$

Следовательно,

$$\|K_h * f - f\|_2^2 = \begin{cases} \dfrac{h}{12a}, & 0 < h \le 1, \\ \dfrac{3h^3 - 6h^2 + 6h - 2}{12ah^2}, & 1 < h \le 2, \\ \dfrac{3h^2 - 3h - 1}{6ah^2}, & h \ge 2. \end{cases}$$

Подставим найденные выражения в формулу для ОИСКО. Для $0 < h \le 1$

$$\frac{R(K)}{h} - \|K_h * f\|_2^2 = \frac{1}{2ah} - \frac{3-h}{6a}.$$

Для $h \ge 1$

$$\frac{R(K)}{h} - \|K_h * f\|_2^2 = \frac{1}{2ah} - \frac{3h-1}{6ah^2} = \frac{1}{6ah^2}.$$

Итоговая формула имеет вид

$$\mathrm{MISE}(h,n) = \begin{cases} \dfrac{h}{12a} + \dfrac{1}{n}\left(\dfrac{1}{2ah} - \dfrac{3-h}{6a}\right), & 0 < h \le 1, \\ \dfrac{3h^3 - 6h^2 + 6h - 2}{12ah^2} + \dfrac{1}{n} \cdot \dfrac{1}{6ah^2}, & 1 < h \le 2, \\ \dfrac{3h^2 - 3h - 1}{6ah^2} + \dfrac{1}{n} \cdot \dfrac{1}{6ah^2}, & h \ge 2, \end{cases} \qquad a = \sqrt{3}.$$

Проверим согласованность формулы. В точке $h = 1$ первая и вторая ветви дают

$$\frac{1}{12a} + \frac{1}{6an}.$$

В точке $h = 2$ вторая и третья ветви дают

$$\frac{5}{24a} + \frac{1}{24an}.$$

Значит, $\mathrm{MISE}(h,n)$ непрерывна при $h = 1$ и $h = 2$. Кроме того,

$$h \to 0+: \qquad \mathrm{MISE}(h,n) \sim \frac{1}{2anh} \to \infty,$$

а при $h \to \infty$

$$\mathrm{MISE}(h,n) \to \frac{1}{2a} = \int_{-\infty}^{\infty} f^2(x)\,dx = \frac{1}{2\sqrt{3}}.$$

Графическая иллюстрация результатов

Для графиков положим $\xi = h$ и используем полученную выше кусочно-заданную формулу для $\mathrm{MISE}(h,n)$ без дополнительных аппроксимаций. Нормированную ошибку обозначим через

$$\Delta(h,n) = \frac{\mathrm{MISE}(h,n)}{\int f^2(x)\,dx} = 2\sqrt{3}\ \mathrm{MISE}(h,n),$$

а эффективность определим как

$$E(\xi) = \frac{\Delta_{\min}(400)}{\Delta(\xi,400)}, \qquad \Delta_{\min}(400) = \min_h \Delta(h,400).$$

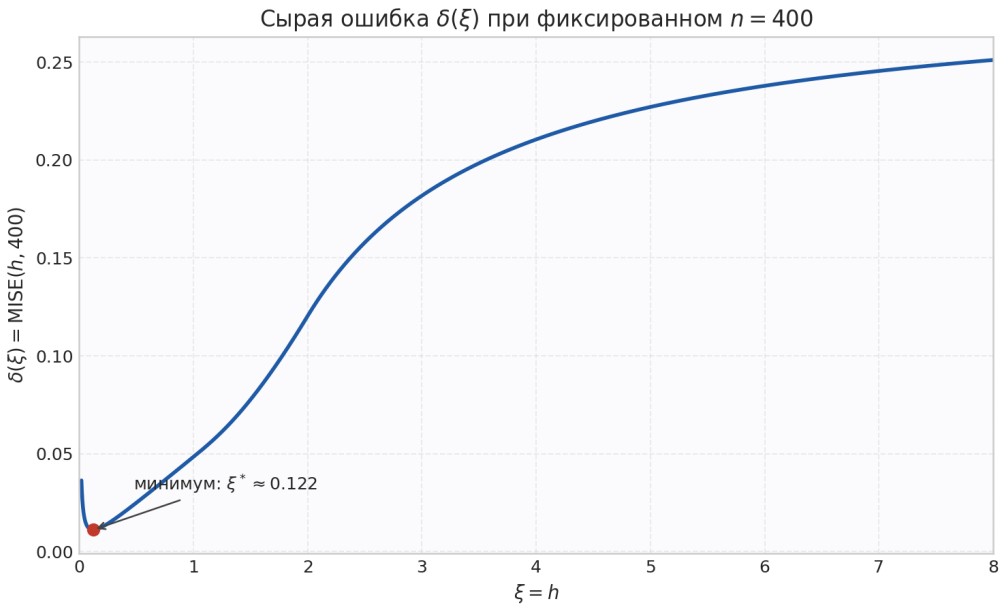

Рис. 1: График $\delta(\xi) = \mathrm{MISE}(h, 400)$, построенный по аналитической формуле для прямоугольного ядра.

При малых $\xi = h$ ошибка быстро растёт из-за дисперсионного члена $\sim (2anh)^{-1}$, а при больших h кривая приближается к пределу $1/(2\sqrt{3})$.

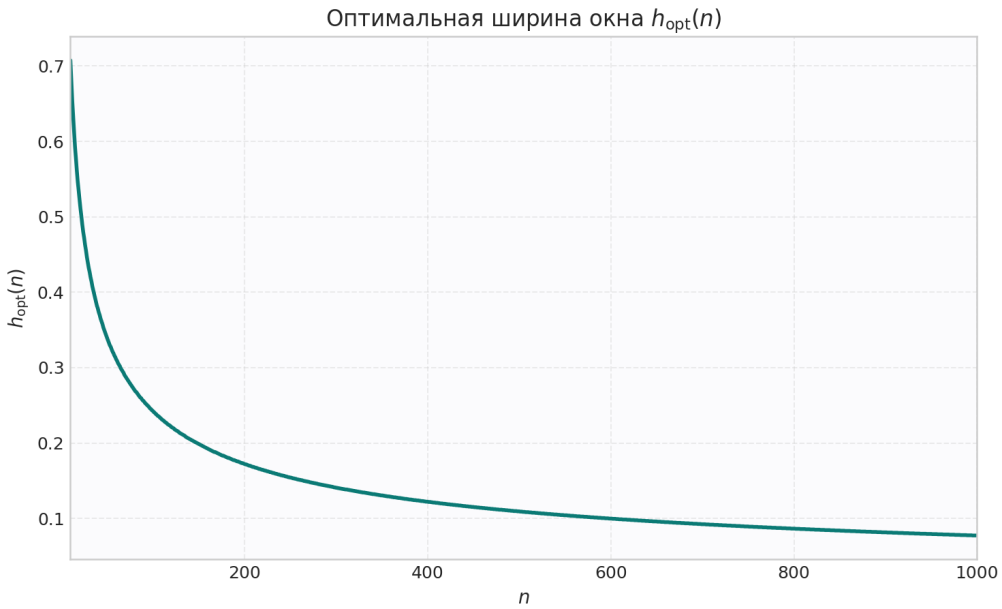

Рис. 2: Оптимальная ширина окна $h_{\mathrm{opt}}(n)$, численно найденная из минимума аналитической функции $\mathrm{MISE}(h, n)$.

По мере роста объёма выборки оптимальное значение h убывает, поскольку для больших n можно использовать более узкое окно без сильного штрафа по дисперсии.

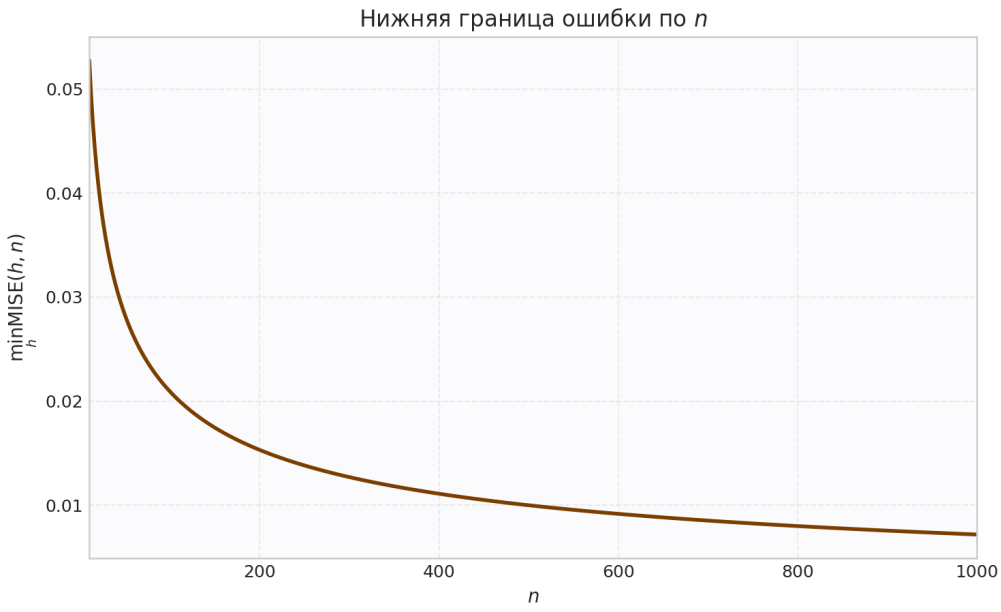

Рис. 3: Зависимость $\min_h \mathrm{MISE}(h, n)$ от размера выборки n для той же аналитической формулы.

Нижняя граница ошибки по n монотонно убывает: увеличение выборки улучшает наилучшее достижимое качество оценки.

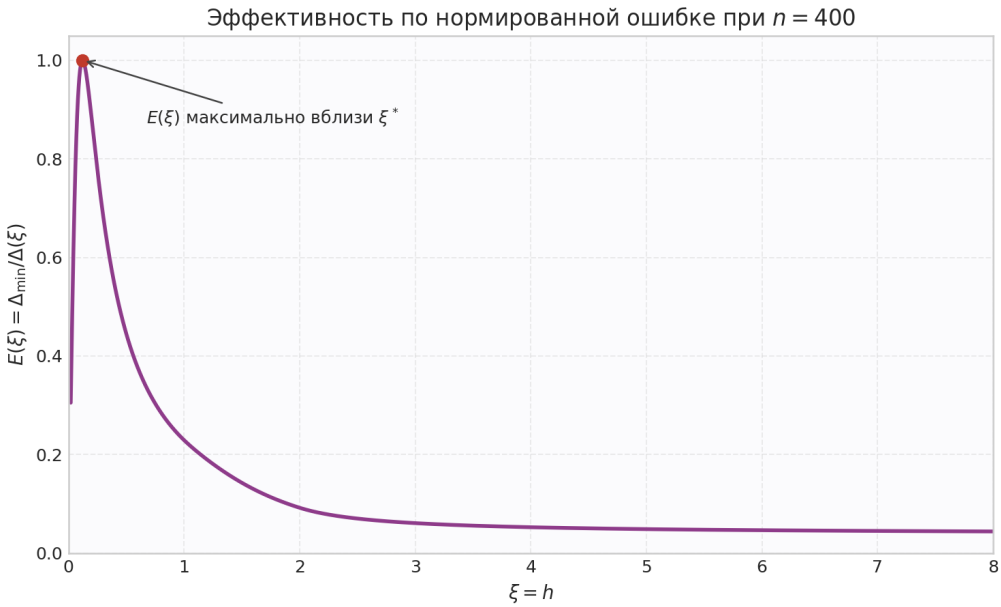

Рис. 4: Эффективность $E(\xi) = \Delta_{\min}(400)/\Delta(\xi, 400)$ при $n = 400$.

Эффективность максимальна вблизи оптимального значения h и убывает как при слишком малых, так и при слишком больших ξ, что напрямую отражает форму аналитической зависимости $\mathrm{MISE}(h, n)$.