Аналитический расчёт ОИСКО для прямоугольного ядра

Пусть

$$a = \sqrt{3}, \qquad f(x) = K(x) = \frac{1}{2a}\mathbf{1}_{\{|x|\le a\}}.$$

Здесь f является плотностью равномерного распределения на $[-a, a]$, а K берётся тем же прямоугольным ядром. Параметр сглаживания будем сразу обозначать через ξ, как в учебнике.

Рассматривается ядерная оценка плотности

$$\widehat{f}_\xi(x) = \frac{1}{n\xi}\sum_{i=1}^{n} K\left(\frac{x - X_i}{\xi}\right), \qquad X_i \sim U[-a, a].$$

Введём масштабированное ядро

$$K_\xi(x) = \frac{1}{\xi}K\left(\frac{x}{\xi}\right) = \frac{1}{2a\xi}\mathbf{1}_{\{|x|\le a\xi\}}.$$

Тогда одно слагаемое в оценке имеет вид $K_\xi(x - X_i)$, а математическое ожидание оценки равно свёртке:

$$\mathbb{E}\widehat{f}_\xi(x) = (K_\xi * f)(x).$$

ОИСКО определяется как математическое ожидание интегрального квадрата отклонения оценки от истинной плотности:

$$\bar{\delta}_n(\xi) = \mathbb{E}\int_{-\infty}^{\infty}\left(\widehat{f}_\xi(x) - f(x)\right)^2 dx.$$

Для каждого фиксированного x используем тождество

$$\mathbb{E}(\widehat{f}_\xi(x) - f(x))^2 = \operatorname{Var}\widehat{f}_\xi(x) + \left(\mathbb{E}\widehat{f}_\xi(x) - f(x)\right)^2.$$

После интегрирования по x получаем разложение ОИСКО на дисперсионную часть и квадрат смещения:

$$\bar{\delta}_n(\xi) = \int_{-\infty}^{\infty}\operatorname{Var}\widehat{f}_\xi(x)\,dx + \int_{-\infty}^{\infty}\left((K_\xi * f)(x) - f(x)\right)^2 dx.$$

Дисперсионная часть

Для одного наблюдения положим

$$Y_x = K_\xi(x - X).$$

Так как наблюдения независимы и одинаково распределены,

$$\operatorname{Var}\widehat{f}_\xi(x) = \frac{1}{n}\operatorname{Var}Y_x.$$

Следовательно,

$$\int \operatorname{Var}\widehat{f}_\xi(x)\,dx = \frac{1}{n}\left(\int \mathbb{E}Y_x^2\,dx - \int\left(\mathbb{E}Y_x\right)^2 dx\right).$$

Первый интеграл упрощается заменой переменной $u = x - t$ и теоремой Фубини:

$$\int \mathbb{E}Y_x^2\,dx = \int f(t) \int K_\xi^2(x-t)\,dx\,dt$$
$$= \int K_\xi^2(u)\,du = \frac{1}{\xi}\int K^2(u)\,du.$$

Для прямоугольного ядра

$$R(K) = \int K^2(u)\,du = \int_{-a}^{a} \frac{1}{4a^2}\,du = \frac{1}{2a}.$$

Кроме того,

$$\mathbb{E}Y_x = (K_\xi * f)(x).$$

Поэтому дисперсионная часть равна

$$\int \operatorname{Var} \widehat{f}_\xi(x)\,dx = \frac{1}{n}\left(\frac{R(K)}{\xi} - \|K_\xi * f\|_2^2\right).$$

Свёртка прямоугольных плотностей

Найдём $(K_\xi * f)(x)$. Оба множителя под интегралом являются постоянными на своих носителях, поэтому свёртка равна произведению высот на длину пересечения отрезков

$$[x - a\xi, x + a\xi] \quad \text{и} \quad [-a, a].$$

То есть

$$(K_\xi * f)(x) = \frac{1}{4a^2\xi}\,\ell(x), \qquad \ell(x) = \operatorname{length}\left([x - a\xi, x + a\xi] \cap [-a, a]\right).$$

Вид свёртки меняется в зависимости от того, какой из отрезков длиннее. Если $0 < \xi \le 1$, сглаживающее окно короче носителя f, поэтому в центре свёртка совпадает с f. Если $\xi \ge 1$, появляется центральная площадка высоты $1/(2a\xi)$.

При $0 < \xi \le 1$

$$(K_\xi * f)(x) = \begin{cases} \dfrac{1}{2a}, & |x| \le a(1-\xi), \\ \dfrac{a(1+\xi) - |x|}{4a^2\xi}, & a(1-\xi) < |x| \le a(1+\xi), \\ 0, & |x| > a(1+\xi). \end{cases}$$

Используя чётность функции, получаем

$$\|K_\xi * f\|_2^2 = 2\int_0^{a(1-\xi)} \frac{1}{4a^2}\,dx + 2\int_{a(1-\xi)}^{a(1+\xi)} \left(\frac{a(1+\xi) - x}{4a^2\xi}\right)^2 dx$$
$$= \frac{1-\xi}{2a} + \frac{1}{8a^4\xi^2}\int_{a(1-\xi)}^{a(1+\xi)} \big(a(1+\xi) - x\big)^2 dx$$
$$= \frac{1-\xi}{2a} + \frac{1}{8a^4\xi^2}\cdot\frac{(2a\xi)^3}{3} = \frac{3-\xi}{6a}.$$

При $\xi \geq 1$

$$(K_\xi * f)(x) = \begin{cases} \dfrac{1}{2a\xi}, & |x| \leq a(\xi-1), \\ \dfrac{a(1+\xi)-|x|}{4a^2\xi}, & a(\xi-1) < |x| \leq a(1+\xi), \\ 0, & |x| > a(1+\xi). \end{cases}$$

Аналогично,

$$\begin{aligned} \|K_\xi * f\|_2^2 &= 2\int_0^{a(\xi-1)} \frac{1}{4a^2\xi^2}\,dx + 2\int_{a(\xi-1)}^{a(1+\xi)} \left(\frac{a(1+\xi)-x}{4a^2\xi}\right)^2 dx \\ &= \frac{\xi-1}{2a\xi^2} + \frac{1}{8a^4\xi^2}\cdot\frac{(2a)^3}{3} = \frac{3\xi-1}{6a\xi^2}. \end{aligned}$$

Итак,

$$\|K_\xi * f\|_2^2 = \begin{cases} \dfrac{3-\xi}{6a}, & 0 < \xi \leq 1, \\ \dfrac{3\xi-1}{6a\xi^2}, & \xi \geq 1. \end{cases}$$

Квадрат смещения

Теперь вычислим

$$\|K_\xi * f - f\|_2^2.$$

Здесь приходится рассматривать три случая, потому что взаимное положение центральной площадки свёртки и носителя f меняется при $\xi = 1$ и $\xi = 2$.

При $0 < \xi \leq 1$ в центре отрезка $[-a(1-\xi), a(1-\xi)]$ свёртка совпадает с f. Ошибка возникает только в двух внутренних граничных слоях и двух внешних хвостах:

$$\begin{aligned} \|K_\xi * f - f\|_2^2 = 2\int_{a(1-\xi)}^{a} &\left(\frac{a(1+\xi)-x}{4a^2\xi} - \frac{1}{2a}\right)^2 dx \\ &+ 2\int_a^{a(1+\xi)} \left(\frac{a(1+\xi)-x}{4a^2\xi}\right)^2 dx. \end{aligned}$$

В обоих интегралах после замены переменной получается один и тот же интеграл по отрезку длины $a\xi$:

$$\|K_\xi * f - f\|_2^2 = 2\int_0^{a\xi} \left(\frac{u}{4a^2\xi}\right)^2 du + 2\int_0^{a\xi} \left(\frac{u}{4a^2\xi}\right)^2 du = \frac{\xi}{12a}.$$

При $1 < \xi \leq 2$ центральная площадка свёртки $|x| \leq a(\xi-1)$ лежит внутри носителя f. Поэтому квадрат смещения состоит из вклада центральной площадки, наклонной части внутри носителя и внешнего хвоста:

$$\begin{aligned} \|K_\xi * f - f\|_2^2 = 2\int_0^{a(\xi-1)} &\left(\frac{1}{2a\xi} - \frac{1}{2a}\right)^2 dx \\ &+ 2\int_{a(\xi-1)}^{a} \left(\frac{a(1+\xi)-x}{4a^2\xi} - \frac{1}{2a}\right)^2 dx \\ &+ 2\int_a^{a(1+\xi)} \left(\frac{a(1+\xi)-x}{4a^2\xi}\right)^2 dx. \end{aligned}$$

После вычисления элементарных интегралов:

$$\|K_\xi * f - f\|_2^2 = \frac{3\xi^3 - 6\xi^2 + 6\xi - 2}{12a\xi^2}, \qquad 1 < \xi \le 2.$$

При $\xi \ge 2$ весь носитель f лежит внутри центральной площадки свёртки, а вне носителя f остаются ещё постоянные участки свёртки и наклонные хвосты. Поэтому

$$\begin{aligned}\|K_\xi * f - f\|_2^2 = 2\int_0^a \left(\frac{1}{2a\xi} - \frac{1}{2a}\right)^2 dx \\ + 2\int_a^{a(\xi-1)} \left(\frac{1}{2a\xi}\right)^2 dx \\ + 2\int_{a(\xi-1)}^{a(1+\xi)} \left(\frac{a(1+\xi) - x}{4a^2\xi}\right)^2 dx \\ = \frac{3\xi^2 - 3\xi - 1}{6a\xi^2}.\end{aligned}$$

Следовательно,

$$\|K_\xi * f - f\|_2^2 = \begin{cases} \dfrac{\xi}{12a}, & 0 < \xi \le 1, \\ \dfrac{3\xi^3 - 6\xi^2 + 6\xi - 2}{12a\xi^2}, & 1 < \xi \le 2, \\ \dfrac{3\xi^2 - 3\xi - 1}{6a\xi^2}, & \xi \ge 2. \end{cases}$$

Итоговая формула для ОИСКО

Собираем дисперсионную часть и квадрат смещения. Для $0 < \xi \le 1$

$$\frac{R(K)}{\xi} - \|K_\xi * f\|_2^2 = \frac{1}{2a\xi} - \frac{3-\xi}{6a}.$$

Для $\xi \ge 1$

$$\frac{R(K)}{\xi} - \|K_\xi * f\|_2^2 = \frac{1}{2a\xi} - \frac{3\xi - 1}{6a\xi^2} = \frac{1}{6a\xi^2}.$$

Значит,

$$\bar{\delta}_n(\xi) = \begin{cases} \dfrac{\xi}{12a} + \dfrac{1}{n}\left(\dfrac{1}{2a\xi} - \dfrac{3-\xi}{6a}\right), & 0 < \xi \le 1, \\ \dfrac{3\xi^3 - 6\xi^2 + 6\xi - 2}{12a\xi^2} + \dfrac{1}{n}\cdot\dfrac{1}{6a\xi^2}, & 1 < \xi \le 2, \\ \dfrac{3\xi^2 - 3\xi - 1}{6a\xi^2} + \dfrac{1}{n}\cdot\dfrac{1}{6a\xi^2}, & \xi \ge 2, \end{cases} \qquad a = \sqrt{3}.$$

Проверим согласованность формулы. В точке $\xi = 1$ первая и вторая ветви дают

$$\frac{1}{12a} + \frac{1}{6an}.$$

В точке $\xi = 2$ вторая и третья ветви дают

$$\frac{5}{24a} + \frac{1}{24an}.$$

Значит, $\bar{\delta}_n(\xi)$ непрерывна при $\xi = 1$ и $\xi = 2$. Кроме того,

$$\xi \to 0+ : \qquad \bar{\delta}_n(\xi) \sim \frac{1}{2an\xi} \to \infty,$$

то есть слишком малое окно даёт большой дисперсионный вклад. При $\xi \to \infty$

$$\bar{\delta}_n(\xi) \to \frac{1}{2a} = \int_{-\infty}^{\infty} f^2(x)\,dx = \frac{1}{2\sqrt{3}},$$

что соответствует чрезмерному сглаживанию: оценка становится слишком широкой и плохо приближает исходную плотность.

Оптимальный параметр и минимальная ОИСКО

Оптимальный параметр определяется из условия минимума:

$$\xi_{\text{opt}}(n) = \arg\min_{\xi>0} \bar{\delta}_n(\xi), \qquad \bar{\delta}_{n,\min} = \bar{\delta}_n(\xi_{\text{opt}}).$$

Для рассматриваемого значения $n = 400$ минимум находится в первой ветви. Дифференцируя первую ветвь по ξ, получаем

$$\frac{d}{d\xi}\bar{\delta}_n(\xi) = \frac{1}{12a} + \frac{1}{6an} - \frac{1}{2an\xi^2}.$$

Из условия равенства производной нулю следует

$$\xi_{\text{opt}}(n) = \sqrt{\frac{6}{n+2}}.$$

При $n = 400$

$$\xi_{\text{opt}}(400) = \sqrt{\frac{6}{402}} \approx 0.122, \qquad \bar{\delta}_{400,\min} \approx 0.0111.$$

Эффективность параметра ξ определим отношением

$$e_n(\xi) = \frac{\bar{\delta}_{n,\min}}{\bar{\delta}_n(\xi)}, \qquad 0 < e_n(\xi) \le 1.$$

Максимальное значение эффективности равно 1 и достигается при $\xi = \xi_{\text{opt}}(n)$.

Графическая иллюстрация

Основные графики построены для $n = 400$ по формуле $\bar{\delta}_n(\xi)$ без дополнительных аппроксимаций.

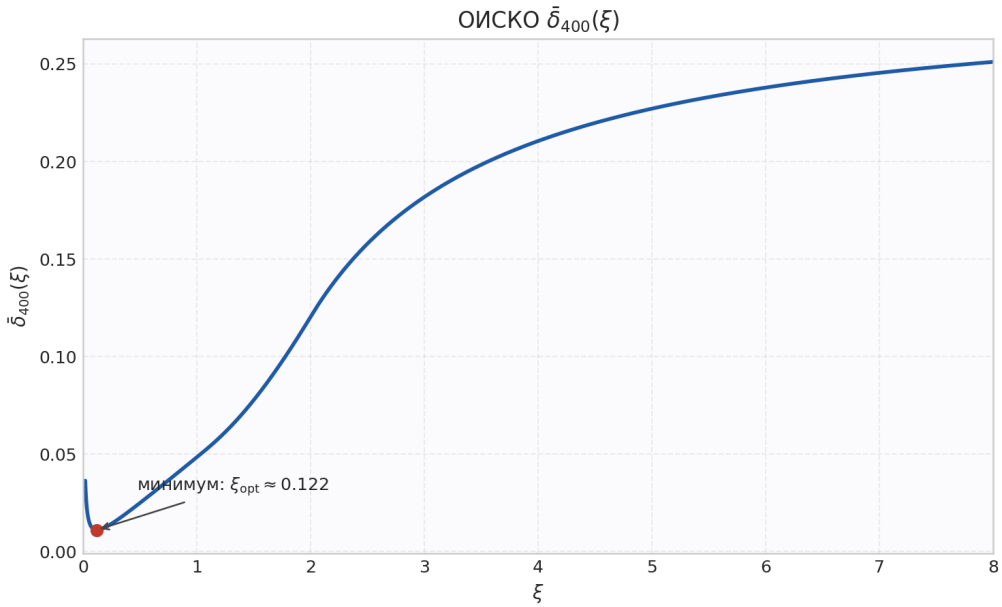

Рис. 1: График ОИСКО $\bar{\delta}_{400}(\xi)$, построенный по аналитической формуле для прямоугольного ядра.

При малых ξ ошибка быстро растёт из-за дисперсионного члена $\sim (2an\xi)^{-1}$, а при больших ξ кривая приближается к пределу $1/(2\sqrt{3})$.

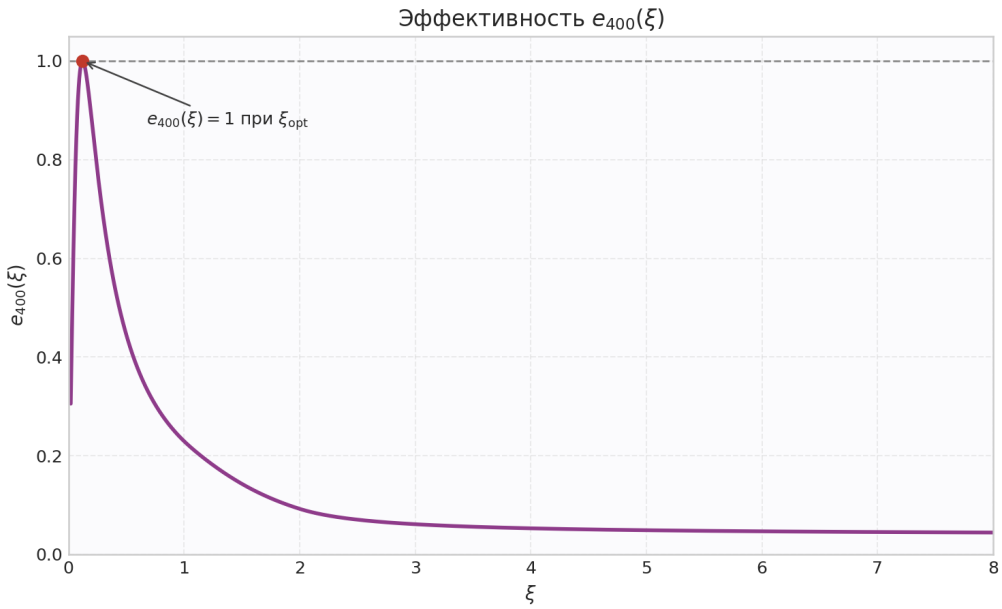

Рис. 2: Эффективность $e_{400}(\xi) = \bar{\delta}_{400,\min}/\bar{\delta}_{400}(\xi)$ с максимумом, равным 1.

Эффективность максимальна вблизи оптимального значения ξ и убывает как при слишком малых, так и при слишком больших значениях параметра.

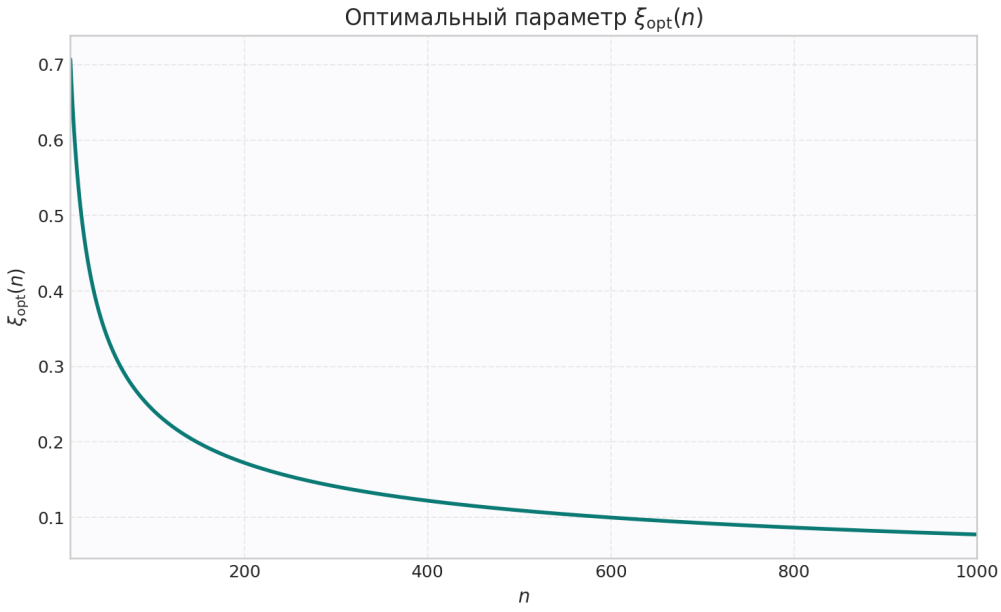

Рис. 3: Дополнительно: зависимость $\xi_{\text{opt}}(n)$ от размера выборки n.

По мере роста объёма выборки оптимальное значение ξ убывает, поскольку для больших n можно использовать более узкое окно без сильного штрафа по дисперсии.

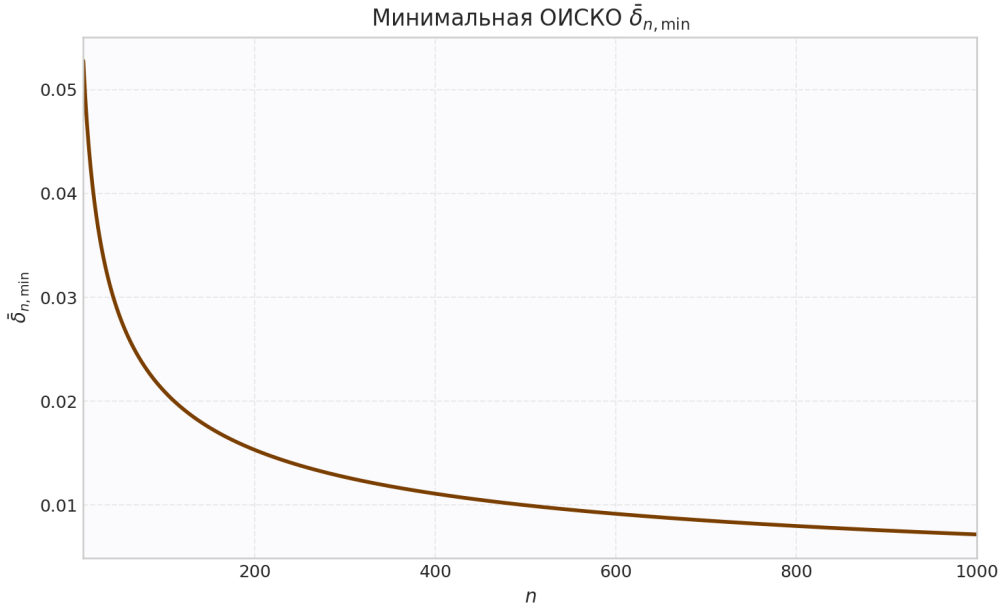

Рис. 4: Дополнительно: зависимость $\bar{\delta}_{n,\min}$ от размера выборки n.

Минимальная ОИСКО монотонно убывает: увеличение выборки улучшает наилучшее достижимое качество оценки.