Министерство образования и науки Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Институт прикладной математики и механики

Работа допущена к защите
Заведующий кафедрой
_____ М.Е. Фролов
«___»_____ 2019 г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА МАГИСТРА

ИССЛЕДОВАНИЕ ЯДЕРНОЙ ОЦЕНКИ ПЛОТНОСТИ ВЕРОЯТНОСТИ В УСЛОВИЯХ МАЛОЙ ВЫБОРКИ

по направлению 01.04.02 «Прикладная математика и информатика»
по образовательной программе
01.04.02_02 «Системное программирование»

Выполнил
студент гр. 23641/2 М.Ю. Туник

Руководитель
доцент, к.ф.-м.н. О.И. Заяц

Консультант
к.ф.-м.н. С.В. Березин

Санкт-Петербург
2019

САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ПЕТРА ВЕЛИКОГО
Институт Прикладной математики и механики
Кафедра Прикладная математика

УТВЕРЖДАЮ

Заведующий кафедрой

_____М.Е.Фролов

«__» _____2019 г.

ЗАДАНИЕ

по выполнению выпускной квалификационной работы

студенту Тунику Михаилу Юрьевичу, гр. 23641/2

1. **Тема работы:** Исследование ядерной оценки плотности вероятности в условиях малой выборки;

2. **Срок сдачи студентом законченной работы:** июнь 2019 года;

3. **Исходные данные по работе:** В работе необходимо исследовать традиционные и автоматические ядерные оценки плотности вероятности для случая выборок малого объема с зависимыми и независимыми элементами;

4. **Содержание работы (перечень подлежащих разработке вопросов):**
   В работе необходимо привести:
   1. Обзор литературы по теме;
   2. Вывод традиционной и автоматической ядерных оценок для случая независимых выборок;
   3. Вывод традиционной и автоматической ядерных оценок для случая зависимых выборок, полученных как дискретные отсчёты гауссовского стационарного случайного процесса с корреляционной функцией заданного вида;
   4. Разработать метод нахождения оптимального параметра сглаживания для традиционных и автоматических ядерных оценок;
   5. Произвести проверку результатов методом статистического моделирования;
   6. Произвести теоретическое и численно-экспериментальное исследование полученных оценок, включая другие разновидности адаптивных ядерных оценок;
   7. Произвести сравнение ядерных и классических оценок;

5. **Перечень графического материала (с указанием обязательных чертежей):**
   Таблицы и графики строятся по мере надобности;

6. **Консультант по проекту (с указанием относящихся к ним разделов проекта, работы):**
   Вопросы теории вероятности и математической статистики – С.В. Березин;

7. **Дата выдачи задания:** сентябрь 2018.

Руководитель: О.И. Заяц _____

Задание принял к исполнению _____

(дата, подпись студента)

Реферат

На 71 с., 16 рис., 3 приложения

Ядерная оценка плотности вероятности, малая выборка, L_2-подход, автоматическая оценка, стационарный гауссовский процесс.

Работа посвящена ядерным оценкам плотности вероятности, построенным по выборкам конечного объема (малым выборкам). Основное внимание уделено получению и последующему исследованию явных формул для автоматических и неавтоматических ядерных оценок как для случая классических выборок, так и для случая зависимых выборок (реализаций случайных процессов). Исследование основано на использовании L_2-подхода в котором за меру качества ядерной оценки принимается относительное интегральное среднеквадратическое отклонение. Для случая выборки, построенной по дискретным отсчётам реализации стационарного гауссовского процесса предлагается новый метод построения оптимальной автоматической оценки.

Abstract

71 pages, 16 pictures, 3 appendices

Kernel density estimator, small sample, L_2-view, automatic estimator, Gaussian stationary process.

The focus of the thesis is kernel density estimators in the setting of a small-size sample. Explicit formulas for automatic and non-automatic kernel estimators are derived and studied for both independent and dependent samples. The approach is based on the L_2-view, in which Relative Mean Integrated Squared Error is used as a quality metric. A new approach to obtain the optimal automatic density estimator is proposed for a sample comprised of dependent Gaussian random variables under stationarity assumption.

Оглавление

Введение **6**

1 Традиционные ядерные оценки для выборок с независимыми элементами **9**

1.1 Основные сведения из классической теории ядерного оценивания 9

1.1.1 Понятие малой выборки 13

1.2 Традиционные ядерные оценки в условиях малой выборки 15

1.2.1 Метод статистического моделирования 16

1.2.2 Представление ОИСКО в терминах характеристических функций . . 16

1.2.3 Случай выборки из нормального распределения 17

1.2.4 Численные результаты 19

2 Автоматические ядерные оценки в условиях малой выборки с независимыми элементами **22**

2.1 Автоматическая ядерная оценка плотности вероятности 22

2.1.1 Ортогональные преобразования 25

2.2 Случай нормальной выборки и ядра Гаусса 26

2.3 Численные результаты 29

3 Классические оценки плотности вероятности для выборок с независимыми элементами **31**

3.1 Метод максимального правдоподобия 31

3.1.1 Оценка плотности при известной дисперсии 32

3.1.2 Оценка плотности при известном математическом ожидании 32

3.1.3 Оценка плотности при двух неизвестных параметрах 33

3.2 Гистограммы 33

3.2.1 Численные результаты 34

3.3 Эффект малой выборки 35

4 Ядерная оценка для выборок с зависимыми элементами **37**

4.1 Исходные предположения. Понятие случайного процесса 37

4.1.1 Корреляционные функции . . . 38
4.1.2 Модели корреляционной зависимости . . . 41
4.1.3 Общее выражение ОИСКО неавтоматической оценки для зависимой выборки . . . 42
4.2 Неавтоматическая оценка для выборки из нормального распределения . . . 43
4.2.1 Случай трехдиагональной корреляционной матрицы . . . 45
4.3 Автоматическая оценка . . . 47
4.3.1 Общее выражение ОИСКО . . . 47
4.3.2 Слагаемое I_A . . . 47
4.3.3 Слагаемое I_B . . . 48
4.3.4 Слагаемое I_C . . . 50
4.3.5 Теорема об аналитической форме ОИСКО для случая гауссовского ядра и корреляционной матрицы общего вида . . . 51
4.4 Численные результаты и сравнения . . . 52
4.4.1 Моделирование методом Монте-Карло . . . 52
4.4.2 Значения ОИСКО и оптимальные параметры . . . 53
4.4.3 Дополнительные исследования . . . 56

Заключение **60**

Литература **62**

A Таблицы **67**

B Дополнительные графики **69**

C Алгоритм вычисления вспомогательных коэффициентов **70**

Введение

Задача оценки плотности вероятности непрерывной случайной величины X на основании выборки ее значений $X_1, \ldots, X_n$ заданного объема n составляет одну из центральных проблем математической статистики. Указанная задача, во-первых, представляет большой самостоятельный интерес, так как именно ее решение часто служит конечной целью исследования. Во-вторых, оценка плотности является обязательным элементом решения других многочисленных важных статистических задач, таких, как проверка статистических гипотез, регрессионный и кластерный анализ, распознавание образов и ряда других, подобных перечисленным.

Различают два принципиально разных подхода к задаче оценки закона распределения: *параметрический* и *непараметрический*. При первом из них оцениваемый закон считается функцией заданного вида, но зависящей от нескольких числовых параметров, которые, собственно говоря, и требуется оценить по выборке. Таким образом, здесь оценивается некоторый векторный параметр, принадлежащий к соответствующему *конечномерному* пространству.

При втором подходе, искомый закон распределения разыскивают в самом общем виде без какой-либо параметризации, то есть как элемент некого *бесконечномерного* функционального пространства.

Достоинством параметрических методов является их относительная простота, а также тот немаловажный факт, что для законов, допускающих точную параметризацию, их параметрические оценки, как правило, имеют меньшую погрешность, чем непараметрические. Вместе с тем саму параметризацию строго и корректно удается осуществить только в исключительных случаях. Приближенная же параметризация таит в себе опасность грубых ошибок, так как параметрические оценки весьма чувствительны к отклонениям от теоретического типа распределения. Все это объясняет важную роль непараметрических методов и повышенный интерес к ним в последние десятилетия.

Наиболее известной классической непараметрической оценкой плотности является *гистограмма*. Она строится следующим образом. Диапазон изменения случайной величины X делят на интервалы, или разряды (как правило, одинаковой ширины). Затем для каждого разряда подсчитывают частоту попадания элементов выборки в него. В пределах разряда оценка плотности аппроксимируется постоянной, равной отношению эмпирической частоты разряда к его ширине.

Гистограмма является исторически первой и универсальной оценкой плотности. Однако этот метод имеет существенные недостатки. Главными из них является низкая точность, а также сама ступенчатая кусочно-постоянная форма оценки, которая наглядно представляет искомую плотность только при малой ширине разрядов и при условии попадания большого числа элементов выборки в каждый из них. В результате качественную гисто-

граммную оценку можно построить только для выборок большого объема n.

В современных руководствах по статистике отмечается, что гистограмма, как оценка плотности, в настоящее время вытесняется другими, более точными методами оценивания, такими, как оценки ядерного типа Э. Парзена-М. Розенблатта или проекционные оценки Н.Н. Ченцова [23]. При этом важно отметить, что при небольшом числе наблюдений преимущество имеют ядерные оценки [6]. Именно этому классу оценок в условиях малой выборки и посвящено настоящее диссертационное исследование.

Указанная тема работы обладает несомненной новизной и практической значимостью. Ситуации, когда экспериментальных данных мало, нередко возникают на практике. Малый объем выборки может быть обусловлен экономическими причинами (высокая стоимость натурных испытаний), большими временными затратами на сбор информации, уникальностью самих исследуемых объектов (например, в геологии при отборе образцов горных пород). При этом ставится задача максимально рационально организовать оценивание в условиях скудного статистического материала.

Диссертация состоит из введения, четырех глав, заключения, списка литературы и приложений.

Первая глава содержит необходимые общие сведения по теории ядерного оценивания и теории малой выборки. Детально излагается L_2-теория для традиционных (не являющихся автоматическими в смысле П. Деовеля) ядерных оценок. Подробно рассмотрен случай выборки из нормального закона, для которого приведено исследование точности традиционных ядерных оценок в условиях малой выборки.

Во **второй главе** исследуются автоматические ядерные оценки в смысле П. Деовеля. Их особенностью является то, что параметр сглаживания формируется пропорционально некоторой статистике параметра масштаба, причем коэффициент пропорциональности выбирается оптимальным образом. Таким образом, построенные оценки являются адаптивными и не требуют никакой дополнительной информации кроме самой выборки. Приводится теоретическое обоснование оценок, а также анализируется их точность.

В **третьей главе** рассмотрены классические оценки (различные варианты метода максимального правдоподобия), а также гистограмма. Приведено сравнительное исследование точности классических и ядерных оценок, на основе которого разбирается так называемый *эффект малой выборки*, заключающийся в преимуществе по точности ядерных оценок над классическими при достаточно малых n.

В **четвертой главе** изучаются ядерные оценки для выборок с зависимыми элементами (то есть по существу для реализаций *случайных процессов*). Для случая стационарного гауссовского процесса с заданной нормированной корреляционной функцией строится как традиционные, так и автоматические оценки. Разобраны несколько вариантов корреляционной зависимости между элементами выборки. Изучен предельный случай радиуса корреляции, стремящегося к нулю, соответствующий выборке с независимыми элементами. Доказана согласованность этих результатов с результатами предыдущих глав. Дополнительно проведена проверка и сравнение с результатами статистического моделирования.

Заключение содержит краткий перечень основных результатов, полученных в диссертации.

Список литературы содержит 63 работы отечественных и зарубежных авторов.

Приложения содержат вспомогательный материал, включающий громоздкие выкладки, исключенные из основного текста, чтобы не нарушить целостность изложения, дополнительные таблицы, графики, а также алгоритмы программ, с помощью которых были получены все числовые результаты. Всего в работе 3 приложения.

Глава 1

Традиционные ядерные оценки для выборок с независимыми элементами

1.1 Основные сведения из классической теории ядерного оценивания

Рассмотрим скалярную случайную величину X непрерывного типа. Допустим, что проведена серия повторных независимых наблюдений этой величины, на основе которых сформирована выборка $X_1, \ldots, X_n$ объема n. В этой главе считается, что все элементы выборки независимы и одинаково распределены. Обозначим плотность вероятности X через $f(x)$. Задача заключается в том, чтобы по выборке построить оценку $\hat{f}(x)$ неизвестной плотности вероятности $f(x)$.

Ядерной оценкой плотности f называют оценку вида

$$\hat{f}(x) = \frac{1}{nh} \sum_{j=1}^{n} K\left(\frac{x - X_j}{h}\right), \quad h > 0, \tag{1.1}$$

где функция $K(x)$ называется *ядром* оценки, а числовой параметр h — *параметром сглаживания*. Если параметр h не зависит от элементов выборки, то оценку (1.1) будем называть *традиционной* (или классической). В настоящей главе мы сосредоточим свое внимание только на таких оценках.

Отметим, что в общей теории ядерного оценивания рассматривают также случаи, когда допускается зависимость h от элементов выборки. Такую ядерную оценку называют *адаптивной* (см.,например, [10]). В дальнейшем в диссертации будет рассмотрен один важный класс адаптивных оценок, а именно так называемые *автоматические* оценки, введенные П. Деовелем [40]. Их детальному рассмотрению будет посвящена глава 2.

Сформулируем дополнительные ограничения, накладываемые на ядро. Прежде всего будем считать, что рассматриваемые плотности вероятности f и ядра K квадратично интегрируемы по всей вещественной оси, то есть будем придерживаться L_2-подхода (существует альтернативный L_1-подход [10], однако он менее употребителен и гораздо более сложен в математическом отношении).

Далее в диссертации будут использоваться только ядра удовлетворяющие условиям:

$$\int\limits_{-\infty}^{+\infty} K(x)dx = 1, \quad K(x) \geq 0, \tag{1.2}$$

$$\int\limits_{-\infty}^{+\infty} x^2 K(x)dx < \infty, \tag{1.3}$$

$$K(-x) = K(x). \tag{1.4}$$

Такие ядра называют *регулярными*. Очевидно, регулярное ядро представляет собой некоторую плотность вероятности, причем такую, которая имеет моменты первого и второго порядка. Подчеркнем, что ядро положительно и нормировано, то есть удовлетворяет всем свойствам плотности вероятности. Нетрудно показать, что в случае регулярности ядра оценка (1.1) также обладает всеми свойствами плотности вероятности.

В рамках L_2-подхода за меру точности оценки (1.1) принимается интегральное среднеквадратичное отклонение (или сокращенно ИСКО). В англоязычной научной литературе для обозначения этой величины традиционно используется аббревиатура MISE (Mean Integrated Squared Error). По определению

$$\mathrm{MISE}(f, \hat{f}) = \mathbb{E}\,\|f - \hat{f}\|^2,$$

где $\mathbb{E}$ обозначает символ математического ожидания, а под $\|\cdot\|$ подразумевается норма в пространстве $L_2(\mathbb{R})$.

В настоящей работе в качестве основной будет использоваться несколько видоизмененная мера точности оценки, а именно относительное интегральное среднеквадратическое отклонение (ОИСКО) или в английской нотации RMISE (Relative Mean Integrated Squared Error), определяемое формулой:

$$\mathrm{RMISE}(f, \hat{f}) = \frac{\mathbb{E}\,\|f - \hat{f}\|^2}{\|f\|^2}. \tag{1.5}$$

Величина RMISE обладает определенными преимуществами по сравнению с MISE, так как, во-первых, она является безразмерной, во-вторых, зависит только от безразмерного параметра сглаживания и, в-третьих, характеризуется свойством инвариантности по отношению к линейному преобразованию случайной величины X с некоторыми параметрами сдвига и масштаба (на это обстоятельство обращалось внимание в работах [1, 15, 14]).

Впервые ядерная оценка вида (1.1) была предложена М. Розенблаттом в 1956 году [58]. Розенблатт пытался оценить плотность вероятности в виде конечной разности от эмпирической оценки функции распределения $\hat{F}(x)$, а именно

$$\hat{f}(x) = \frac{\hat{F}(x+h) - \hat{F}(x-h)}{2h},$$

где $\hat{F}(x)$ определяется как отношение числа элементов выборки, меньших, чем x, к ее объему n. Очевидно, такую оценку можно представить в виде (1.1), если выбрать ядро $K(x)$ в виде плотности равномерного закона на интервале $[-1, 1]$:

$$K(x) = \begin{cases} \frac{1}{2}, & \text{если } |x| \leq 1 \\ 0, & |x| > 1. \end{cases}$$

Такое ядро называют *прямоугольным*. Ядра общего вида, отличные от прямоугольного, впервые использовал в 1962 году Э. Парзен [54]. Работа Парзена послужила отправной точкой для целого нового направления в математической статистике. В шестидесятые и семидесятые годы было опубликовано большое число статей, посвященных исследованию оценок плотности вида (1.1) и родственных им оценок. Результаты этих исследований были подытожены в ряде обзоров, опубликованных в семидесятые и восьмидесятые годы [36, 38, 49, 62, 63].

В конце семидесятых — начале восьмидесятых годов появились первые монографии по теории ядерных оценок. Одной из первых была опубликована книга Р. Тапия и Дж. Томпсона [60]. Особо следует отметить книгу грузинского математика Э.А. Надарая [21], выпущенную в Тбилиси в 1983 году. Надарая внес большой личный вклад в разработку теории ядерного оценивания и является одним из ведущих специалистов в этой области. Его книга длительное время служила наиболее полным руководством по таким оценкам. В 1989 году книга в исправленном и дополненном варианте была переведена на английский язык [50]. Следует также упомянуть содержательную книгу Б. Сильвермана [59]. Из русскоязычных изданий ядерные оценки представлены также в книге [9].

Как уже отмечалось во введении, в последние годы наблюдается повышенный интерес специалистов к непараметрическим методам оценивания плотности и непараметрической статистике вообще. Был опубликован целый ряд руководств, в которых достаточно подробно разбираются ядерные оценки плотности. Например, в монографиях [41, 55] им посвящены целые главы.

Следует сказать, что имеются и специальные руководства, посвященные исключительно ядерным оценкам, как, например, книги [43, 45, 61], но применительно к интересующей нас задаче оценки одномерной плотности в них, в основном, приводятся старые, классические результаты, известные еще с прошлого века. Авторов современных руководств по ядерному оцениванию интересуют другие вопросы, связанные с этой темой. Например, рассматривают оценку функции регрессии, оценку многомерной плотности, рекурсивные оценки, оценки производных плотности, оценки функционалов от нее и другие специальные проблемы. К сожалению, работы по анализу малой выборки крайне немногочисленны, а тема эта разработана недостаточно несмотря на ее актуальность и практическую значимость.

Современная теория ядерного оценивания является преимущественно асимптотической

и интересуется прежде всего поведением оценок при больших объемах выборки. Чтобы было более понятно, какими проблемами она занимается, приведем сводку наиболее важных теоретических результатов. Вначале дадим ряд определений.

Оценка плотности $\hat{f}(x)$ называется *асимптотически несмещенной*, если

$$\lim_{n\to\infty} \mathbb{E}[\hat{f}(x)] = f(x).$$

Иначе говоря, асимптотическая несмещенность означает отсутствие систематической ошибки при неограниченном увеличении объема выборки.

Оценку $\hat{f}(x)$ называют *состоятельной*, если она сходится по вероятности к оцениваемой плотности $f(x)$. Состоятельность свидетельствует о том, что оценка уточняется с ростом объема выборки. Достаточным условием состоятельности является асимптотическая несмещенность и стремление к нулю ИСКО оценки.

Иногда требование состоятельности усиливают таким образом, чтобы $\sup_{x\in\mathbb{R}} |\hat{f}(x) - f(x)|$ сходился по вероятности к нулю. Такую оценку называют *равномерно состоятельной*.

В классической теории ядерного оценивания доказаны следующие утверждения.

Утверждение 1.1. *Для того, чтобы оценка* (1.1) *была асимптотически несмещенной достаточно выполнения условия*

$$\lim_{n\to+\infty} h_n = 0. \tag{1.6}$$

Утверждение 1.2. *Для состоятельности оценки* (1.1) *достаточно потребовать, чтобы*

$$\lim_{n\to+\infty} nh_n = +\infty. \tag{1.7}$$

Утверждение 1.3. *Для равномерной состоятельности оценки* (1.1) *условие* (1.7) *усиливается следующим образом*

$$\lim_{n\to+\infty} nh_n^2 = +\infty.$$

Одной из центральных проблем при ядерном оценивании является оптимальный выбор параметра сглаживания h. В настоящей диссертационной работе эта задача будет решаться при конечном фиксированном значении n. В классической теории оптимальное значение h_n при больших объемах выборки n впервые было получено В.А. Епанечниковым [11]. Вывод оптимального значения h_n основывается на следующем факте [11, 40, 58].

Утверждение 1.4. *Пусть при больших n параметр сглаживания h_n одновременно удовлетворяет условиям* (1.6) *и* (1.7)*. Тогда для ИСКО оценки* (1.1) *выполняется следующая асимптотика*

$$\mathrm{MISE}(f, \hat{f}) = \mathrm{AMISE}(f, \hat{f}) + o\left(\frac{1}{nh_n}\right) + o(h_n^4), \tag{1.8}$$

где AMISE обозначает асимптотическое интегральное среднеквадратическое отклонение

$$\mathrm{AMISE}(f, \hat{f}) = \frac{1}{nh_n}\|K\|^2 + \frac{h_n^4}{4}\left(\int\limits_{-\infty}^{+\infty} y^2 K(y)dy\right)^2 \|f''\|^2, \tag{1.9}$$

причем все нормы и интегралы, входящие в (1.9)*, предполагаются конечными.*

В выражение (1.9) входят два слагаемых, первое из которых монотонно убывает с ростом h_n, а второе, напротив, монотонно возрастает. Следовательно, существует минимум AMISE по h_n. Для его получения следует продифференцировать правую часть по h_n и приравнять результат к нулю. Тогда приходим к следующему утверждению.

Утверждение 1.5. *Если ядро $K(x)$ в* (1.1) *квадратично интегрируемо, выполнено условие* (1.3)*, а плотность $f(x)$ имеет квадратично интегрируемую вторую производную $f''(x)$, то тогда асимптотически оптимальным является параметр сглаживания*

$$h^*_{AMISE} = \left(\frac{\|K\|^2}{n\left(\int\limits_{-\infty}^{+\infty} y^2 K(y)dy\right)^2 \|f''\|^2}\right)^{1/5}. \tag{1.10}$$

В дальнейшем такой выбор параметра h_n будем называть *асимптотическим правилом.*

Выражение (1.9) представляет собой некоторый функционал относительно ядра K. Этот функционал является квадратичным по K и легко может быть минимизирован при соответствующих дополнительных условиях. Впервые такая задача была решена В.А. Епанечниковым в [11].

Утверждение 1.6. *Минимум функционала* (1.9) *относительно формы ядра $K(x)$ при дополнительных условиях*

$$\int\limits_{-\infty}^{+\infty} K(x)dx = 1, \quad \int\limits_{-\infty}^{+\infty} x^2 K(x)dx = 1$$

достигается при форме ядра

$$K(x) = \begin{cases} \frac{3}{4\sqrt{5}}(1 - \frac{y^2}{5}), & \text{если } |y| \le \sqrt{5} \\ 0, & |y| > \sqrt{5}. \end{cases}$$

Такое ядро называется *ядром Епанечникова.*

1.1.1 Понятие малой выборки

В последние десятилетия в литературе публикуется большое число работ, посвященных проблемам *малой выборки* (в англоязычной литературе для обозначения этого понятия используется термин *small sample*). Первая монография, систематически изучающая вопросы оценки плотности вероятности по малому числу наблюдений была опубликована

более сорока лет тому назад [6]. С тех пор были опубликованы сотни журнальных статей и целый ряд научно-прикладных руководств (см, например, [19, 26, 28, 29]). Каждый год продолжают выходить новые работы. Ввиду актуальности и практической значимости данной темы интерес к ней исследователей не ослабевает. При этом, однако, большинство публикуемых работ посвящено конкретным прикладным исследованиям. Ощущается необходимость в более глубоком теоретическом анализе проблем малой выборки.

В настоящей диссертации тема малой выборки является центральной, поэтому необходимо остановиться на трактовке этого понятия подробнее.

Прежде всего следует отметить, что многие авторы понимают под малой выборкой попросту выборку ограниченного объема. Считается, что к теме малой выборки относятся все работы, в которых не используется предельный переход, предусматривающий неограниченное увеличение объема выборки n. При такой трактовке в качестве первого крупного специалиста по теории малой выборки называют знаменитого английского специалиста по статистике Стьюдента (псевдоним У. Госсета), который предложил ряд статистических процедур, не требующих асимптотически больших n. В указанном смысле все выборки, рассматриваемые в настоящей диссертационной работе, разумеется, будут являться малыми.

В ряде работ (см., например, [6, 15]) дается несколько иная, более узкая по смыслу трактовка понятия малости выборки, опирающаяся на анализ точности оценивания. Выборку $X_1, \ldots, X_n$ называют при этом *малой*, если по ней невозможно оценить подлежащие определению вероятностные характеристики с требуемой точностью. Это определение является достаточно общим, так как объем ниже которого выборку следует считать малой зависит от многих факторов: выбранной меры точности, типа распределения генеральной совокупности, оцениваемой характеристики, используемой оценки.

Например, при ядерном оценивании плотности в качестве меры точности будем использовать ОИСКО (1.5). Зададим критический уровень погрешности оценивания δ_{cr}. Тогда выборку объема n следует признать малой, если ни при каком выборе параметра сглаживания не удается обеспечить выполнение неравенства $\mathrm{RMISE}(f, \hat{f}) < \delta_{cr}$. В настоящей диссертации будут получены аналитические выражения для ОИСКО ядерной оценки при конечных n, с помощью которых можно безо всякого труда решить вопрос о малости выборки в смысле определения, подобного [6, 15].

Существует еще одна трактовка понятия малой выборки, при которой обращают внимание на те статистические методы и процедуры, которые обеспечивают наименьшую погрешность оценивания [6, 12, 15]. Как свидетельствует опыт, во многих практически интересных задачах статистического оценивания существует такой критический объем выборки n_{cr}, что при $n < n_{cr}$ классические оценки оказываются менее точными, чем некоторые специальным образом построенные неклассические оценки. При этом считают, что при $n < n_{cr}$ проявляется так называемый *эффект малой выборки*.

Например, в задаче обработки результатов косвенных измерений [12] теоретически доказано, что существует такое n_{cr}, что при $n < n_{cr}$ более эффективной при оценке среднего является не классическая оценка, а так называемая «псевдооценка». В монографии [6] на основе анализа большого экспериментального материала, полученного в конкретных исследованиях по прикладной статистике, делается вывод, что при малых n более эф-

фективной, чем классические оценки является ядерная оценка. Настоящая диссертация посвящается строго количественному анализу этого явления и получению конкретных значений n_{cr} при различных комбинациях закона распределения генеральной совокупности и закона распределения, ассоциированного с формой ядра.

1.2 Традиционные ядерные оценки в условиях малой выборки

Рассмотрим семейство плотностей вида

$$f(x) = \frac{1}{\sigma} f_0\Big(\frac{x-\mu}{\sigma}\Big), \tag{1.11}$$

где $f_0(x)$ обозначает некоторую заданную базовую плотность вероятности, а μ и σ — числовые параметры, удовлетворяющие неравенствам $\sigma > 0, -\infty < \mu < \infty$. Про семейство распределений указанного вида говорят, что оно имеет *тип* f_0, при этом параметр μ называют *параметром сдвига*, а параметр σ — *параметром масштаба* [15, 22].

Обозначим через Y случайную величину, распределенную по закону f_0. Нетрудно понять, что любая случайная величина типа f_0 может быть представлена в виде линейного преобразования этой базовой случайной величины, причем коэффициенты преобразования совпадают с коэффициентами сдвига и масштаба: $X = \sigma Y + \mu$.

Весь смысл введения семейства распределений вида (1.11) состоит в том, что для всех плотностей такого семейства (и при заданной форме ядра) ОИСКО ядерной оценки (1.1) будет зависеть только от безразмерного параметра сглаживания $\xi = \frac{h}{\sigma}$, выраженного в долях параметра масштаба σ. Сформулируем это утверждение более точно в виде следующей леммы, играющей важнейшую роль во всем дальнейшем изложении.

Лемма 1.1. *(О безразмерном параметре). При заданной форме ядра K и заданном типе f_0 распределения выборки ОИСКО оценки (1.1) зависит только от отношения $\xi = \frac{h}{\sigma}$.*

Доказательство.
Рассмотрим семейство плотностей вида (1.11). Пусть $Y_1, \dots, Y_n$ – новая выборка, составленная из значений $Y_j = \frac{X_j - \mu}{\sigma}$. Тогда, выражая элементы X через Y, делая замену переменных интегрирования $y = \frac{x-\mu}{\sigma}$ в (1.5) и полагая $h = \xi\sigma$, получаем:

$$\mathrm{RMISE}(f, \hat{f}) = \frac{\mathbb{E}\Big[\int\limits_{-\infty}^{+\infty} \Big(f(x) - \frac{1}{nh}\sum\limits_{j=1}^{n} K\Big(\frac{x-X_j}{h}\Big)\Big)^2 dx\Big]}{\int\limits_{-\infty}^{+\infty} f^2(x)dx} = \frac{\mathbb{E}\Big[\int\limits_{-\infty}^{+\infty} \Big(f_0(y) - \frac{1}{n\xi}\sum\limits_{j=1}^{n} K\Big(\frac{y-Y_j}{\xi}\Big)\Big)^2 dy\Big]}{\int\limits_{-\infty}^{+\infty} f_0^2(y)dy}. \tag{1.12}$$

Таким образом, оптимальный безразмерный параметр ξ минимизирующий ОИСКО для базовой плотности f_0 будет доставлять минимум для всех плотностей семейства типа f_0.

Минимизируя ОИСКО по параметру ξ, мы получим оптимальный параметр $h^* = \sigma\xi^*$.

Оценку, соответствующую такому выбору параметра условимся называть *неавтоматической*. На практике, точное значение параметра σ обычно заранее неизвестно и вместо него приходится использовать какую-либо оценку $\hat{\sigma}$. Вопрос о том, насколько так построенная ядерная оценка теряет в точности будет рассмотрен в следующих разделах.

1.2.1 Метод статистического моделирования

Исследовать ОИСКО можно методом Монте-Карло, заменив вычисление математического ожидания в выражении (1.12) на усреднение по выборочным данным, полученным методом статистического моделирования [20, 35].

Рассмотрим N независимых выборок $\mathbf{x}_j = (X_{1j}, \ldots, X_{nj}),\ j = 1, \ldots, N$ из заданного распределения, тогда

$$\frac{\mathbb{E}\,\|f - \hat{f}(n,\xi)\|^2}{\|f\|^2} \approx \frac{1}{N\|f\|^2} \sum_{j=1}^{N} \|f - \hat{f}(n,\xi,\mathbf{x}_j)\|^2.$$

Полученные результаты будут содержать ощутимые случайные ошибки, так как метод сходится с ростом N достаточно медленно. В данной работе моделирование используется только для проверки теоретических результатов.

1.2.2 Представление ОИСКО в терминах характеристических функций

Для упрощения дальнейших вычислений перейдем от плотностей вероятности к характеристическим функциям. Здесь и далее используем обозначение

$$E_f(z) = \int\limits_{-\infty}^{+\infty} e^{izx} f(x)dx. \tag{1.13}$$

Заметим, что характеристическая функция E_f является результатом применения *преобразования Фурье* к плотности вероятности f.

Лемма 1.2. *Выражение для ОИСКО классической ядерной оценки* (1.1) *по выборке с независимыми элементами в терминах характеристических функций имеет вид*

$$\mathrm{RMISE}(f,\hat{f}) = \frac{\int\limits_{-\infty}^{+\infty} \left(|E_{f_0}(z)|^2 - 2|E_{f_0}(z)|^2 E_K(\xi z) + \frac{1}{n}|E_K(\xi z)|^2 + \frac{n-1}{n}|E_{f_0}(z)|^2|E_K(\xi z)|^2\right) dz}{\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 dz}. \tag{1.14}$$

Доказательство.

С помощью формулы Парсеваля для преобразования Фурье [31] выражение (1.12) приводится к виду:

$$\mathrm{RMISE}(f,\hat{f}) = \frac{\mathbb{E}\left[\int\limits_{-\infty}^{+\infty} \left|E_{f_0}(z) - \frac{1}{n}\sum\limits_{j=1}^{n} e^{iY_j z} E_K(\xi z)\right|^2 dz\right]}{\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 dz}.$$

Раскрывая здесь полный квадрат в интеграле, стоящем в числителе, приходим к равенству

$$\mathrm{MISE}(f,\hat{f}) = \mathbb{E}\Big[\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 - \frac{2}{n}\,\mathrm{Re}\,\big(\overline{E_{f_0}(z)}\sum_{j=1}^{n} e^{iY_j z}E_K(\xi z)\big) + \frac{1}{n^2}\sum_{1\le s,t\le n} e^{i(Y_s-Y_t)z}|E_K(\xi z)|^2 dz\Big]. \tag{1.15}$$

Обе суммы в полученном выражении допускают упрощение если элементы Y независимы и одинаково распределены. Опуская ряд простых выкладок, которые подробно изложены в [32], получаем следующее:

$$\mathrm{MISE}(f,\hat{f}) = \mathbb{E}\Big[\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 - 2\,\mathrm{Re}\,(\overline{E_{f_0}(z)}e^{iY_k z}E_K(\xi z)) + \frac{1}{n}|E_K(\xi z)|^2 + \frac{n-1}{n}e^{i(Y_l-Y_m)z}|E_K(\xi z)|^2 dz\Big]. \tag{1.16}$$

Далее, по теореме Фубини [17], оператор математического ожидания можно внести под знак интеграла. Пользуясь тем, что $\mathbb{E}\big[\,\mathrm{Re}(X)\big] = \mathrm{Re}(\mathbb{E}\big[X\big])$ для произвольной комплексной случайной величины X и $E_{f_0}(-z) = \overline{E_{f_0}(z)}$, приходим к (1.14).

<u>Замечание.</u> В работе [61] ИСКО неавтоматической оценки приводится к несколько иному виду

$$\mathrm{MISE}(f,\hat{f}) = \int\limits_{-\infty}^{+\infty} f^2(y)dy - 2\int\limits_{-\infty}^{+\infty}(K_h * f)(y)f(y)dy + \frac{1}{n}\int\limits_{-\infty}^{+\infty} K_h^2(y)dy + \frac{n-1}{n}\int\limits_{-\infty}^{+\infty}(K_h * f)^2(y)dy, \tag{1.17}$$

где введено обозначение $K_h(y) = \frac{1}{h}K(\frac{y}{h})$. Результат леммы можно получить из этой формулы следующим образом: сначала необходимо перейти от параметра h к безразмерному параметру ξ, а затем полученный результат преобразовать с помощью теоремы о свертке и обобщенного тождества Парсеваля [31]:

$$\int\limits_{-\infty}^{+\infty} f(x)g(x)dx = \frac{1}{2\pi}\int\limits_{-\infty}^{+\infty} E_f(z)\overline{E_g(z)}dz.$$

1.2.3 Случай выборки из нормального распределения

В данной работе нас всегда будет интересовать явный вид ОИСКО при различных предположениях о типе распределения элементов выборки и форме ядра. Для некоторых частных способов их задания выражение для ОИСКО существенно упростится. Выражение для ОИСКО для выборки из нормального распределения и произвольного ядра K имеет вид:

$$\mathrm{RMISE}(f,\hat{f}) = 1 + \frac{1}{\sqrt{\pi}}\Big(\frac{1}{n}\int\limits_{-\infty}^{+\infty}|E_K(\xi z)|^2 dz - 2\int\limits_{-\infty}^{+\infty} e^{-z^2}E_K(\xi z)dz + \frac{n-1}{n}\int\limits_{-\infty}^{+\infty} e^{-z^2}|E_K(\xi z)|^2 dz\Big). \tag{1.18}$$

Для дальнейших упрощений по отдельности рассматриваются слагаемые:

$$I_1 = \int\limits_{-\infty}^{+\infty}|E_K(\xi z)|^2 dz,\ I_2 = \int\limits_{-\infty}^{+\infty} e^{-z^2}E_K(\xi z)dz, I_3 = \int\limits_{-\infty}^{+\infty} e^{-z^2}|E_K(\xi z)|^2 dz.$$

Слагаемые подобного типа будут постоянно встречаться в дальнейшем изложении при рассмотрении ОИСКО различных оценок плотности. Далее получим аналитическое представление ОИСКО неавтоматической оценки для некоторых типов ядер.

1. Рассмотрим ядро Гаусса $K(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$.
В работах [1, 13, 32] все вычисления уже были проделаны до конца, причем оказалось, что

$$I_1 = \frac{\sqrt{\pi}}{\xi},\ I_2 = \frac{\sqrt{2\pi}}{\sqrt{2+\xi^2}},\ I_3 = \sqrt{\frac{\pi}{1+\xi^2}}.$$

Собирая все слагаемые вместе получаем искомое выражение ОИСКО:

$$\mathrm{RMISE}(f, K, \xi, n) = 1 + \frac{1}{n\xi} - \frac{2\sqrt{2}}{\sqrt{2+\xi^2}} + \frac{n-1}{n}\frac{1}{\sqrt{1+\xi^2}}. \tag{1.19}$$

Этот результат можно найти и в зарубежных работах, например в монографии [61].

2. Рассмотрим прямоугольное ядро $K(x) = \begin{cases} \frac{1}{2}, & \text{если } |x| < 1 \\ 0, & \text{иначе} \end{cases}$, (см. [54, 58]).

Выкладки здесь несколько усложнятся, однако сам процесс получения результата остается неизменным. Точно так же, как и в предыдущем случае выделяем три слагаемых:

1. $I_1 = \mathbb{E} \int\limits_{-\infty}^{+\infty} \left(\frac{\sin \xi z}{\xi z}\right)^2 dz = \frac{\pi}{\xi}$.

2. $I_2 = \int\limits_{-\infty}^{+\infty} e^{-z^2} \frac{\sin \xi z}{\xi z} dz = \frac{1}{\xi}\pi \operatorname{erf}(\frac{\xi}{2})$.

3. $I_3 = \int\limits_{-\infty}^{+\infty} e^{-z^2} \frac{\sin^2 \xi z}{\xi^2 z^2} dz = \frac{1}{\xi^2}(\xi\pi \operatorname{erf}(\xi) + \sqrt{\pi}(e^{-\xi^2} - 1))$.

Первые два интеграла можно найти в справочниках (см. [8, 51]).

Третий интеграл приходится вычислять самостоятельно. Докажем, что:

$$\int\limits_{-\infty}^{+\infty} e^{-z^2} \frac{\sin^2 Az}{z^2} dz = A\pi \operatorname{erf}(A) + \sqrt{\pi}(e^{-A^2} - 1).$$

Действительно, пусть $I(A) = \int\limits_{-\infty}^{+\infty} e^{-z^2} \frac{\sin^2 Az}{z^2} dz$, тогда $I'(A) = \int\limits_{-\infty}^{+\infty} e^{-z^2} \frac{\sin(2Az)}{z} dz = \pi \operatorname{erf}(A)$. Первообразная для функции $\operatorname{erf}(x)$ хорошо известна (см. [51]), интегрирование дает результат

$$I(A) = \pi(A \operatorname{erf}(A) + \frac{e^{-A^2}}{\sqrt{\pi}}) + C.$$

Начальное условие $I(0) = 0$ позволяет найти значение константы $C = -\sqrt{\pi}$, что и доказывает утверждение. Отсюда получаем выражение для третьего слагаемого:

$$I_3 = \frac{1}{\xi^2}(\xi\pi\,\mathrm{erf}(\xi) + \sqrt{\pi}(e^{-\xi^2} - 1)).$$

Собирая все три слагаемых вместе, получаем искомое выражение ОИСКО:

$$\mathrm{RMISE}(f, K, \xi, n) = 1 + \frac{\sqrt{\pi}}{n\xi} - \frac{2}{\xi}\sqrt{\pi}\,\mathrm{erf}(\frac{\xi}{2}) + \frac{n-1}{n\xi^2}(\xi\sqrt{\pi}\,\mathrm{erf}(\xi) + e^{-\xi^2} - 1). \tag{1.20}$$

1.2.4 Численные результаты

Для удобства сравнения результатов, относящихся к разным ядрам, в работах [1, 15] предлагается нормировать все ядра по второму моменту:

$$\int\limits_{-\infty}^{+\infty} x^2 K(x)dx = 1.$$

Это легко сделать, учитывая что для промасштабированного семейства ядер вида $K(x) = aK_0(ax)$ справедливо тождество:

$$\mathrm{RMISE}(f, K, \xi) = \mathrm{RMISE}(f, K_0, \frac{\xi}{a}).$$

Выбрав $a = \sqrt{\int\limits_{-\infty}^{+\infty} x^2 K_0(x)dx}$, получим нормировку, представленную в таблице 1.1.

Таблица 1.1: Нормировочные множители для различных ядер.

$K_0(x)$	a
$\frac{1}{2\pi}e^{-\frac{x^2}{2}}$	1
$\begin{cases} \frac{1}{2}, & \text{если } \lvert x\rvert < 1 \\ 0, & \text{иначе} \end{cases}$	$\frac{1}{\sqrt{3}}$

Далее все вычисления будем выполнять только для нормированных ядер.
По выражениям (1.19), (1.20) можно построить графики и таблицы минимумов и оптимальных параметров ξ^* (см. приложение).

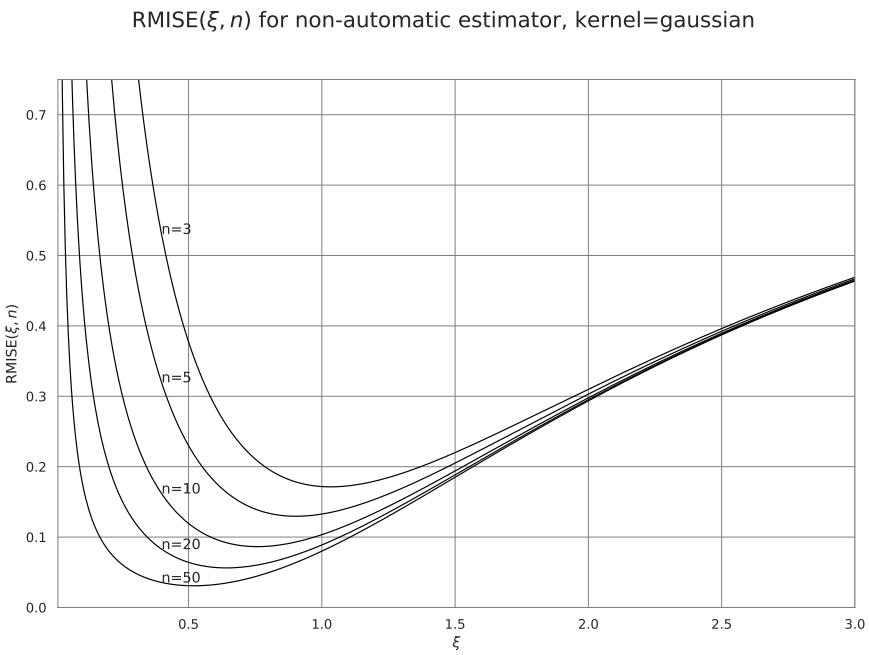

Рис. 1.1: ОИСКО неавтоматической оценки с ядром Гаусса.

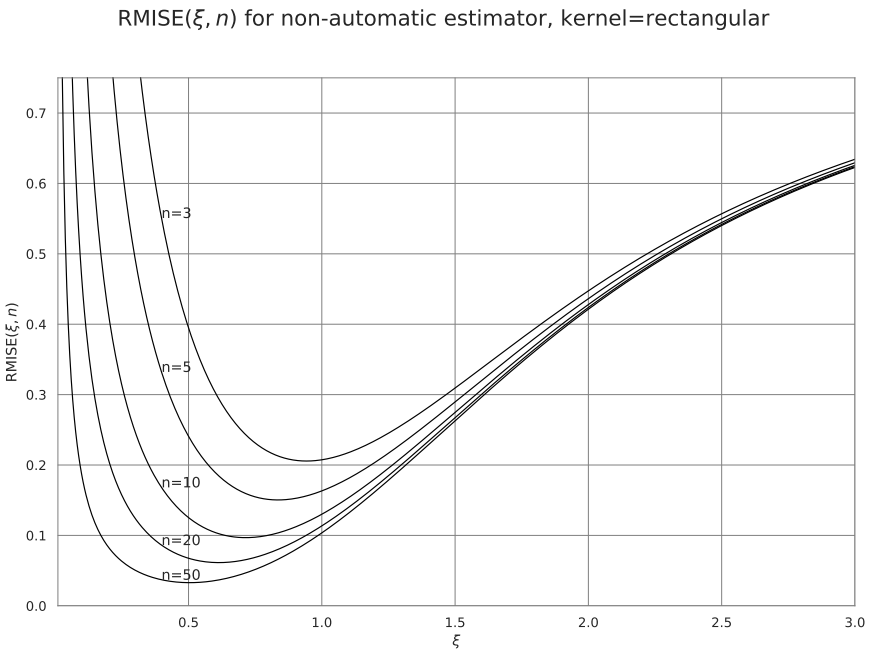

Рис. 1.2: ОИСКО неавтоматической оценки с прямоугольным ядром.

Графики для различных ядер очень похожи. Можно выделить ряд общих свойств.

1. Во всех случаях график для n_2 лежит ниже графика для n_1 для всех значений $n_1 < n_2$:

$$\mathrm{MISE}(f, K, \xi, n_1) - \mathrm{MISE}(f, K, \xi, n_2) > 0.$$

Для ядра Гаусса это утверждение было доказано в работе [32]. Докажем это в общем случае для любого типа распределения и при произвольной форме ядра.

Вычисляя разность числителей выражений (1.14) для заданных n_1, n_2, приходим к:

$$\mathrm{MISE}(f, K, \xi, n_1) - \mathrm{MISE}(f, K, \xi, n_2) = \left(\frac{1}{n_1} - \frac{1}{n_2}\right) \int\limits_{-\infty}^{+\infty} |E_K(\xi z)|^2 (1 - |E_{f_0}(z)|^2) dz > 0.$$

Полученное неравенство выполняется тождественно для любого ядра K и любого распределения абсолютно непрерывной случайной величины.
2. В пределе при $\xi \to 0$ справа ОИСКО неограниченно растет, если же $\xi \to \infty$, то значение ОИСКО стремится к единице снизу. Эти свойства очевидно следуют из полученных представлений (1.19), (1.20).

Как видно из приведенных результатов, ядро Гаусса дает большую точность оценки для выборки из нормального распределения. Отметим, что все полученные значения для прямоугольного ядра и ядра Гаусса совпали с результатами, приведенными в дипломе [1] с точностью до нормировки ядра.

Глава 2

Автоматические ядерные оценки в условиях малой выборки с независимыми элементами

2.1 Автоматическая ядерная оценка плотности вероятности

Построенная в первой главе традиционная неавтоматическая оценка плотности обладает принципиальным недостатком. В результирующем выражении для оценки сохраняется заранее неизвестное истинное (теоретическое) значение параметра масштаба σ, входящее в определяющее соотношение (1.11) для семейства распределений типа f_0. Собственно говоря, именно из-за этого оценка и была названа «неавтоматической»: для использования ее мало знать только выборку, необходимы также дополнительные соображения, позволяющие как-то задать σ.

Такие соображения очевидны, когда объем выборки n велик. Можно взять какую-либо состоятельную оценку $\hat{\sigma}$ параметра σ и приближенно заменить σ на $\hat{\sigma}$. В случае малой выборки такая замена некорректна, так как оценка параметра масштаба может сильно уклоняться от самого параметра.

При малых n приходится качественно усложнять вид оценки, используя *адаптивную* ядерную оценку. Напомним (см. главу 1), что ядерная оценка называется адаптивной, если ее параметр сглаживания

$$h = h(X_1, \ldots, X_n)$$

зависит от элементов выборки, то есть является некоторой статистикой [10].

Класс адаптивных ядерных оценок является весьма широким, а изучение точности таких оценок при самых общих предположениях относительно вида статистики $h(X_1, \ldots, X_n)$ представляет чрезвычайно сложную теоретическую задачу. Поэтому целесообразно несколько сузить класс рассматриваемых адаптивных оценок, выбрав функцию $h(X_1, \ldots, X_n)$ в некотором специальном частном виде.

В настоящем диссертационном исследовании будут детально изучены так называемые *автоматические* ядерные оценки плотности, впервые предложенные в восьмидесятые годы прошлого века французским математиком П. Деовелем [40]. Деовель формировал па-

раметр сглаживания в виде

$$h(X_1, \ldots, X_n) = \xi\theta(X_1, \ldots, X_n), \tag{2.1}$$

где в общем случае θ обозначает некоторую заданную статистику, а ξ — безразмерный параметр сглаживания, аналогичный по смыслу параметру, введенному ранее в первой главе. При этом появляется возможность оптимизировать оценку плотности, минимизируя ее ОИСКО по параметру ξ.

Особый интерес представляет тот случай, когда в качестве статистики θ используется *оценка параметра масштаба* σ, то есть

$$\theta(X_1, \ldots, X_n) = \hat{\sigma}(X_1, \ldots, X_n). \tag{2.2}$$

При этом, как нетрудно показать, для выборок с распределением типа f_0 оценка $\hat{\sigma}$ с точностью до постоянного множителя совпадает с оценкой среднеквадратического отклонения, рассчитанной по выборке $X_1, \ldots, X_n$.

Действительно, для двухпараметрического семейства распределений (1.11) исследуемая случайная величина X выражается через базовую случайную величину Y, распределенную по закону f_0, следующим образом

$$X = \sigma Y + \mu, \tag{2.3}$$

откуда следует, что

$$\sigma = \frac{\sigma_X}{\sigma_Y}.$$

Здесь σ_Y обозначает среднеквадратическое отклонение распределения f_0, которое задается по условию, причем часто выбирают базовое распределение так, чтобы σ_Y равнялось единице. Тогда

$$\hat{\sigma} = \hat{\sigma}_X = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(X_j - \bar{X})^2}, \quad \bar{X} = \frac{1}{n}\sum_{j=1}^{n} X_j. \tag{2.4}$$

Если $\sigma_Y \neq 1$, то тогда все равно можно принять $\theta = \hat{\sigma}$, но это приведет лишь к появлению некоторого постоянного масштабного множителя в (2.1).

Теперь можно сформулировать основную лемму, аналогичную лемме о безразмерном параметре, но относящуюся уже к автоматическим оценкам.

Лемма 2.1. *(Об инвариантности ОИСКО автоматических оценок). При заданной форме ядра K и заданном типе f_0 распределения выборки ОИСКО автоматической оценки вида (1.1), в которой параметр сглаживания задается в виде*

$$h(X_1, \ldots, X_n) = \xi\hat{\sigma}_X(X_1, \ldots, X_n), \tag{2.5}$$

где $\hat{\sigma}_X$ есть выборочное среднеквадратическое отклонение (2.4), зависит только от отношения $\xi = \frac{h}{\hat{\sigma}_X}$.

Доказательство.

Рассмотрим семейство плотностей вида (1.11), сформируем выборку $X_1, \ldots, X_n$ из генеральной совокупности распределенной по закону (1.11) и образуем новую выборку составленную из элементов $Y_j = \frac{X_j - \mu}{\sigma}$, $j = 1, \ldots, n$. Подставим оценку (1.1) с параметром сглаживания (2.5) в общее выражение (1.5) для ОИСКО. Затем выразим все элементы X_j исходной выборки через Y_j по формуле (2.3) и проделаем в интеграле замену переменной $y = \frac{x-\mu}{\sigma}$. Тогда после несложных алгебраических преобразований получим

$$\mathrm{RMISE}(\hat{\sigma}, f, \hat{f}) = \frac{\mathbb{E}\left[\int\limits_{-\infty}^{+\infty} (f_0(y) - \frac{1}{n\xi(\frac{\hat{\sigma}_X}{\sigma})} \sum\limits_{j=1}^{n} K\left(\frac{y-Y_j}{\xi(\frac{\hat{\sigma}_X}{\sigma})}\right))^2 dy\right]}{\int\limits_{-\infty}^{+\infty} f_0^2(y) dy}. \tag{2.6}$$

Осталось заметить, что величина

$$\frac{\hat{\sigma}_X}{\sigma} = \hat{\sigma}_Y = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(Y_j - \bar{Y})^2}, \quad \bar{Y} = \frac{1}{n}\sum_{j=1}^{n} Y_j \tag{2.7}$$

представляет собой заданную функцию от совокупности n независимых одинаково распределенных по закону f_0 величин и не зависит ни от параметров (μ, σ), ни от формы ядра.

В заключение заметим, что выбор статистики $h(X_1, \ldots, X_n)$ в форме (2.5) рекомендовал сам Деовель в [40]. Возникает вопрос, каким ограничениям должна удовлетворять статистика общего вида θ в (2.1), чтобы лемма сохранила силу. Из хода доказательства следует, что искомое ограничение таково:

$$\theta(\sigma X_1 + \mu, \ldots, \sigma X_n + \mu) = \sigma\theta(X_1, \ldots, X_n).$$

В частном случае, когда $\mu = 0$ и семейство (1.11) является однопараметрическим с параметром масштаба σ, имеем

$$\theta(\sigma X_1, \ldots, \sigma X_n) = \sigma\theta(X_1, \ldots, X_n),$$

то есть статистика θ должна быть однородной формой первого порядка.

В данной главе нас также будет интересовать явный вид ОИСКО, оптимальное значение параметра сглаживания, а также само значение минимума ОИСКО для автоматических оценок. Найдем эти характеристики.

Из формулы (1.15) следует, что общее выражение для ОИСКО автоматической оценки плотности имеет вид:

$$\mathrm{RMISE}(\hat{\sigma}, f, \hat{f}) = \frac{\mathbb{E}\left[\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 - 2\,\mathrm{Re}\,(\overline{E_{f_0}(z)} e^{iY_k z} E_K(\xi\hat{\sigma}z)) + \frac{1}{n}|E_K(\xi\hat{\sigma}z)|^2 + \frac{n-1}{n} e^{i(Y_l - Y_m)z} |E_K(\xi\hat{\sigma}z)|^2 dz\right]}{\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 dz}. \tag{2.8}$$

Здесь k, l, m обозначают произвольные целые числа от 1 до n, причем $l \neq m$.

Из-за того что в каждое слагаемое входят все элементы выборки получение явной формы ОИСКО встречает определенные трудности. Вычисления необходимо выполнять отдельно для каждой плотности f и ядра K конкретного фиксированного вида.

2.1.1 Ортогональные преобразования

Основные трудности при преобразовании выражения (2.8) состоят в сложности выражения для $\hat{\sigma}_Y^2$ (далее будем писать просто $\hat{\sigma}^2$, опуская индекс при $\hat{\sigma}$):

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{j=1}^{n}(Y_j - \bar{Y})^2 = \frac{1}{n}\sum_{j=1}^{n} Y_j^2 - (\frac{1}{n}\sum_{j=1}^{n} Y_j)^2.$$

Для того чтобы упростить это выражение в работах [1, 32] было предложено линейное, ортогональное преобразование $\tilde{\mathbf{y}} = \mathbf{H}\mathbf{y}$, которое переводит выражение для выборочной дисперсии к виду суммы $(n-1)$ квадрата:

$$\hat{\sigma}_Y^2(\tilde{Y}_1, \ldots, \tilde{Y}_n) = \frac{1}{n}\sum_{j=1}^{n-1} \tilde{Y}_j^2.$$

Матрица этого преобразования

$$\mathbf{H} = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & \cdots & 0 & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \frac{1}{\sqrt{(n-1)(n-2)}} & \frac{1}{\sqrt{(n-1)(n-2)}} & \cdots & \frac{2-n}{\sqrt{(n-1)(n-2)}} & 0 \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \cdots & \frac{1}{\sqrt{n(n-1)}} & \frac{1-n}{\sqrt{n(n-1)}} \\ \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} \end{pmatrix}$$

была впервые получена в работе [32] методом Грама-Шмидта (в работе [1] та же матрица использовалась неявно).

Далее в разделе, посвященном получению ОИСКО для выборок с зависимыми элементами, будет проделано сразу несколько различных ортогональных преобразований. Каждый раз мы будем пользоваться целым рядом их полезных свойств. Перечислим эти свойства.

1. Якобиан ортогонального преобразования по модулю равен единице.

2. При ортогональной замене n переменных, интеграл по $\mathbb{R}^n$ вновь переходит в интеграл по $\mathbb{R}^n$.

3. При ортогональной замене n переменных, сумма квадратов n переменных остается неизменной.

Для выборок из нормального распределения и ортогональных преобразований также будет справедливы следующие утверждения (см. [34]).

1. При ортогональных преобразованиях система независимых нормальных случайных величин всегда переходит в систему независимых нормальных случайных величин.
2. Для любой системы из n зависимых нормальных случайных величин всегда существует ортогональное преобразование переводящие их в систему n независимых нормальных случайных величин.

В данной работе такое преобразование часто будет полезно и необходимо. Рассмотрим его подробнее. Пусть далее $\mathbf{y} = (Y_1, \ldots, Y_n)$ — выборка из центрированного, нормированного нормального распределения.

Рассмотрим разложение корреляционной матрицы $\mathbf{\Sigma}_Y = \mathbb{E}[\mathbf{y}\mathbf{y}^T]$ по собственным числам и векторам, позволяющее привести эту матрицу к диагональному виду

$$\mathbf{\Sigma}_Y = \mathbf{R}\mathbf{\Lambda}\mathbf{R}^T,$$

где $\mathbf{\Lambda} = \mathrm{diag}(\lambda_1, \ldots, \lambda_n)$ — диагональная матрица, а матрица $\mathbf{R}$ составлена из собственных векторов $\mathbf{\Sigma}_Y$.

Отметим, что корреляционная матрица для вещественных случайных величин всегда симметрична и неотрицательно определена:

$$\mathbf{\Sigma}_Y = \mathbf{\Sigma}_Y^T,$$

$$\mathbf{x}^T\mathbf{\Sigma}_Y\mathbf{x} \geq 0 \ \text{ для всех ненулевых } \mathbf{x} \in \mathbb{R}^n.$$

Хорошо известно, что такая матрица может быть приведена к диагональному виду ортогональным преобразованием (подробнее в работах [18, 53]). Таким образом, матрицу $\mathbf{R}$ далее везде можно будет считать ортогональной.

Перейдем к новой выборке $\mathbf{z} = \mathbf{R}^T\mathbf{y}$. Корреляционная матрица для нее будет диагональной:

$$\mathbf{\Sigma}_Z = \mathbf{R}^T\mathbf{\Sigma}_Y\mathbf{R} = \mathbf{\Lambda}.$$

Как известно (см., например, [16]) для нормальных случайных величин $Y_1, \ldots, Y_n$ это равносильно их независимости.

Замечание. Такой переход может быть проделан и другими способами. Во-первых, с помощью разложения Холецкого. Также существует способ с извлечением корня из обратной матрицы [48].

2.2 Случай нормальной выборки и ядра Гаусса

Автоматические оценки для независимых выборок рассматривались в работах [1, 32]. Основным теоретическим результатом работы [32] является теорема о явном виде ОИСКО автоматической оценки с ядром Гаусса для случая выборки из нормального распределения.

В данной работе предлагается упрощенное доказательство этой теоремы, опирающееся на вспомогательную лемму.

Лемма 2.2. *(О многомерном гауссовском интеграле). Пусть* $\mathbf{A} \in \mathbb{R}^{n\times n}$ *— положительно-определенная симметричная вещественная матрица,* $\mathbf{b} \in \mathbb{C}^n$ *— произвольный комплексный вектор. Тогда*

$$\int\limits_{\mathbb{R}^n} e^{-\frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x}+\mathbf{b}^T\mathbf{x}} d\mathbf{X} = \frac{(2\pi)^{\frac{n}{2}}}{\sqrt{\det \mathbf{A}}}\, e^{\frac{1}{2}\mathbf{b}^T\mathbf{A}^{-1}\mathbf{b}}.$$

Доказательство.

$$\int\limits_{\mathbb{R}^n} e^{-\frac{1}{2}(\mathbf{x}^T\mathbf{A}\mathbf{x}-2\mathbf{b}^T\mathbf{x})} d\mathbf{X} = \int\limits_{\mathbb{R}^n} e^{-\frac{1}{2}((\mathbf{x}-\mathbf{A}^{-1}\mathbf{b})^T\mathbf{A}(\mathbf{x}-\mathbf{A}^{-1}\mathbf{b})-\mathbf{b}^T\mathbf{A}^{-1}\mathbf{b})} d\mathbf{X} = e^{\frac{1}{2}\mathbf{b}^T\mathbf{A}^{-1}\mathbf{b}} \int\limits_{\mathbb{R}^n} e^{-\frac{1}{2}\mathbf{y}^T\mathbf{A}\mathbf{y}} d\mathbf{y}.$$

Полученный интеграл совпадает с интегралом от плотности многомерного нормального распределения с точностью до нормировки. Данная лемма помогает существенно упростить доказательство теоремы, предложенное ранее в [32].

Теорема 2.1. *Для выборки* $X_1, \ldots, X_n$ *из нормального распределения, ядра Гаусса* $K(y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$ *и статистики* $\hat{\sigma}$ *вида* (2.4) *ОИСКО автоматической ядерной оценки выражается в виде:*

$$\begin{aligned}\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi) =& 1 + \frac{1}{\xi\sqrt{2n}} \frac{\Gamma\left(\frac{n-2}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)} - \frac{2\sqrt{n}}{\sqrt{\pi}\xi} \int\limits_0^1 e^{-\frac{(n+1)x}{2\xi^2(1-x)}} (1-x)^{\frac{n-4}{2}} x^{-\frac{1}{2}} e^{-\frac{(n-1)x}{2\xi^2}} dx \\ &+ \frac{n-1}{\xi\sqrt{2\pi n}} \int\limits_0^1 (1-x)^{\frac{n-4}{2}} x^{-\frac{1}{2}} e^{-\frac{nx}{2\xi^2}}\, dx.\end{aligned} \tag{2.9}$$

Доказательство.

Легко видеть, что после подстановки выражения для ядра Гаусса ОИСКО разбивается на три слагаемых:

$$\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi) = 1 + \frac{1}{\sqrt{\pi}}\Big(\frac{1}{n} I_1 - 2I_2 + \frac{n-1}{n} I_3\Big), \text{ где} \tag{2.10}$$

$$I_1 = \int\limits_{-\infty}^{+\infty} \mathbb{E}\,[e^{-\xi^2 \hat{\sigma_Y}^2 z^2}] dz,$$

$$I_2 = \int\limits_{-\infty}^{+\infty} e^{-\frac{z^2}{2}}\, \mathbb{E}\,[e^{iY_n z} e^{-\frac{\xi^2 \hat{\sigma_Y}^2 z^2}{2}}] dz,$$

$$I_3 = \int\limits_{-\infty}^{+\infty} \mathbb{E}\,[e^{iz(Y_1-Y_2)} e^{-\xi^2 \hat{\sigma_Y}^2 z^2}] dz,$$

причем $Y_1, \ldots, Y_n$ — независимые одинаково распределённые стандартные гауссовские величины.

Нетрудно убедиться, что каждое из математических ожиданий под интегралом после ортогонального преобразования $\mathbf{H}$ подпадает под условия вспомогательной леммы и легко вычисляется:

$$I_1 = \int\limits_{-\infty}^{+\infty} \mathbb{E}\,[e^{-\xi^2(\frac{1}{n}\sum_{j=1}^{n-1}\tilde{Y}_j^2)z^2}]dz = \int\limits_{-\infty}^{+\infty} \frac{1}{(2\pi)^{\frac{n-1}{2}}} \int\limits_{\mathbb{R}^{n-1}} e^{-\frac{1}{2}(1+\frac{2\xi^2 z^2}{n})\tilde{\mathbf{y}}^T\tilde{\mathbf{y}}} d\tilde{\mathbf{y}}dz = \int\limits_{-\infty}^{+\infty} (1+\frac{2\xi^2 z^2}{n})^{-\frac{n-1}{2}} dz,$$

$$I_2 = \int\limits_{-\infty}^{+\infty} e^{-\frac{z^2}{2}}\, \mathbb{E}\,[e^{iz(\frac{1-n}{\sqrt{n(n-1)}}\tilde{Y}_{n-1}+\frac{1}{\sqrt{n}}\tilde{Y}_n)} e^{-\frac{\xi^2(\frac{1}{n}\sum_{j=1}^{n-1}\tilde{Y}_j^2)z^2}{2}}]dz =$$

$$= \int\limits_{-\infty}^{+\infty} \frac{e^{-\frac{z^2}{2}}}{(2\pi)^{\frac{n}{2}}} \int\limits_{\mathbb{R}^n} e^{-\frac{1}{2}\tilde{\mathbf{y}}^T\mathbf{D}_n\tilde{\mathbf{y}}+iz(\frac{1-n}{\sqrt{n(n-1)}}\tilde{y}_{n-1}+\frac{1}{\sqrt{n}}\tilde{y}_n)} d\tilde{\mathbf{y}}dz = \int\limits_{-\infty}^{+\infty} e^{-\frac{z^2}{2}(1+\frac{1}{n})}(1+\frac{\xi^2 z^2}{n})^{-\frac{n-1}{2}} e^{-\frac{z^2(1-\frac{1}{n})}{2(1+\frac{\xi^2 z^2}{n})}} dz,$$

$$I_3 = \int\limits_{-\infty}^{+\infty} \mathbb{E}\,[e^{iz\sqrt{2}\tilde{Y}_1} e^{-\xi^2(\frac{1}{n}\sum_{j=1}^{n-1}\tilde{Y}_j^2)z^2}]dz = \int\limits_{-\infty}^{+\infty} \frac{1}{(2\pi)^{\frac{n-1}{2}}} \int\limits_{\mathbb{R}^{n-1}} e^{-\frac{1}{2}(1+\frac{2\xi^2 z^2}{n})\tilde{\mathbf{y}}^T\tilde{\mathbf{y}}+iz\sqrt{2}\tilde{y}_1} d\tilde{\mathbf{y}}dz =$$

$$= \int\limits_{-\infty}^{+\infty} (1+\frac{2\xi^2 z^2}{n})^{-\frac{n-1}{2}} e^{-\frac{z^2}{(1+\frac{2\xi^2 z^2}{n})}} dz.$$

Матрица $\mathbf{D}_n$ в интеграле I_2 является диагональной, $\mathbf{D}_n = \mathrm{diag}(1+\frac{\xi^2 z^2}{n}, \ldots, 1+\frac{\xi^2 z^2}{n}, 1)$.

Первый интеграл можно вычислить, используя плотность распределения Стьюдента:

$$I_1 = \int\limits_{-\infty}^{+\infty} (1+\frac{2\xi^2 z^2}{n})^{-\frac{n-1}{2}} dz = \sqrt{\frac{n\pi}{2\xi^2}} \frac{\Gamma(\frac{n-2}{2})}{\Gamma(\frac{n-1}{2})}.$$

Каждая из подынтегральных функций в I_2, I_3 обладает свойством четности, следовательно можно перейти к интегрированию по полуоси $[0, +\infty)$. После замены переменной $x = \frac{az^2}{1+az^2}$, где $a = \frac{\xi^2}{n}$ для I_2 и $a = \frac{2\xi^2}{n}$ для I_3, приходим к:

$$I_2 = \sqrt{\frac{n}{\xi^2}} \int\limits_0^1 e^{-\frac{(n+1)x}{2\xi^2(1-x)}} (1-x)^{\frac{n-4}{2}} x^{-\frac{1}{2}} e^{-\frac{(n-1)x}{2\xi^2}} dx,$$

$$I_3 = \sqrt{\frac{n}{2\xi^2}} \int\limits_0^1 (1-x)^{\frac{n-4}{2}} x^{-\frac{1}{2}} e^{-\frac{nx}{2\xi^2}} dx.$$

После подстановки полученных результатов для I_1, I_2, I_3 в (2.10) получаем требуемый результат.

Замечание 1. Для $n = 1$ автоматическая оценка с выборочным среднеквадратическим отклонением $\hat{\sigma}$ в качестве статистики не определена, а при $n = 2$ математическое ожидание от нормы $\|f - \hat{f}\|^2$ не существует. Аналогичными свойствами обладает оценка максимального правдоподобия третьего типа, где так же, как и здесь, используется $\hat{\sigma}$ в качестве оценки неизвестного параметра.

Замечание 2. В работе [1] для автоматической оценки использовалась несколько иная статистика

$$\hat{\sigma}_0 = \sqrt{\frac{1}{n-1}\sum_{j=1}^{n}(X_j - \bar{X})^2}.$$

Нетрудно показать, что в этом случае преобразование **H** также упрощает выкладки и ход преобразований не меняется, при этом $\mathrm{RMISE}(\hat{\sigma}_0, f, K, n, \xi) = \mathrm{RMISE}(\hat{\sigma}, f, K, n, \sqrt{\frac{n}{n-1}}\xi)$, то есть величина минимума ОИСКО не меняется, только сдвигается абсцисса минимума.

Замечание 3. Для нормального закона и ядра Гаусса асимптотическое правило (1.10) имеет следующий вид

$$h^*_{AMISE} = \left(\frac{\frac{1}{2\sqrt{\pi}}}{n(\frac{3}{8\sqrt{\pi}\sigma^5})}\right)^{\frac{1}{5}} = \sigma\left(\frac{4}{3n}\right)^{\frac{1}{5}} \approx \hat{\sigma}\left(\frac{4}{3n}\right)^{\frac{1}{5}}.$$

Здесь $\hat{\sigma}$ — оценка параметра σ. Построенная оценка по определению является автоматической со следующей величиной безразмерного параметра

$$\xi_{AMISE} = \frac{h^*_{AMISE}}{\hat{\sigma}}.$$

При этом, разумеется, $\mathrm{RMISE}(f, K, h^*_{AMISE}) = \mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi_{AMISE})$.

2.3 Численные результаты

Используя полученное выражение, построим график зависимости ОИСКО автоматической оценки от параметра ξ, а также вычислим оптимальные параметры и минимумы.

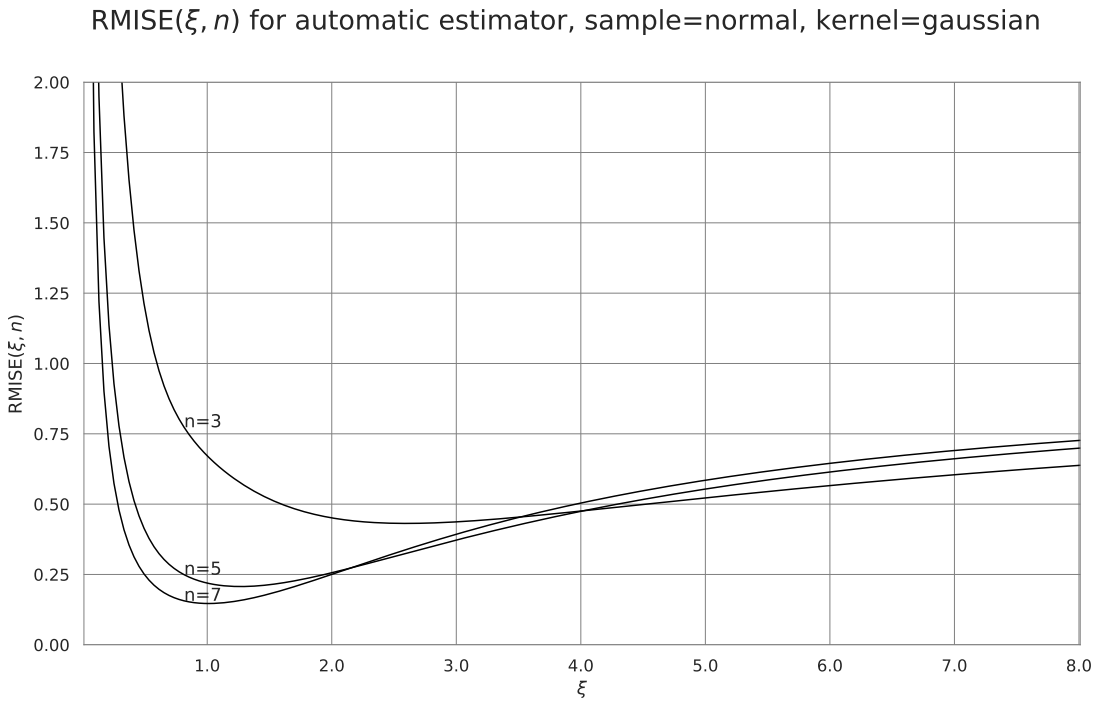

Рис. 2.1: ОИСКО автоматической оценки с ядром Гаусса для выборки из нормального распределения при разных n.

Таблица значений минимумов приведена в приложении. Данные таблицы свидетельствуют о том, что свойство убывания минимумов с ростом n сохраняет силу. При этом, чем больше n, тем быстрее график приближается к горизонтальной асимптоте — это новое свойство, характерное именно для автоматической оценки. Кривые $\mathrm{RMISE}(\xi, n)$ для разных n теперь не располагаются строго одна ниже другой, а имеют точки пересечения.

Отметим, что полученные в предыдущей главе оптимальные параметры неавтоматической оценки ξ_1 можно использовать для построения ядерной оценки по правилу $h = \xi_1\hat{\sigma}$ в том случае, когда точное значение параметра σ неизвестно (ОИСКО такой оценки совпадает с ОИСКО автоматической оценки). С построенной оценкой нетрудно провести сравнение. В таблице полученные минимумы также сравниваются с величиной ОИСКО, соответствующей правилу h^*_{AMISE}.

Полученные результаты полностью соответствуют изложенным выше теоретическим соображениям и согласуются с соображениями здравого смысла. В частности, расчеты подтверждают выполнение неравенств:

$$\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi^*) < \mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi_1) < \mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi_{AMISE}).$$

При этом, чем больше n, тем меньше будут отличаться значения параметров $\xi^*, \xi_1, \xi_{AMISE}$ и значения ОИСКО автоматической оценки, полученные с использованием трех указанных параметров. В частном случае, когда сравниваются оценки с одним и тем же выражением ОИСКО автоматической оценки, но разными значениями ξ, введем *эффективность*:

$$\delta(\xi) = \frac{\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi) - \mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi^*)}{\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi^*)}.$$

Дальнейшие выводы зависят от ограничений, накладываемых на δ.

Пример. Пусть разница $\delta_{fixed} = 0.05$ считается малой и оценки с параметром ξ можно использовать вместо точной автоматической оценки при $\delta(\xi) < \delta_{fixed}$.

Тогда в случае гауссовского ядра, для $n > 7$ можно пользоваться параметром неавтоматической оценки, а при $n > 17$ допустимо использовать асимптотическое правило выбора параметра h^*_{AMISE} (см. таблицы в приложении).

Глава 3

Классические оценки плотности вероятности для выборок с независимыми элементами

В следующих двух разделах мы обсудим два альтернативных типа оценок плотности, а именно оценки максимального правдоподобия и гистограмму. Приводимые ниже результаты известны из работы [1] и нас интересуют только в контексте сравнения с ядерными оценками, ранее построенными в настоящей диссертации.

3.1 Метод максимального правдоподобия

Метод максимального правдоподобия является одним из самых употребительных и универсальных методов построения оценок. Рассмотрим выборку $\mathbf{x} = (X_1, \ldots, X_n)$ из некоторого распределения с плотностью $f(x, \theta)$, где $\theta \in \Theta$ — некоторый параметр. По определению (см. [16]), функцией максимального правдоподобия называется совместная плотность вероятности элементов выборки

$$L(\mathbf{x}, \theta) = \prod_{j=1}^{n} f(X_j, \theta).$$

Оценкой максимального правдоподобия параметра θ или сокращенно ОМП, назовем

$$\theta_{ML} = \arg\max_{\theta \in \Theta} L(\mathbf{x}, \theta).$$

Таким образом, при построении ОМП мы считаем заданным тип распределения. В случае, когда у распределения есть несколько параметров, при построении ОМП некоторые из них можно считать известными. В случае нормального распределения возникают следующие типы ОМП.

1.Оценка математического ожидания при известной дисперсии.

2.Оценка дисперсии при известном математическом ожидании.

3.Одновременная оценка математического ожидания и дисперсии.

В работе [1] были получены аналитические выражения ОИСКО для всех трех упомянутых типов ОМП для плотности по выборке из нормального распределения.

3.1.1 Оценка плотности при известной дисперсии

В первом случае известна дисперсия, неизвестно математическое ожидание. В качестве оценки параметра μ мы используем его ОМП:

$$\hat{\mu} = \frac{1}{n}\sum_{j=1}^{n} X_j.$$

Это дает следующую оценку плотности

$$\hat{f}_{ML}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\hat{\mu})^2}{2\sigma^2}}.$$

Можно показать, что при этом

$$\mathrm{RMISE}(f, \hat{f}_{ML}) = 2\,\mathbb{E}\left[1 - e^{-\frac{Y^2}{4}}\right],$$

где $Y \sim N(0, \frac{1}{\sqrt{n}})$. После вычисления математического ожидания находим:

$$\mathrm{RMISE}(f, \hat{f}_{ML}) = \frac{1}{n + \frac{1}{2} + \sqrt{n(n+\frac{1}{2})}}. \tag{3.1}$$

3.1.2 Оценка плотности при известном математическом ожидании

Во втором случае известно математическое ожидание, дисперсия неизвестна. В качестве оценки параметра σ мы используем его ОМП, при известном μ:

$$\hat{\sigma} = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(X_j - \mu)^2},$$

так что оценка плотности приобретает вид

$$\hat{f}_{ML}(x) = \frac{1}{\sqrt{2\pi}\hat{\sigma}} e^{-\frac{(x-\mu)^2}{2\hat{\sigma}^2}}.$$

Можно показать, что

$$\mathrm{RMISE}(f, \hat{f}_{ML}) = \mathbb{E}\left[1 + \sqrt{\frac{n}{Z}} - \frac{2\sqrt{2n}}{\sqrt{Z+n}}\right],$$

где $Z \sim \chi^2_n$, то есть распределено по закону хи-квадрат с n степенями свободы. После вычисления математического ожидания находим:

$$\mathrm{RMISE}(f, \hat{f}_{ML}) = 1 + \sqrt{\frac{n}{2}}\frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} - \sqrt{\frac{n}{2^{n-3}\pi}}\int_0^{+\infty}\frac{e^{-nx}}{\sqrt{x}(x+\frac{1}{2})^{\frac{n}{2}}}dx. \tag{3.2}$$

3.1.3 Оценка плотности при двух неизвестных параметрах

В третьем случае, математическое ожидание и дисперсия неизвестны и в качестве оценок параметров μ, σ мы используем их ОМП:

$$\hat{\mu} = \frac{1}{n}\sum_{j=1}^{n} X_j,\ \hat{\sigma} = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(X_j - \hat{\mu})^2}.$$

При этом получаем следующую оценку плотности:

$$\hat{f}_{ML}(x) = \frac{1}{\sqrt{2\pi}\hat{\sigma}} e^{-\frac{(x-\hat{\mu})^2}{2\hat{\sigma}^2}}.$$

Можно показать, что

$$\mathrm{RMISE}(f, \hat{f}_{ML}) = \mathbb{E}\left[1 + \sqrt{\frac{n}{Z_0}} - \frac{2\sqrt{2n}}{\sqrt{Z_0 + n}} e^{-\frac{nY^2}{2(Z_0+n)}}\right],$$

где $Y \sim N(0, \frac{1}{\sqrt{n}})$, $Z_0 \sim \chi^2_{n-1}$ и при этом обе они независимы. После вычисления математического ожидания получаем:

$$\mathrm{RMISE}(f, \hat{f}_{ML}) = 1 + \sqrt{\frac{n}{2}}\frac{\Gamma(\frac{n-2}{2})}{\Gamma(\frac{n-1}{2})} - \sqrt{\frac{n}{2^{n-4}\pi}} \int\limits_0^{+\infty} \frac{e^{-(n+1)x}}{\sqrt{x}(x+\frac{1}{2})^{\frac{n-1}{2}}} dx. \tag{3.3}$$

3.2 Гистограммы

При построении классической гистограммы мы разбиваем числовую ось на равные интервалы — *столбцы* или *разряды*. Зафиксируем на числовой прямой некоторую начальную точку x_0, ширину столбца гистограммы обозначим через h. Границы столбца гистограммы обозначим $x_i^* = x_0 + jh, (j = 0, \pm 1, \pm 2, ...)$.

Пусть имеется выборка размера n, через n_i обозначим количество элементов, попавших в столбец с границами (x_i^*, x_{i+1}^*). Тогда по определению оценка плотности вероятности в виде гистограммы будет иметь вид:

$$\hat{f}_H(x) = \begin{cases} \frac{n_i}{nh}, & \text{если } x_i^* < x < x_{i+1}^*, \\ \frac{n_i + n_{i-1}}{2nh}, & \text{если } x = x_i^*. \end{cases} \tag{3.4}$$

За меру точности оценки $\hat{f}_H$ по-прежнему принимаем ОИСКО, вычисляемое по правилам, описанным в первой главе. Рассмотрим вначале ИСКО гистограммы. Его можно представить в виде [1, 15]

$$\mathrm{MISE}(f, \hat{f}_H) = \mathbb{E}\left[\int\limits_{-\infty}^{+\infty} f^2(x)dx - \frac{2}{nh}\sum_{j=-\infty}^{+\infty} n_i \int\limits_{x_i^*}^{x_{i+1}^*} f(x)dx + \frac{1}{n^2 h}\sum_{j=-\infty}^{+\infty} n_i^2\right].$$

Заметим, что величина n_i распределена биномиально, причем $P\{n_i = k\} = C_n^k p_i^k (1-p_i)^{n-k}$, где p_i — вероятность попасть в i-й столбец гистограммы, очевидно равная

$$p_i = \int\limits_{x_i^*}^{x_{i+1}^*} f(x)dx.$$

Окончательное выражение ОИСКО гистограммы в общем виде таково:

$$\mathrm{RMISE}(f, \hat{f}_H) = 1 + \frac{1}{nh\|f\|^2} - \frac{n+1}{nh\|f\|^2} \sum_{j=-\infty}^{+\infty} \left(\int\limits_{x_i^*}^{x_{i+1}^*} f(x)dx \right)^2.$$

В контексте данного раздела нас будет интересовать ОИСКО гистограммы для выборки из нормального распределения, для того что бы можно было провести сравнение с результатами, полученными для ядерных оценок. Для выборки из нормального распределения в работе [1] был получен следующий результат:

$$\mathrm{RMISE}(f, \hat{f}_H) = 1 + \frac{2\sqrt{\pi}}{n\xi} - \frac{\sqrt{\pi}(n+1)}{2n\xi} \sum_{j=-\infty}^{+\infty} \left(\sqrt{\frac{2}{\pi}} \int\limits_{j\xi}^{(j+1)\xi} e^{-\frac{x^2}{2}} dx \right)^2 =$$

$$= 1 + \frac{2\sqrt{\pi}}{n\xi} - \frac{\sqrt{\pi}(n+1)}{2n\xi} \sum_{j=-\infty}^{+\infty} \left(\mathrm{erf}\left(\frac{(j+1)\xi}{\sqrt{2}} \right) - \mathrm{erf}\left(\frac{j\xi}{\sqrt{2}} \right) \right)^2. \tag{3.5}$$

3.2.1 Численные результаты

График для ОИСКО гистограммы приведен на рисунке 3.1, соответствующая таблица помещена в приложении. Графики и таблица значений минимумов свидетельствуют, что ординаты минимумов убывают с ростом n.

Кривые для разных n располагаются строго одна под другой. Нетрудно чисто аналитически показать, что для ОИСКО гистограммы выполнено строгое неравенство:

$$\mathrm{RMISE}(f, \hat{f}_H, n_2) - \mathrm{RMISE}(f, \hat{f}_H, n_1) > 0 \text{ при } n_2 < n_1.$$

И этот вывод полностью подтверждается расчетами.

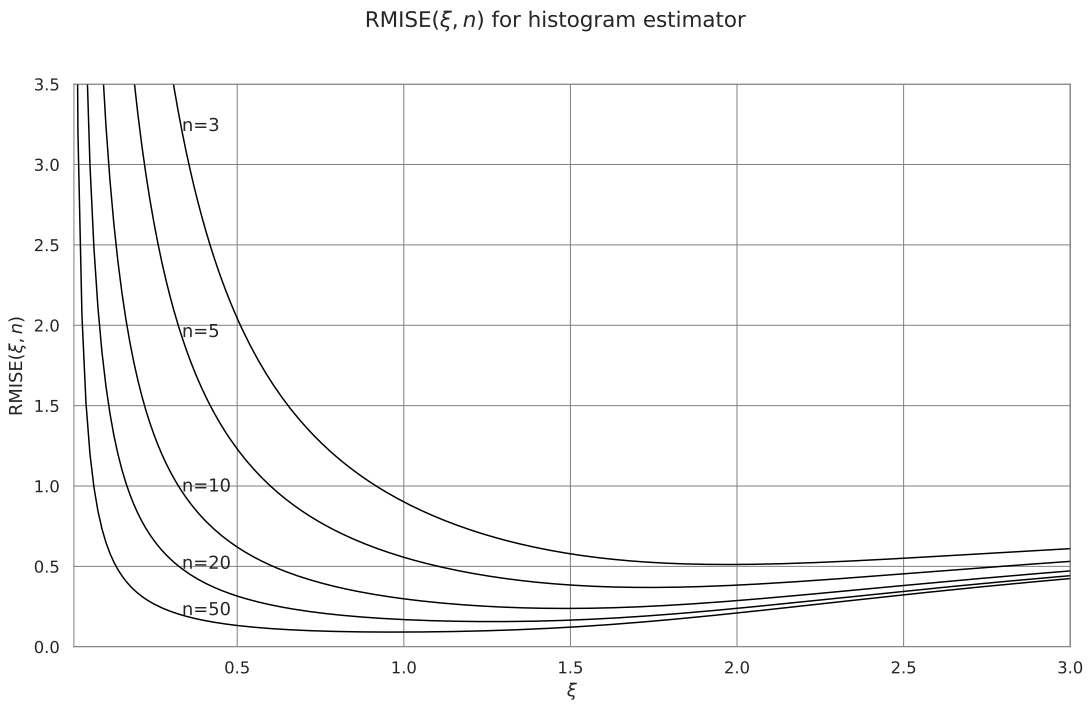

Рис. 3.1: ОИСКО гистограммы для выборки из нормального распределения при разных n.

Значения минимумов ОИСКО для ОМП каждого типа даны в приложении.

3.3 Эффект малой выборки

Эффект малой выборки в данной работе рассматривается с нескольких сторон. Во-первых, в работе изучается расхождение асимптотических результатов с точными при малых значениях объема выборки n. Во-вторых, для ряда оценок была выявлена следующая закономерность: в некоторых случаях существует такое значение n_0 объема оцениваемой выборки, при котором непараметрические ядерные оценки показывают более высокую точность по сравнению с параметрическими при всех $n \leq n_0$.

При сравнении оценок нужно понимать, какие предположения о выборке используются. Для независимой выборки из нормального распределения наименьшую среднеквадратическую ошибку имеют те, которые строятся для известного параметра масштаба σ (неавтоматическая оценка, ОМП первого типа). Следующими по точности оказываются оценки с известным μ (ОМП второго типа). Наибольшую ошибку демонстрируют оценки, не использующие никаких дополнительных знаний о параметрах распределения (автоматическая оценка, ОМП третьего типа, гистограмма). Таким образом, чем больше априорной информации о выборке известно, тем точнее можно оценивать характеристики ее распределения.

Внутри каждого из указанных классов имеет смысл сравнение соответствующих ядерных оценок с альтернативными. Эффект малой выборки будет заключаться в превосход-

стве ядерных оценок до определенного n. Для автоматических оценок данный эффект будет наиболее выражен. Примечательно, что начиная с некоторого объема параметрические оценки из «менее информированных» классов превосходят непараметрические из «более информированных». Так ОМП третьего типа уже при $n \geq 20$ начинает выигрывать в точности даже у неавтоматических ядерных оценок, для которых параметр σ известен.

Глава 4

Ядерная оценка для выборок с зависимыми элементами

4.1 Исходные предположения. Понятие случайного процесса

В предыдущих главах была изложена общая теория ядерного оценивания при классических предположениях математической статистики относительно выборки $X_1, ..., X_n$. Ее элементы считались *независимыми* и *одинаково распределенными* случайными величинами. Между тем, на практике достаточно часто встречается ситуация, когда одно из этих предположений или даже оба сразу нарушаются. Особенно обременительным является требование независимости элементов выборки. Оно сразу же делает невозможным изучение важного класса задач, которые возникают в теории случайных процессов. Ввиду важности этого вопроса остановимся на нем подробнее.

Случайный процесс представляет собой важнейшую разновидность случайной функции. В свою очередь *случайной функцией* называют такую функцию, значения которой при любом значении аргумента обладают свойствами *случайной величины*. Обозначим аргумент случайной функции через t, а ее область определения через T. Если t является скалярной величиной и имеет смысл времени, то такую случайную функцию называют *случайным процессом*.

Областью определения случайного процесса $X(t)$ может служить вещественная ось $\mathbb{R}$ или какой-либо ее отрезок. Областью значений $X(t)$ также считаем множество $\mathbb{R}$ или некоторое его подмножество.

Случайный процесс фактически представляет собой бесконечное параметризованное множество случайных величин, связанных друг с другом. Область определения T является бесконечным множеством. Поэтому можно выбрать любое число n моментов времени $t_1, \ldots, t_n$ и рассмотреть для них систему случайных величин $(X_1, ..., X_n)$, представляющих ординаты процесса $X(t_j) = X_j,\ j = 1, \ldots, n$ для выбранных моментов времени. Совместный закон распределения $f_n(x_1, \ldots, x_n; t_1, \ldots, t_n)$ этой системы называется *законом распределения n-го порядка* для процесса X. Чтобы полностью задать случайный процесс,

нужно задать всю иерархию его законов распределения при произвольном $n \geq 1$ (см. [27]).

Для нашего диссертационного исследования интерес представляют гауссовские процессы, у которых все многомерные законы распределения являются *нормальными*. Важность этого класса процессов для приложений объясняется действием центральных предельных теорем: случайные процессы в природе и технике зависят от большого числа случайных факторов, которые, складываясь, дают в итоге нормальный закон, наблюдаемый в эксперименте.

В этой главе мы отказываемся от требования независимости элементов выборки, но сохраняем требование их *одинакового распределения*. Это можно сделать, если считать процесс $X(t)$ стационарным. Случайный процесс называется *стационарным в узком смысле*, если все его вероятностные свойства не изменятся при произвольном изменении начала отсчета времени. Нетрудно показать [27], что для стационарного процесса

$$f_1(x_1; t) = f_1(x_1), \;\; f_2(x_1, x_2; t_1, t_2) = f_2(x_1, x_2; t_2 - t_1),$$

то есть одномерный закон распределения ординаты одинаков для всех моментов времени, а двумерный закон зависит только от длины интервала между выбранными моментами.

В дальнейшем будем опускать индекс при f и обозначать этой буквой одномерный закон исследуемого процесса $X(t)$. Будем считать этот процесс гауссовским и стационарным. Допустим, что заданы значения $X(t_j) = X_j, \; j = 1, \ldots, n$ для n последовательных моментов времени, которые будем трактовать как выборку с одинаково распределенными по закону $f(x)$, но *зависимыми* элементами. Ядерная оценка плотности f записывается совершенно аналогично (1.1) в виде

$$\hat{f}(x) = \frac{1}{nh} \sum_{j=1}^{n} K\left(\frac{x - X(t_j)}{h}\right). \tag{4.1}$$

Далее, как обычно в нашей работе, построим автоматическую и неавтоматическую оценки, для каждой из них найдем аналитическое выражение ОИСКО, оптимальные параметры сглаживания и соответствующую им нижнюю границу ОИСКО. Прежде чем перейти к реализации этой программы исследований, необходимо пояснить, как моделируется зависимость между элементами выборки.

4.1.1 Корреляционные функции

Корреляционная функция является центральным понятием так называемой корреляционной теории случайных функций [27, 37, 57]. Эта функция определяется как корреляционный момент между двумя ординатами случайной функции $X(t)$, взятыми для двух произвольных моментов времени t_1 и t_2:

$$C(t_1, t_2) = \mathbb{E}\left[(X(t_1) - m_X(t_1))(X(t_2) - m_X(t_2))\right],$$

где $m_X(t) = \mathbb{E}[X(t)]$ обозначает математическое ожидание $X(t)$.

Для стационарного процесса

$$C(t_1, t_2) = C(t_2 - t_1) = C(\tau), (\tau = t_2 - t_1).$$

В корреляционной теории доказываются следующие общие свойства корреляционной функции [27, 37].

1. $C(-\tau) = C(\tau), (-\infty < \tau < \infty)$,
2. $C(0) = \sigma_X^2$,
3. $|C(\tau)| \leq C(0), (-\infty < \tau < \infty)$.

Благодаря выполнению указанных свойств удобно ввести *нормированную корреляционную функцию*

$$C_0(\tau) = \frac{C(\tau)}{C(0)} = \frac{C(\tau)}{\sigma_X^2}.$$

Функция C_0, во-первых, безразмерна, а во-вторых, ограничена по модулю единицей. По своему смыслу она представляет коэффициент корреляции между ординатами процесса, отстоящими по времени на τ.

В общем выражении

$$C(\tau) = \sigma_X^2 C_0(\tau),$$

первый множитель определяет рассеяние ординаты процесса, а второй — характер корреляционной связи между ординатами (скорость затухания корреляций, их знак и т.п.). Следует заметить, что в корреляционной теории существуют достаточно простые и удобные способы оценки характера зависимости C_0 от τ (например, метод релейной корреляционной функции [37]).

Отметим, что корреляционная функция обладает важным свойством *положительной определенности*, согласно которому для любых вещественных a и b, а также любой интегрируемой функции $\eta(t)$ выполняется неравенство

$$\int_a^b \int_a^b C(t_2 - t_1)\eta(t_1)\eta(t_2)dt_1dt_2 \geq 0, \tag{4.2}$$

причем знак равенства здесь достигается только когда $\eta(t)$ почти везде в $[a, b]$ равняется нулю. Это свойство следует из теоремы Бохнера, доказываемой в теории интеграла Фурье [27, 31].

Данное свойство не так просто проверить для произвольной функции, поэтому получим более удобное равносильное условие. Пусть $a = -\infty$, $b = \infty$, тогда левую часть неравенства (4.2) с помощью обобщенного тождества Парсеваля и теоремы о свертке (см. [31]) можно преобразовать следующим образом

$$\int_{-\infty}^{+\infty} \eta(t_2) \int_{-\infty}^{+\infty} C(t_2 - t_1)\eta(t_1)dt_1dt_2 = \langle \eta, C * \eta \rangle = \frac{1}{2\pi}\langle E_\eta^2, E_C \rangle,$$

где $\langle f, g\rangle = \int\limits_{-\infty}^{+\infty} f(x)g(x)dx$ — скалярное произведение в $L_2(\mathbb{R})$, а E_f задано формулой (1.13). Таким образом, в силу *произвольности* функции $\eta(t)$ неотрицательность преобразования Фурье от корреляционной функции:

$$E_C(z) \geq 0, (-\infty < z < \infty)$$

является необходимым условием ее положительной определенности. Оказывается, что оно является и достаточным. Этот факт доказывается в работе [39].

Далее рассмотрим несколько примеров корреляционных функций.

Таблица 4.1: Примеры нормированных корреляционных функций.

$C_0(\tau)$	Обозначение на графиках и в коде программ
$e^{-\alpha\|\tau\|}$	EXPABS, корреляционная функция процесса Орнштейна-Уленбека
$e^{-\alpha\tau^2}$	EXP
$\frac{1}{1+\alpha\tau^2}$	CAUCHY

Все приведенные в таблице 4.1 варианты $C_0(\tau)$ хорошо известны (например, EXPABS является корреляционной функцией для процесса Орнштейна-Уленбека) и соответствуют положительно определенным функциям. При этом параметр α во всех случаях отвечает за скорость затухания корреляционной зависимости между ординатами случайной функции.

В прикладных исследованиях часто вводят радиус корреляции τ_{corr}, как то время, в течении которого корреляционная зависимость затухает в заданное число раз. Согласно стандартному определению радиуса корреляции [7, 25, 33]

$$\tau_{corr} = \frac{1}{C(0)} \int\limits_{0}^{+\infty} C(\tau)d\tau.$$

Легко видеть, что для всех примеров τ_{corr} оказывается обратно пропорциональным α. В пределе при $\alpha \to \infty$ приходим к случаю независимой выборки, разобранному в первых трех главах. Отметим, что по В.С.Пугачеву [24] для стационарного случайного процесса выполнено свойство эргодичности, если корреляционная функция неограниченно убывает по модулю при больших τ:

$$\lim_{|\tau|\to\infty} |C(\tau)| \to 0,$$

следовательно все процессы с $\tau_{corr} < \infty$ можно считать эргодическими.

Итак, ОИСКО в нашей модели зависимой выборки будет зависеть кроме обычных для ядерного оценивания параметров также и от параметра α, задающего соответствующую модель $C_0(\tau)$.

4.1.2 Модели корреляционной зависимости

Далее введем несколько моделей корреляционной зависимости. Рассмотрим выборку $\mathbf{x} = (X(t_1), ..., X(t_n))$ из генеральной совокупности значений случайного гауссовского стационарного процесса с корреляционной функцией $C(\tau)$.

1. **Модель равных временных интервалов.**

Примем, что регистрация процесса происходит в равноотстоящие моменты времени с постоянным шагом τ: $t_j = \tau(j-1),\ j = 1, \ldots, n$, тогда корреляционная матрица для такой выборки будет выглядеть так:

$$\mathbf{\Sigma}_X = \begin{pmatrix} C(0) & C(\tau) & \ldots & C((n-1)\tau) \\ C(\tau) & C(0) & \ddots & \vdots \\ \vdots & \ddots & \ddots & C(\tau) \\ C((n-1)\tau) & \ldots & C(\tau) & C(0) \end{pmatrix}. \tag{4.3}$$

Матрица такой формы называется *теплицевой*. Корреляционные матрицы указанного вида будут далее использоваться для вычислений.

2. **Модель быстро затухающей корреляции.**

В рамках модели равных временных интервалов предположим, что можно пренебречь корреляционной зависимостью за пределами одного временного интервала τ:

$$C_0(j\tau) = \begin{cases} 1, & j = 0 \\ a, & j = 1 \\ 0, & j > 1. \end{cases} \tag{4.4}$$

Легко понять, что в такой модели корреляционная матрица будет *трехдиагональной*:

$$\mathbf{\Sigma} = \begin{pmatrix} 1 & a & \ldots & 0 \\ a & 1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & a \\ 0 & \ldots & a & 1 \end{pmatrix}. \tag{4.5}$$

Отметим, что модель случайного процесса с такой матрицей является наиболее простой моделью зависимой выборки и на ее примере удобно проверять предположения о свойствах получаемых результатов в моделях более общего вида.

Важным является вопрос о том, при каких значениях a матрица (4.5) является корреляционной. Для выполнения свойства положительной определенности *достаточным* условием является *диагональное преобладание*:

$$|a| < \frac{1}{2}. \tag{4.6}$$

Действительно, возьмем произвольный ненулевой вектор $\mathbf{x} \in \mathbb{R}^n$. Рассмотрим квадратичную форму с матрицей (4.5):

$$\mathbf{x}^T \mathbf{\Sigma} \mathbf{x} = \frac{x_1^2 + x_n^2}{2} + \sum_{j=1}^{n-1} \left(\frac{x_j^2}{2} + \frac{x_{j+1}^2}{2} + 2a x_j x_{j+1} \right).$$

При $x_j^2 + x_{j+1}^2 \neq 0$ соответствующее слагаемое в скобках будет положительно как раз при выполнении условия (4.6). Более точные допустимые границы для параметра a будут получены в разделе, посвященном детальному изучению свойств трехдиагональных матриц.

4.1.3 Общее выражение ОИСКО неавтоматической оценки для зависимой выборки

Займемся получением аналитического представления ОИСКО. Нетрудно видеть, что в изложенной выше постановке продолжает действовать лемма о безразмерном параметре, аналогичная леммам 1.1 и 2.1. Ввиду полной аналогии для сокращения места соответствующее доказательство опускается. Первые отличия в ходе рассуждений начнутся лишь с этапа, где происходит переход к характеристическим функциям. Поэтому с этого момента и приводится подробный вывод.

Лемма 4.1. *Выражение для ИСКО неавтоматической оценки в случае зависимой выборки в терминах характеристических функций принимает вид*

$$\begin{aligned} \mathrm{MISE}(f, K, n, \xi) = \int_{-\infty}^{+\infty} |E_{f_0}(z)|^2 dz + \frac{1}{n} \int_{-\infty}^{+\infty} |E_K(\xi z)|^2 dz \\ + \frac{1}{n^2} \int_{-\infty}^{+\infty} |E_K(\xi z)|^2 \sum_{k \neq l} \mathbb{E}\left[e^{iz(Y(t_k) - Y(t_l))} \right] dz - 2 \int_{-\infty}^{+\infty} |E_{f_0}(z)|^2 E_K(\xi z) dz. \end{aligned} \tag{4.7}$$

<u>Доказательство.</u>

Пусть, как обычно, $Y(t_1), \ldots, Y(t_n)$ обозначает центрированную нормированную выборку, построенную по исходной выборке $X(t_1), \ldots, X(t_n)$. Тогда, по упомянутой выше лемме, для ОИСКО справедливо выражение:

$$\mathrm{RMISE}(f, K, n, h) = \frac{\mathbb{E}\left[\int_{-\infty}^{+\infty} |E_{f_0}(z) - \frac{1}{n} \sum_{j=1}^{n} e^{iY(t_j)z} E_K(\xi z)|^2 dz \right]}{\int_{-\infty}^{+\infty} |E_{f_0}(z)|^2 dz}.$$

Раскроем здесь полный квадрат в числителе и внесем оператор математического ожидания под знак интеграла. Тогда числитель преобразуется к виду (здесь и далее сумма вида

$\sum\limits_{k=1}^{n}\sum\limits_{l=1,l\neq k}^{n}$ будет обозначаться как $\sum\limits_{k\neq l}$):

$$\mathrm{MISE}(f,K,n,h)=\int\limits_{-\infty}^{+\infty}|E_{f_0}(z)|^2dz+\frac{1}{n}\int\limits_{-\infty}^{+\infty}|E_K(\xi z)|^2dz$$

$$+\frac{1}{n^2}\int\limits_{-\infty}^{+\infty}\mathbb{E}\left[\sum_{k\neq l}e^{iz(Y(t_k)-Y(t_l))}|E_K(\xi z)|^2\right]dz-\frac{2}{n}\int\limits_{-\infty}^{+\infty}\mathbb{E}\left[\mathrm{Re}(\overline{E_{f_0}(z)}E_K(\xi z)\sum_{k=1}^{n}e^{iY(t_k)})\right]dz.$$

Заметим, что

$$\frac{1}{n}\mathbb{E}\left[\mathrm{Re}(\overline{E_{f_0}(z)}E_K(\xi z)\sum_{k=1}^{n}e^{iY(t_k)})\right]=|E_{f_0}(z)|^2E_K(\xi z),$$

из чего сразу следует утверждение леммы.

<u>Замечание.</u> Анализ полученного выражения показывает, что ОИСКО неавтоматической оценки в случае зависимой выборки будет несколько отличаться от выражения для независимой выборки, но только одним слагаемым.

4.2 Неавтоматическая оценка для выборки из нормального распределения

Рассмотрим случай выборки $Y(t_1),\ldots,Y(t_n)$ из центрированного и нормированного нормального распределения с корреляционной матрицей $\mathbf{\Sigma}$. Заметим, что в этом случае разности вида $Y(t_k)-Y(t_l)$ распределены нормально с нулевым математическим ожиданием и дисперсией, определяемой выражением:

$$\mathbb{E}[(Y(t_k)-Y(t_l))^2]=2(1-\mathbb{E}[Y(t_k)Y(t_l)])=2(1-\Sigma_{kl}).$$

После подстановки $f_0(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$ выражение (4.7) примет вид:

$$\mathrm{MISE}(f,K,n,h)=\sqrt{\pi}+\tfrac{1}{n}\int\limits_{-\infty}^{+\infty}|E_K(\xi z)|^2dz+\tfrac{1}{n^2}\int\limits_{-\infty}^{+\infty}|E_K(\xi z)|^2\textstyle\sum_{k\neq l}e^{-z^2(1-\Sigma_{kl})}dz-2\int\limits_{-\infty}^{+\infty}e^{-\frac{z^2}{2}}E_K(\xi z)dz. \quad (4.8)$$

Пусть $K(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$. После подстановки этого выражения числитель ОИСКО для неавтоматической оценки преобразуется к виду:

$$\mathrm{MISE}(f,K,n,h)=\sqrt{\pi}+\frac{\sqrt{\pi}}{n\xi}+\frac{1}{n^2}\int\limits_{-\infty}^{+\infty}e^{-\xi^2z^2}\sum_{k\neq l}e^{-z^2(1-\Sigma_{kl})}dz-2\int\limits_{-\infty}^{+\infty}e^{\frac{-z^2(1+\xi^2)}{2}}dz.$$

Слагаемое с суммой можно фактически вычислить:

$$\sum_{k\neq l}\int\limits_{-\infty}^{+\infty}e^{-(1+\xi^2-\Sigma_{kl})z^2}dz=\sum_{k\neq l}\sqrt{\frac{\pi}{1+\xi^2-\Sigma_{kl}}}.$$

В результате выражение ОИСКО примет вид:

$$\mathrm{RMISE}(f, K, n, \xi) = 1 + \frac{1}{n\xi} + \sum_{k \neq l} \frac{1}{n^2\sqrt{1+\xi^2-\Sigma_{kl}}} - \frac{2\sqrt{2}}{\sqrt{2+\xi^2}}. \tag{4.9}$$

Замечание 1. Рассмотрим модель затухающей корреляционной зависимости (таковы все варианты из примеров). Тогда при любом $\alpha > 0$ имеем

$$\lim_{\alpha\to\infty} C(\tau;\alpha) = 0.$$

Для такой модели при $\alpha \to \infty$ корреляционная матрица стремится к единичной матрице

$$\lim_{\alpha\to\infty} \mathbf{\Sigma} = \mathbf{E}_n,$$

а тогда

$$\lim_{\substack{\alpha\to\infty \\ k\neq l}} \frac{1}{\sqrt{1+\xi^2-\Sigma_{kl}}} = \frac{1}{\sqrt{1+\xi^2}},$$

то есть при $\alpha \to \infty$ все слагаемые двойной суммы в выражении (4.9) становятся одинаковыми. Учитывая, что в сумме $n(n-1)$ слагаемых, получаем в точности выражение (1.19) для ОИСКО неавтоматической оценки по независимой выборке из нормального распределения.

Замечание 2. Для некоторых моделей корреляционной зависимости полученное выражение можно упростить. Заметим, что для модели равных временных интервалов, заданной формулой (4.3) справедливо равенство $\Sigma_{kl} = C_0(j\tau)$ при $j = |k-l|$. Таким образом, двойную сумму в выражении (4.9) можно заменить однократной:

$$\sum_{k\neq l} \frac{1}{n^2\sqrt{1+\xi^2-\Sigma_{kl}}} = \sum_{j=1}^{n-1} \frac{2(n-j)}{n^2\sqrt{1+\xi^2-C_0(j\tau)}}. \tag{4.10}$$

Если пренебречь корреляционной зависимостью за пределами временного интервала τ (модель малой корреляции с корреляционной функцией вида (4.4)), выражение для суммы упростится следующим образом:

$$\sum_{j=1}^{n-1} \frac{2(n-j)}{n^2\sqrt{1+\xi^2-C(j\tau)}} = \frac{2(n-1)}{n^2\sqrt{1+\xi^2-a}} + \frac{n^2-3n+2}{n^2\sqrt{1+\xi^2}}. \tag{4.11}$$

Замечание 3. Выпишем выражение ОИСКО неавтоматической оценки для случая трехдиагональной корреляционной матрицы явно:

$$\mathrm{RMISE}(f, K, n, \xi) = 1 + \frac{1}{n\xi} + \frac{2(n-1)}{n^2\sqrt{1+\xi^2-a}} + \frac{n^2-3n+2}{n^2\sqrt{1+\xi^2}} - \frac{2\sqrt{2}}{\sqrt{2+\xi^2}}. \tag{4.12}$$

Заметим, что оно монотонно зависит от параметра a, при этом если менять параметр в некотором интервале $a \in [-a_n; a_n]$, то минимум выражения (4.12) будет достигаться на

левой границе интервала:

$$\mathrm{RMISE}(f, K, n, \xi, -a_n) \leq \mathrm{RMISE}(f, K, n, \xi, a) \leq \mathrm{RMISE}(f, K, n, \xi, a_n). \tag{4.13}$$

Таким образом, обнаруживаем *эффект отрицательной корреляции*: для зависимой выборки с трехдиагональной корреляционной матрицей и $a < 0$ ядерная оценка оказывается точнее, чем для независимой выборки ($a = 0$):

$$\mathrm{RMISE}(f, K, n, \xi, a) < \mathrm{RMISE}(f, K, n, \xi, 0), \ a < 0. \tag{4.14}$$

Нетрудно видеть, что данный эффект относится и к общему выражению (4.9), например, он будет проявляться для всех корреляционных матриц $\mathbf{\Sigma}$ с отрицательными внедиагональными элементами.

4.2.1 Случай трехдиагональной корреляционной матрицы

Ранее уже было отмечено, что в некоторых случаях корреляционную матрицу в исходной модели можно заменить на *трехдиагональную*. Если разность между ними окажется достаточно малой по некоторой норме, то характеристики матриц будут мало отличаться (см, например, [44]). Таким образом, трехдиагональная матрица соответствует случаю, когда корреляционная функция убывает достаточно быстро, чтобы пренебречь ее значениями на расстоянии, больше одного временного интервала τ.

Кроме того, корреляционная зависимость вида (4.4) может возникать не только в качестве некоторого приближения истинной зависимости, но и в качестве частного случая конкретной точной зависимости. Рассмотрим, например, функцию вида

$$R(\tau) = \begin{cases} 1 - \alpha|\tau|, & \text{если } |\tau| \leq \frac{1}{\alpha} \\ 0, & |\tau| > \frac{1}{\alpha} \end{cases}, \ \alpha > 0.$$

Очевидно, что она ограничена и симметрична, проверим свойство положительной определенности. Хорошо известно [2], что ее преобразование Фурье $E_R(z)$ равно:

$$E_R(z) = \frac{1}{\alpha}\left(\frac{\sin(\frac{z}{\alpha})}{\frac{z}{\alpha}}\right)^2.$$

При этом $E_R(z) \geq 0$, следовательно, $R(\tau)$ положительно определена в смысле (4.2), а значит является корреляционной функцией.

Понятно, что частный случай (4.4) для такой корреляционной зависимости возникает в модели равных временных интервалов (4.3) при $\tau < \frac{1}{\alpha} < 2\tau$. Отметим также, что сама функция $R(\tau)$ встречается в реальных практических задачах [56].

Далее в данном разделе подробно рассмотрим случай теплицевой трехдиагональной корреляционной матрицы, заданной выражением (4.5). Далее приведем известные результаты для некоторых характеристик такой матрицы. Для таких матриц из работ [5, 52]

известны собственные числа в виде:

$$\lambda_k = 1 + 2a\cos\frac{k\pi}{n+1},\ k = 1, \dots, n. \tag{4.15}$$

Этот известный результат нетрудно получить из следующих соображений. Пусть $\chi_n(\lambda, a)$ обозначает характеристический многочлен для трехдиагональной матрицы указанного вида, тогда

$$\chi_n(\lambda, a) = (1-\lambda)\chi_{n-1}(\lambda, a) - a^2\chi_{n-2}(\lambda, a), \tag{4.16}$$

с начальными условиями $\chi_1(\lambda, a) = 1 - \lambda, \chi_2(\lambda, a) = (1-\lambda)^2 - a^2$.

Введем $U_n(x, a) = a^{-n}\chi_n(1 - 2ax, a)$. Рекуррентное соотношение (4.16) тогда переписывается в виде:

$$U_n(x, a) = 2xU_{n-1}(x, a) - U_{n-2}(x, a).$$

Осталось заметить, что начальные условия (а значит и вся последовательность) вообще не зависят от α, поскольку $U_1(x) = 2x, U_2(x) = 4x^2 - 1$. Функции $U_n(x)$ обладают рядом замечательных свойств и называются *полиномами Чебышёва второго рода* [3].

Известно, что корни этих полиномов таковы: $x_k = \cos(\frac{k\pi}{n+1})$. Тогда для собственных чисел исходной матрицы получаем: $\lambda_k = 1 - 2a\cos(\frac{k\pi}{n+1})$, что с точностью до перестановки корней совпадает с приведенным выше выражением (4.15).

Теперь можно получить *точный* допустимый интервал для параметра a. Вспомним, что для того, чтобы матрица оказалась неотрицательно определенной необходима и достаточна неотрицательность всех ее собственных чисел. Учитывая это условие, с помощью выражения (4.15) получаем:

$$a \in [-a_n, a_n],\ a_n = \frac{1}{2\cos(\frac{\pi}{n+1})}. \tag{4.17}$$

Данное условие уже является *необходимым и достаточным* для неотрицательной определенности трехдиагональной матрицы. Ввиду монотонной зависимости от параметра a выражения ОИСКО ядерной оценки (4.12), полученные значения представляют интерес для дальнейших исследований. Отметим также, что данная поправка имеет наибольшее влияние для небольших значений n, а при $n \to \infty$ получаем условие диагонального преобладания (4.6).

Вычисление собственных векторов трехдиагональной матрицы представляет собой более трудную задачу. Отметим, что в работе [42] она решена и вычислены соответствующие собственные векторы $u^{(1)}, \dots, u^{(n)}$, компоненты которых таковы:

$$u_j^{(k)} = \sqrt{\frac{2}{n+1}}\sin\frac{kj\pi}{n+1} = R_{kj},\ j = 1, \dots, n. \tag{4.18}$$

Доказательство этого факта для краткости здесь не приводится.

Замечание 1. Собственные векторы трехдиагональной матрицы не зависят от a.
Пусть $a = 0$, тогда $\mathbf{\Sigma} = \mathbf{E}_n$. По формуле (4.15) тогда все собственные числа станут равны единице. Действительно, $\lambda = 1$ является собственным числом кратности n для матрицы $\mathbf{E}_n$ и поэтому соответствующие собственные векторы не будут уникальны и образуют n-мерное пространство, в котором мы можем выбрать любой ортонормированный базис, например, (4.18). Таким образом, формулы останутся справедливыми при $a = 0$.

Замечание 2. Для трехдиагональной матрицы можно найти обратную матрицу и определитель. Для определителя $D_n(a) = \det \mathbf{\Sigma}$ справедливо рекуррентное соотношение:

$$D_n(a) = D_{n-1}(a) - a^2 D_{n-2}(a).$$

Нетрудно показать, что его решением является $D_n(a) = a^n U(\frac{1}{2a})$. Выражение для обратной матрицы можно найти в работе [47].

4.3 Автоматическая оценка

4.3.1 Общее выражение ОИСКО

Для автоматической оценки общее выражение ОИСКО получается с помощью тех же рассуждений, которые были использованы для неавтоматической оценки в случае зависимой выборки. Легко показать, что ИСКО для автоматической оценки имеет вид:

$$\begin{aligned}
&\mathrm{MISE}(\hat{\sigma}, f, K, n, \xi) = \\
&\int\limits_{-\infty}^{+\infty} |E_{f_0}(z)|^2 dz + \frac{1}{n} \int\limits_{-\infty}^{+\infty} \mathbb{E}\left[|E_K(\xi \hat{\sigma_Y} z)|^2\right] dz + \frac{1}{n^2} \int\limits_{-\infty}^{+\infty} \mathbb{E}\left[\sum_{k \neq l} e^{iz(Y(t_k) - Y(t_l))} |E_K(\xi \hat{\sigma_Y} z)|^2\right] dz \\
&- \frac{2}{n} \int\limits_{-\infty}^{+\infty} \mathbb{E}\left[\mathrm{Re}(\overline{E_{f_0}(z)} E_K(\xi \hat{\sigma_Y} z) \sum_{k=1}^{n} e^{iY(t_k)})\right] dz.
\end{aligned} \tag{4.19}$$

Все вычисления далее проводятся только для случая **ядра Гаусса**. Каждое из слагаемых будем рассматривать отдельно.

4.3.2 Слагаемое I_A

Рассмотрим первое слагаемое

$$I_A = \frac{1}{n} \int\limits_{-\infty}^{+\infty} \mathbb{E}\left[|E_K(\xi \hat{\sigma_Y} z)|^2\right] dz.$$

Его вычисление сводится к подсчету математического ожидания под интегралом. После подстановки выражения для гауссовского ядра и ортогонального преобразования $\mathbf{v} = \mathbf{H}\mathbf{y}$, где $\mathbf{H}$ приведено в третьей главе, получим:

$$\mathbb{E}\left[|E_K(\xi\hat{\sigma_Y}z)|^2\right] = \mathbb{E}\left[e^{-\xi^2\hat{\sigma}_Y z^2}\right] = \mathbb{E}\left[e^{-\frac{\xi^2}{n}\sum_{j=1}^{n-1}V_j^2 z^2}\right].$$

Основная трудность дальнейших преобразований состоит в том, что компоненты случайного вектора $\tilde{\mathbf{v}} = (V_1, ..., V_{n-1})$ зависимы. Подберем еще одно ортогональное преобразование $\mathbf{w} = \mathbf{G}\tilde{\mathbf{v}}$, с такой матрицей $\mathbf{G}$, что $W_1, ..., W_{n-1}$ будут независимы. Рассмотрим разложение корреляционной матрицы $\mathbf{\Sigma}_{\tilde{V}}$ по собственным числам и собственным векторам: $\mathbf{\Sigma}_{\tilde{V}} = \mathbf{R}\mathbf{\Lambda}\mathbf{R}^T$. Тогда, полагая $\mathbf{G} = \mathbf{R}^T$ получим

$$\mathbf{\Sigma}_W = \mathbf{G}\mathbf{\Sigma}_{\tilde{V}}\mathbf{G}^T = \mathrm{diag}(\lambda_1, ..., \lambda_{n-1}).$$

Таким образом, случайные величины $W_1, ..., W_{n-1}$ действительно оказываются независимы. После этого можно воспользоваться леммой 2.2 о многомерном гауссовском интеграле из главы, посвященной автоматическим оценкам по независимой выборке

$$\mathbb{E}\left[e^{-\frac{\xi^2}{n}\sum_{j=1}^{n-1}V_j^2 z^2}\right] = \mathbb{E}\left[e^{-\frac{\xi^2}{n}\sum_{j=1}^{n-1}W_j^2 z^2}\right] = \prod_{j=1}^{n-1}\left(\frac{2\xi^2 z^2\lambda_j}{n} + 1\right)^{-\frac{1}{2}}.$$

В результате получаем аналитическое выражение для первого слагаемого

$$I_A = \frac{2}{n}\int_0^{+\infty}\prod_{j=1}^{n-1}\left(\frac{2\xi^2 z^2\lambda_j}{n} + 1\right)^{-\frac{1}{2}} dz. \tag{4.20}$$

4.3.3 Слагаемое I_B

Рассмотрим второе слагаемое:

$$I_B = \frac{1}{n^2}\int_{-\infty}^{+\infty}\mathbb{E}\left[|E_K(\xi\hat{\sigma_Y}z)|^2\sum_{k\neq l}e^{iz(Y(t_k)-Y(t_l))}\right]dz.$$

Его вычисление сводится к подсчету математического ожидания вида

$$\mathbb{E}\left[|E_K(\xi\hat{\sigma_Y}z)|^2\sum_{k\neq l}e^{iz(Y(t_k)-Y(t_l))}\right] = \mathbb{E}\left[e^{-\xi^2\hat{\sigma_Y}^2 z^2}\sum_{k\neq l}e^{iz(Y(t_k)-Y(t_l))}\right] =$$

$$= \mathbb{E}\left[e^{-\frac{\xi^2}{n}\sum_{j=1}^{n-1}V_j^2 z^2}\sum_{k\neq l}e^{iz\sum_{s=1}^{n}(H_{sk}-H_{sl})V_s)}\right]. \tag{4.21}$$

Следующее ортогональное преобразование $\mathbf{w} = \hat{\mathbf{G}}\mathbf{v}$ подберем так, чтобы новые случайные величины $W_j,\ j = 1, \ldots, n$ оказались независимы. Матрицу преобразования и корреляционную матрицу $\mathbf{\Sigma}_V$ представим в блочном виде:

$$\hat{\mathbf{G}} = \left[\begin{array}{c|c}\mathbf{G} & \\ \hline & 1\end{array}\right], \quad \mathbf{\Sigma}_V = \left[\begin{array}{c|c}\mathbf{\Sigma}_{\tilde{V}} & \mathbf{u} \\ \hline \mathbf{u}^T & \sigma_{nn}\end{array}\right].$$

Теперь положим $\mathbf{G} = \mathbf{R}^T$, где $\mathbf{R}$ берем из спектрального разложения $\mathbf{\Sigma}_{\tilde{V}} = \mathbf{R}\mathbf{\Lambda}\mathbf{R}^T$, что дает

$$\mathbf{\Sigma}_W = \left[\begin{array}{c|c} \mathbf{G} & \\ \hline & 1 \end{array}\right] \left[\begin{array}{c|c} \mathbf{\Sigma}_{\tilde{V}} & \mathbf{u} \\ \hline \mathbf{u}^T & \sigma_{nn} \end{array}\right] \left[\begin{array}{c|c} \mathbf{G}^T & \\ \hline & 1 \end{array}\right] = \left[\begin{array}{c|c} \mathbf{\Lambda} & \mathbf{G}\mathbf{u} \\ \hline \mathbf{u}^T\mathbf{G}^T & \sigma_{nn} \end{array}\right].$$

Итак, матрица $\mathbf{\Sigma}_W$ имеет вид:

$$\begin{pmatrix} \lambda_1 & & & \alpha_1 \\ & \ddots & & \vdots \\ & & \lambda_{n-1} & \alpha_{n-1} \\ \alpha_1 & \dots & \alpha_{n-1} & \sigma_{nn} \end{pmatrix}.$$

После замены $\mathbf{w} = \hat{\mathbf{G}}\mathbf{v}$ в (4.21) получаем

$$\mathbb{E}\left[\left(\sum_{k\neq l} e^{iz\sum_{s=1}^{n}\sum_{r=1}^{n}(H_{sk}-H_{sl})\hat{G}_{rs}W_r}\right) e^{-\frac{\xi^2}{n}\sum_{j=1}^{n-1}W_j^2 z^2}\right].$$

В этом выражении $W_1, \dots, W_{n-1}$ пока еще зависят от W_n. Рассмотрим случайные величины $\tilde{W}_1, \dots, \tilde{W}_{n-1}, Z$, такие что

$$\begin{cases} \tilde{W}_1 = W_1 \\ \vdots \\ \tilde{W}_{n-1} = W_{n-1} \\ \tilde{W}_n = \beta_1 W_1 + \ldots + \beta_{n-1}W_{n-1} + \beta_n Z, \end{cases} \tag{4.22}$$

где $W_1, \dots, W_{n-1}, Z$ — независимы, и притом $Z \sim N(0,1)$.

Случайные векторы $\mathbf{w}, \tilde{\mathbf{w}}$ — центрированные многомерные нормальные случайные величины. Для равенства их корреляционных матриц необходимо выбрать коэффициенты $\beta_j,\ j = 1, \dots, n$ так:

$$\beta_1 = \frac{\alpha_1}{\lambda_1}, \dots, \beta_{n-1} = \frac{\alpha_{n-1}}{\lambda_{n-1}}, \beta_n = \sqrt{\sigma_{nn} - \sum_{j=1}^{n-1}\beta_j^2\lambda_j}. \tag{4.23}$$

В этом случае векторы $\mathbf{w}, \tilde{\mathbf{w}}$ будут одинаково распределены

$$\mathrm{Law}(W_1, \dots, W_n) = \mathrm{Law}(\tilde{W}_1, \dots, \tilde{W}_n).$$

Значит, в интересующем нас выражении их можно заменить друг на друга:

$$\mathbb{E}\left[\left(\sum_{k\neq l} e^{iz\sum_{s=1}^{n}\sum_{r=1}^{n}(H_{sk}-H_{sl})\hat{G}_{rs}\tilde{W}_r}\right) e^{-\frac{\xi^2}{n}\sum_{j=1}^{n-1}\tilde{W}_j^2 z^2}\right].$$

Упростим здесь выражение в показателе экспоненты, перейдя в нем к переменным $W_1, \dots, W_{n-1}, Z$ по формуле (4.22). Имеем:

$$\sum_{s=1}^{n}\sum_{r=1}^{n}(H_{sk} - H_{sl})\hat{G}_{rs}\tilde{W}_r =$$

$$= \sum_{r=1}^{n-1} W_r \Big(\sum_{s=1}^{n} (H_{sk} - H_{sl}) \hat{G}_{rs} + \beta_r \sum_{s=1}^{n} (H_{sk} - H_{sl}) \hat{G}_{ns} \Big) + \sum_{s=1}^{n} (H_{sk} - H_{sl}) \hat{G}_{ns} \beta_n Z =$$

$$= \sum_{r=1}^{n-1} W_r \Big(\sum_{s=1}^{n} (H_{sk} - H_{sl}) (\hat{G}_{rs} + \beta_r \hat{G}_{ns}) \Big) + Z \sum_{s=1}^{n} (H_{sk} - H_{sl}) \hat{G}_{ns} \beta_n = \sum_{r=1}^{n} A_{klr} \tilde{Y}_r,$$

где

$$A_{klr} = \begin{cases} \sum_{s=1}^{n} (H_{sk} - H_{sl}) (\hat{G}_{rs} + \beta_r \hat{G}_{ns}), \ r < n \\ \sum_{s=1}^{n} (H_{sk} - H_{sl}) \hat{G}_{ns} \beta_n, \ r = n. \end{cases} \tag{4.24}$$

и переобозначено $(W_1, ..., W_{n-1}, Z) = (\tilde{Y}_1, ..., \tilde{Y}_n)$. Таким образом, мы добились желаемого и $\tilde{Y}_1, \ldots, \tilde{Y}_n$ оказались независимы с диагональной корреляционной матрицей $\Sigma_{\tilde{Y}} = \mathrm{diag}(\lambda_1, \ldots, \lambda_{n-1}, 1)$.

Вернемся к вычислению математического ожидания:

$$\mathbb{E}\Big[\Big(\sum_{k \neq l} e^{iz \sum_{s=1}^{n} \sum_{r=1}^{n} (H_{sk} - H_{sl}) \hat{G}_{rs} \tilde{W}_r} \Big) e^{-\frac{\xi^2}{n} \sum_{j=1}^{n-1} \tilde{W}_j^2 z^2} \Big] = \mathbb{E}\Big[\sum_{k \neq l} e^{iz \sum_{r=1}^{n} A_{klr} \tilde{Y}_r} e^{-\frac{\xi^2}{n} \sum_{j=1}^{n-1} \tilde{Y}_j^2 z^2} \Big].$$

Теперь математическое ожидание произведения распадается в произведение математических ожиданий, что позволит нам получить аналитический результат.

$$\sum_{k \neq l} \Big(\mathbb{E}\left[e^{izA_{kln} \tilde{Y}_n} \right] \prod_{r=1}^{n-1} \mathbb{E}\left[e^{izA_{klr} \tilde{Y}_r} e^{-\frac{\xi^2}{n} \tilde{Y}_r^2 z^2} \right] \Big) = \sum_{k \neq l} \Big(e^{-\frac{A_{kln}^2 z^2}{2}} \prod_{r=1}^{n-1} \big(\frac{2\xi^2 z^2 \lambda_r}{n} + 1 \big)^{-\frac{1}{2}} e^{-\frac{A_{klr}^2 z^2 \lambda_r n}{2(2\xi^2 z^2 \lambda_r + n)}} \Big).$$

Окончательное аналитическое выражение для второго слагаемого принимает вид:

$$I_B = \frac{2}{n^2} \int_0^{+\infty} \sum_{k \neq l} \Big(e^{-\frac{A_{kln}^2 z^2}{2}} \prod_{r=1}^{n-1} \big(\frac{2\xi^2 z^2 \lambda_r}{n} + 1 \big)^{-\frac{1}{2}} e^{-\frac{A_{klr}^2 z^2 \lambda_r n}{2(2\xi^2 z^2 \lambda_r + n)}} \Big) dz. \tag{4.25}$$

4.3.4 Слагаемое I_C

Рассмотрим третье слагаемое:

$$I_C = \frac{2}{n} \int_{-\infty}^{+\infty} \mathbb{E}\left[E_{f_0}(z) E_K(\xi \hat{\sigma_Y} z) \sum_{k=1}^{n} e^{iY(t_k)} \right] dz.$$

Как и раньше, все выкладки сводятся к вычислению математического ожидания, стоящего под интегралом. Как и в предыдущем случае мы последовательно проводим два ортогональных преобразования с матрицами $\mathbf{H}, \hat{\mathbf{G}}$:

$$\mathbb{E}\left[E_{f_0}(z) E_K(\xi \hat{\sigma_Y} z) \sum_{k=1}^{n} e^{iY(t_k)} \right] =$$

$$= \sum_{k=1}^{n} \mathbb{E}\left[e^{-\frac{z^2}{2}} e^{-\frac{\xi^2 \hat{\sigma}_Y z^2}{2}} e^{iY(t_k)} \right] = \sum_{k=1}^{n} \mathbb{E}\left[e^{-\frac{z^2}{2}} e^{-\frac{\xi^2 z^2}{2n} \sum_{j=1}^{n-1} W_j^2} e^{iz \sum_{s=1}^{n} \sum_{r=1}^{n} H_{sk} \hat{G}_{rs} W_r} \right].$$

Затем переходим к системе случайных величин $\tilde{W}_1, \ldots, \tilde{W}_n$ с возвратом к $W_1, ..., W_{n-1}, Z$ по формулам (4.22), (4.23). После этих преобразований получаем $(W_1, \ldots, W_{n-1}, Z)$ опять для удобства переобозначены как $(\tilde{Y}_1, ..., \tilde{Y}_n)$

$$\sum_{k=1}^{n} \mathbb{E}\left[e^{-\frac{z^2}{2}} e^{-\frac{\xi^2 z^2}{2n}\sum_{j=1}^{n-1}\tilde{Y}_j^2} e^{iz\sum_{r=1}^{n} B_{kr}\tilde{Y}_r}\right],$$

где

$$B_{kr} = \begin{cases} \sum_{s=1}^{n} H_{sk}(\hat{G}_{rs} + \beta_r \hat{G}_{ns}), \ r < n \\ \sum_{s=1}^{n} H_{sk}\hat{G}_{ns}\beta_n, \ r = n. \end{cases} \tag{4.26}$$

Таким образом, математическое ожидание произведения распадается в произведение математических ожиданий, что позволит нам получить аналитический результат:

$$e^{-\frac{z^2}{2}} \sum_{k=1}^{n} \left(\mathbb{E}\left[e^{izB_{kn}\tilde{Y}_n}\right] \prod_{r=1}^{n-1} \mathbb{E}\left[e^{-\frac{\xi^2 z^2}{2n}\tilde{Y}_r^2 + izB_{kr}\tilde{Y}_r}\right] \right) = e^{-\frac{z^2}{2}} \sum_{k=1}^{n} \left(e^{-\frac{B_{kn}^2 z^2}{2}} \prod_{r=1}^{n-1} \left(\frac{\xi^2 z^2 \lambda_r}{n} + 1\right)^{-\frac{1}{2}} e^{-\frac{B_{kr}^2 z^2 \lambda_r n}{2(\xi^2 z^2 \lambda_r + n)}} \right).$$

Отсюда

$$I_C = \frac{4}{n} \int_0^{+\infty} \sum_{k=1}^{n} \left(e^{-\frac{(B_{kn}^2+1)z^2}{2}} \prod_{r=1}^{n-1} \left(\frac{\xi^2 z^2 \lambda_r}{n} + 1\right)^{-\frac{1}{2}} e^{-\frac{B_{kr}^2 z^2 \lambda_r n}{2(\xi^2 z^2 \lambda_r + n)}} \right) dz. \tag{4.27}$$

4.3.5 Теорема об аналитической форме ОИСКО для случая гауссовского ядра и корреляционной матрицы общего вида

Используя формулы, выведенные в предыдущих параграфах, основной результат данной главы можно представить в виде следующей теоремы.

Теорема 4.1. *Пусть $X(t_1), \ldots, X(t_n)$ — выборка из стационарного гауссовского процесса. Тогда ОИСКО автоматической ядерной оценки с ядром Гаусса представимо в виде*

$$\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi) = 1 + \frac{1}{\sqrt{\pi}}(I_A + I_B - I_C), \tag{4.28}$$

где введены следующие обозначения

$$I_A = \frac{1}{n} \int_0^1 \prod_{j=1}^{n-1} \left(\frac{2\xi^2 \lambda_j (1-t)}{nt} + 1 \right)^{-\frac{1}{2}} \frac{dt}{t^{\frac{3}{2}}\sqrt{1-t}},$$

$$I_B = \frac{1}{n^2} \int_0^1 \sum_{k \neq l} \left(e^{-\frac{A_{kln}^2(1-t)}{2t}} \prod_{r=1}^{n-1} \left(\frac{2\xi^2 \lambda_r (1-t)}{nt} + 1\right)^{-\frac{1}{2}} e^{-\frac{A_{klr}^2 \lambda_r n(1-t)}{2(2\xi^2 \lambda_r (1-t) + nt)}} \right) \frac{dt}{t^{\frac{3}{2}}\sqrt{1-t}},$$

$$I_C = \frac{2}{n} \int_0^1 \sum_{k=1}^{n} \left(e^{-\frac{(B_{kn}^2+1)(1-t)}{2t}} \prod_{r=1}^{n-1} \left(\frac{\xi^2 \lambda_r (1-t)}{nt} + 1\right)^{-\frac{1}{2}} e^{-\frac{B_{kr}^2 \lambda_r n(1-t)}{2(\xi^2 \lambda_r (1-t) + nt)}} \right) \frac{dt}{t^{\frac{3}{2}}\sqrt{1-t}},$$

а коэффициенты A_{klr}, B_{kr} определяются формулами (4.24), (4.26) и зависят только от вида исходной корреляционной матрицы $\mathbf{\Sigma}$.

Доказательство.

С помощью замены переменной $t = \frac{1}{1+z^2}$ в выражениях (4.20), (4.25), (4.27) можно будет выполнять интегрирование по отрезку $[0, 1]$. После этого теорема становится тривиальным следствием формулы (4.19).

Замечание. Учитывая, что мы нигде не пользовались каким-либо конкретным видом корреляционной матрицы, заключаем, что было получено выражение ОИСКО автоматической оценки для случая гауссовского ядра и корреляционной матрицы самого общего вида.

4.4 Численные результаты и сравнения

4.4.1 Моделирование методом Монте-Карло

Приведенные выражения оказались достаточно громоздкими, поэтому целесообразно их проверить. Для этого было смоделировано множество выборок из стационарного гауссовского случайного процесса методом квадратного корня.

Пусть необходимо смоделировать гауссовский случайный вектор с корреляционной матрицей $\mathbf{\Sigma}$, тогда алгоритм моделирования можно описать следующим образом [20]:

1. Генерируем независимую выборку $\mathbf{x} = (X_1, \ldots, X_n)$, все элементы которой являются независимыми одинаково распределенными стандартными гауссовскими величинами: $X_j \sim N(0, 1),\ j = 1, \ldots, n$.
2. Рассмотрим разложение Холецкого нужной корреляционной матрицы (для симметричной, неотрицательно-определенной матрицы указанное разложение существует, см. [4]):

$$\mathbf{\Sigma} = \mathbf{S}\mathbf{S}^T.$$

Перейдем к новой выборке $(Y_1, \ldots, Y_n)$ по формуле $\mathbf{y} = \mathbf{S}\mathbf{x}$. Отметим, что корреляционная матрица $\mathbf{\Sigma}_Y$ в точности равна $\mathbf{S}\mathbf{\Sigma}_X\mathbf{S}^T = \mathbf{\Sigma}$.

Для каждой полученной зависимой выборки построим автоматическую оценку плотности с заданной ξ и вычислим среднее ОИСКО:

$$\mathrm{RMISE}_{MC}(f, \hat{f}) = \frac{1}{N\|f(x)\|^2} \sum_{j=1}^{N} \|f(x) - \hat{f}(x, Y_1^{(j)}, \ldots, Y_n^{(j)})\|^2.$$

Проделаем указанные вычисления на сетке $\xi_1, \ldots, \xi_k$ с небольшим шагом и на основании полученных данных построим графики зависимости ОИСКО от ξ.

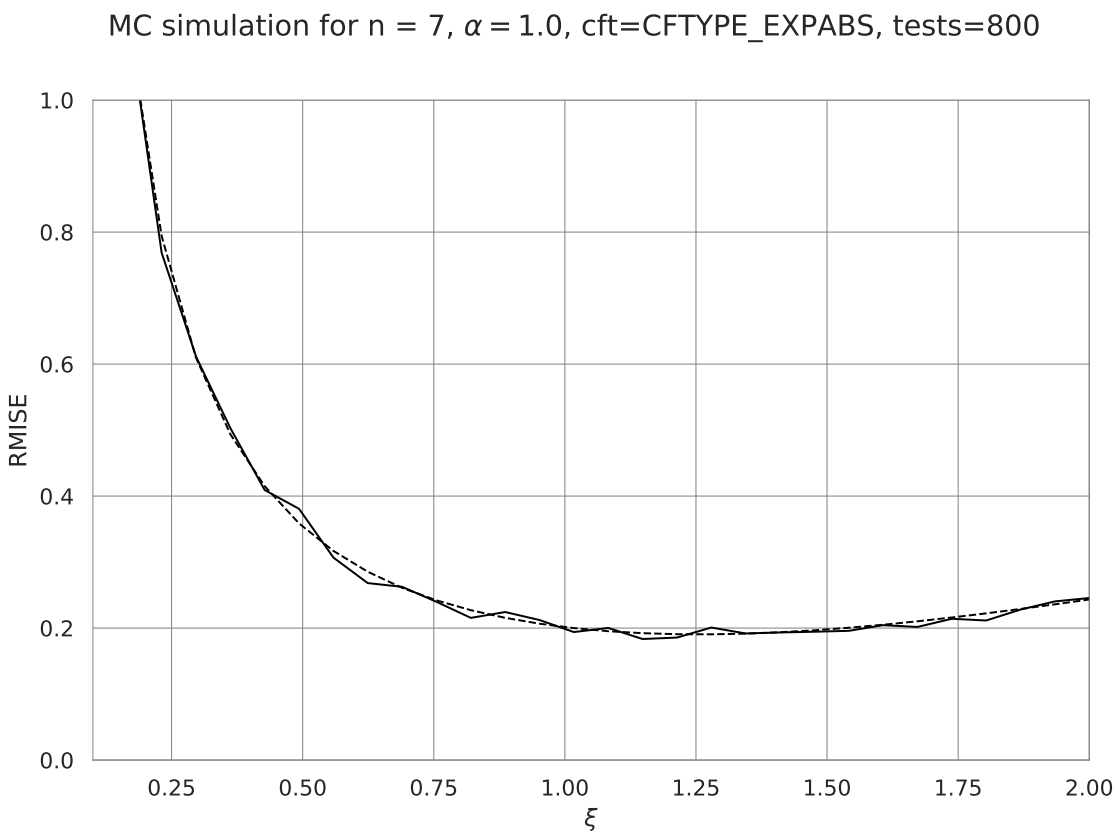

Рис. 4.1: Значения ОИСКО, полученные методом статистического моделирования (сплошная линия) и аналитическим методом (пунктир).

Полученные приближенные результаты сходятся к аналитическим с ростом числа испытаний N:

$$\mathrm{RMISE}(f, \hat{f}) \approx \mathrm{RMISE}_{MC}(f, \hat{f}).$$

Учитывая, что данный метод представляет собой элементарное усреднение случайных величин вида $\|f(x) - \hat{f}(x, Y_1, \ldots, Y_n)\|^2$, нетрудно дать оценку скорости сходимости построенного метода. Из центральной предельной теоремы следует, что погрешность метода убывает пропорционально обратному корню из числа тестов $\frac{1}{\sqrt{N}}$ [20, 35].

4.4.2 Значения ОИСКО и оптимальные параметры

У ядерной оценки закона распределения случайного гауссовского процесса имеются следующие параметры: безразмерный параметр сглаживания ξ, объем выборки n, а также параметр α, входящий в определение корреляционной функции, при этом два из них — ξ, α могут меняться непрерывно. Другими словами, зависимости ОИСКО от остальных параметров можно представить как поверхности на плоскости (ξ, α) для различных комбинаций оставшихся параметров. Для более подробного анализа полученных результатов необходимо строить сечения данных поверхностей при разных α. Случай автоматической и неавтоматической ядерной оценки имеет смысл рассматривать вместе, так как получен-

ные результаты для них имеют много общего.

Корреляционные матрицы $\mathbf{\Sigma}$ во всех вариантах были сгенерированы для стандартного учетного интервала $\tau = 1.0$, то есть рассматривается модель равных временных отсчетов с корреляционной матрицей вида (4.3). Отметим, что разработанный метод вычисления ОИСКО не налагает никаких ограничений на величину временных интервалов. Стандартная ширина интервала подобрана для единообразия и наглядности. Корреляционные функции выбраны из таблицы 4.1.

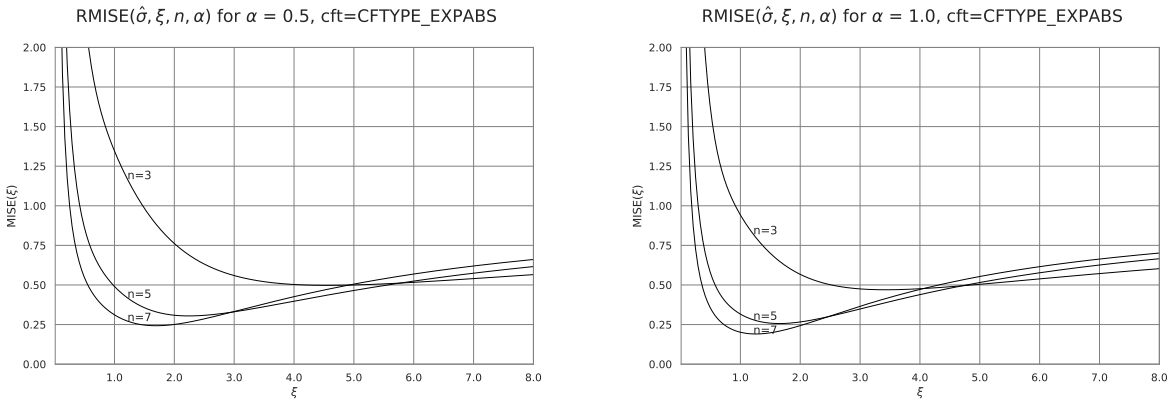

Рис. 4.2: Сечения поверхности RMISE$(\hat{\sigma}, \xi, n, \alpha)$ автоматической оценки для разных значений параметров и типов корреляционных функций.

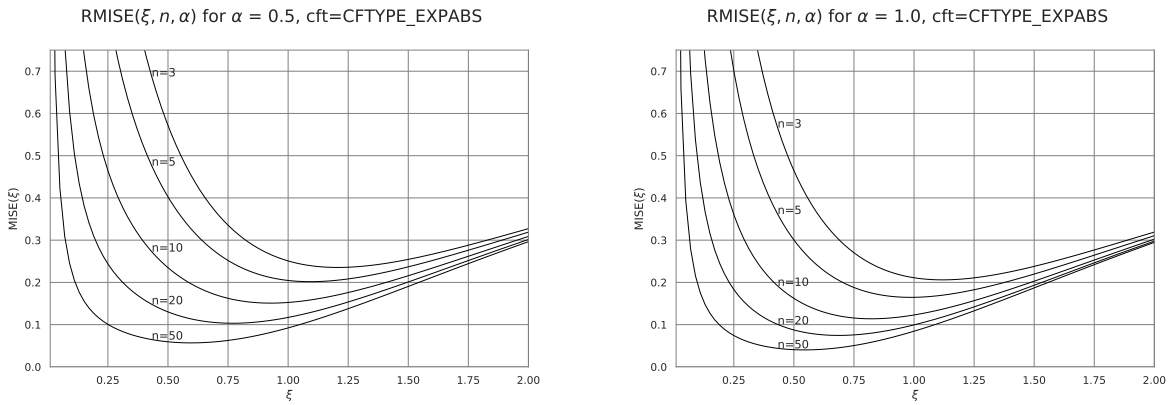

Рис. 4.3: Сечения поверхности RMISE(ξ, n, α) для неавтоматической оценки для разных значений параметров и типов корреляционных функций.

Отдельный интерес представляют оптимальные параметры сглаживания и сами минимумы. В отличие от случая независимой выборки эти значения будут зависеть еще и от параметра корреляционной функции α.

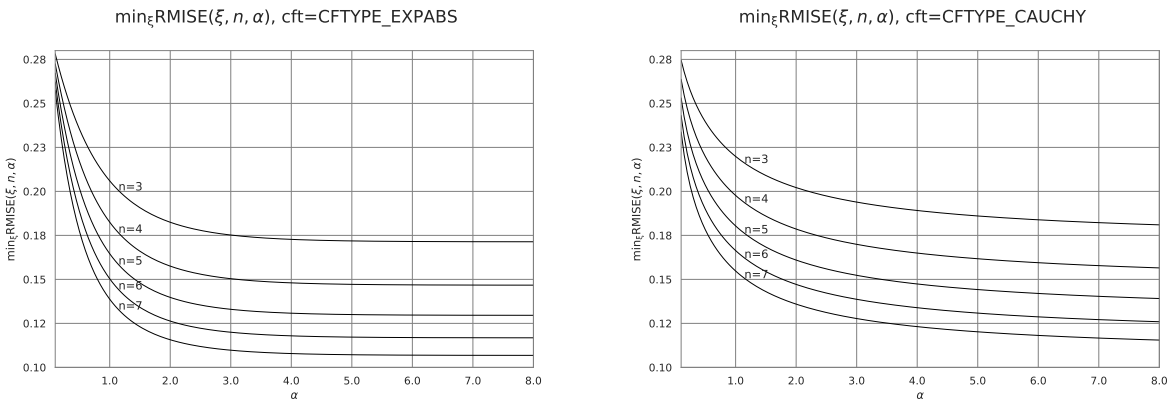

Рис. 4.4: Минимумы ОИСКО неавтоматической оценки для разных значений параметров и типов корреляционных функций, различных n и α.

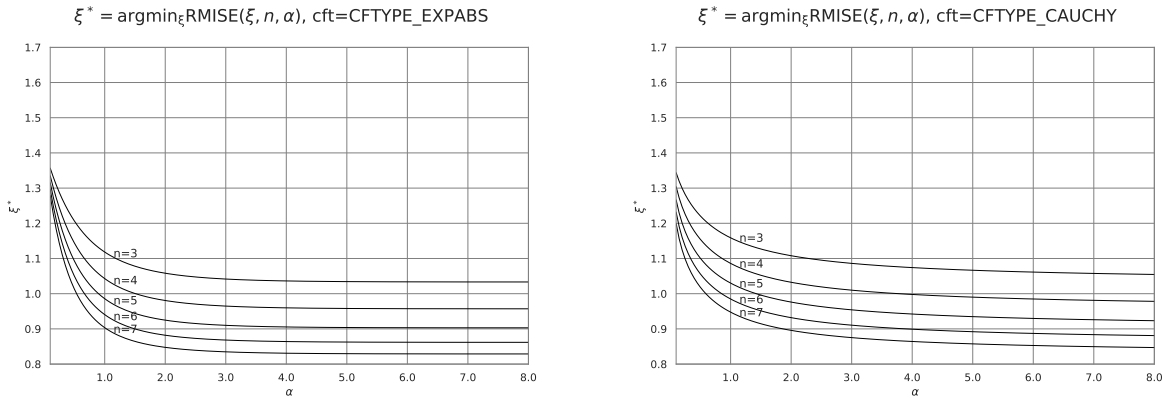

Рис. 4.5: Оптимальные параметры сглаживания ξ^* для различных n и α в случае неавтоматической оценки.

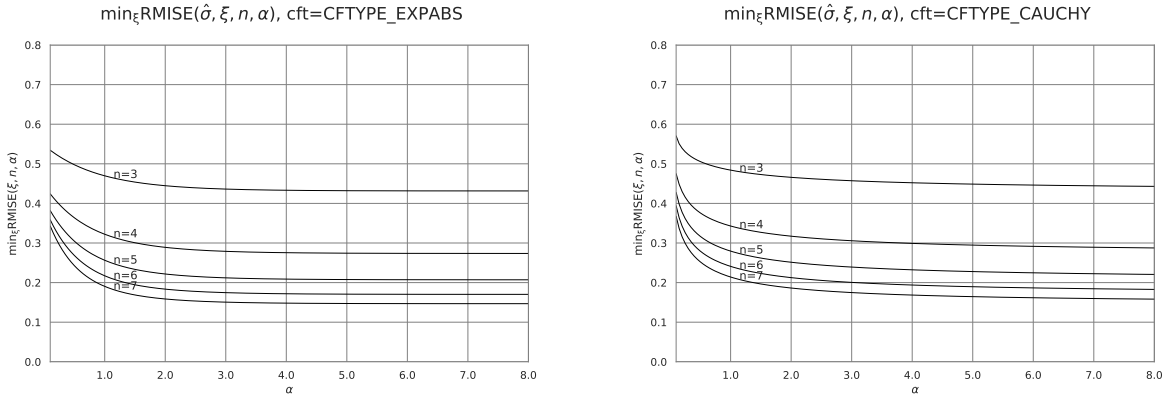

Рис. 4.6: Минимумы ОИСКО автоматической оценки для разных значений параметров и типов корреляционных функций, различных n и α.

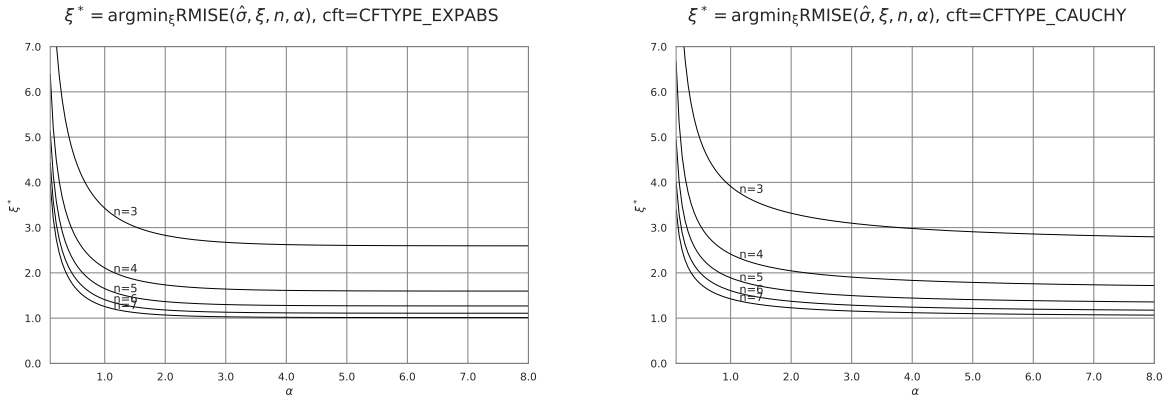

Рис. 4.7: Оптимальные параметры сглаживания ξ^* для различных n и α в случае автоматической оценки.

Заметим, что при стремлении $\alpha \to \infty$ оптимальные параметры и минимумы приближаются к значениям, которые были уже были получены в рамках исследования оценок независимой выборки из нормального распределения. При этом вид корреляционной функции не сказывается сколько-нибудь существенно на виде полученных зависимостей для рассматриваемых функций.

4.4.3 Дополнительные исследования

В данном разделе приведем результаты нескольких дополнительных исследований. Во-первых, проверим эффект отрицательной корреляции (4.14) для неавтоматической и автоматической оценок в случае трехдиагональной корреляционной матрицы. Сначала вычислим ОИСКО для некоторых граничных случаев зависимости между элементами по выведенным формулам, а затем полученные результаты проверим методом статистического моделирования. Во-вторых, проведем проверку эффективности использования оптимального параметра сглаживания неавтоматической ядерной оценки при построении автоматической.

Итак, рассмотрим модель зависимой выборки с трехдиагональной корреляционной матрицей вида (4.5). Построим зависимости ОИСКО для неавтоматической и автоматической ядерной оценки в трех случаях: $a = -a_n$, $a = 0$ (соответствует независимой выборке), $a = a_n$. Подчеркнем, что значения $a_n = \frac{1}{2\cos(\frac{\pi}{n+1})}$ являются *граничными* в смысле определенности корреляционной матрицы (см. (4.17)). В случае неавтоматической оценки указанные значения будут граничными еще и в смысле величины ОИСКО.

Обратим внимание на то, что исследуемая параметризация корреляционной зависимости отличается от предыдущего раздела. В случае корреляционных функций с параметром α затухания корреляционной связи, для допустимых значений параметра справедливо $0 < \alpha < \infty$, где $\alpha \to \infty$ соответствует случаю независимой выборки. Для модели с трехдиагональной корреляционной функцией параметр a меняется в интервале $-a_n < a < a_n$, где $a = 0$ соответствует отсутствию зависимости между элементами выборки.

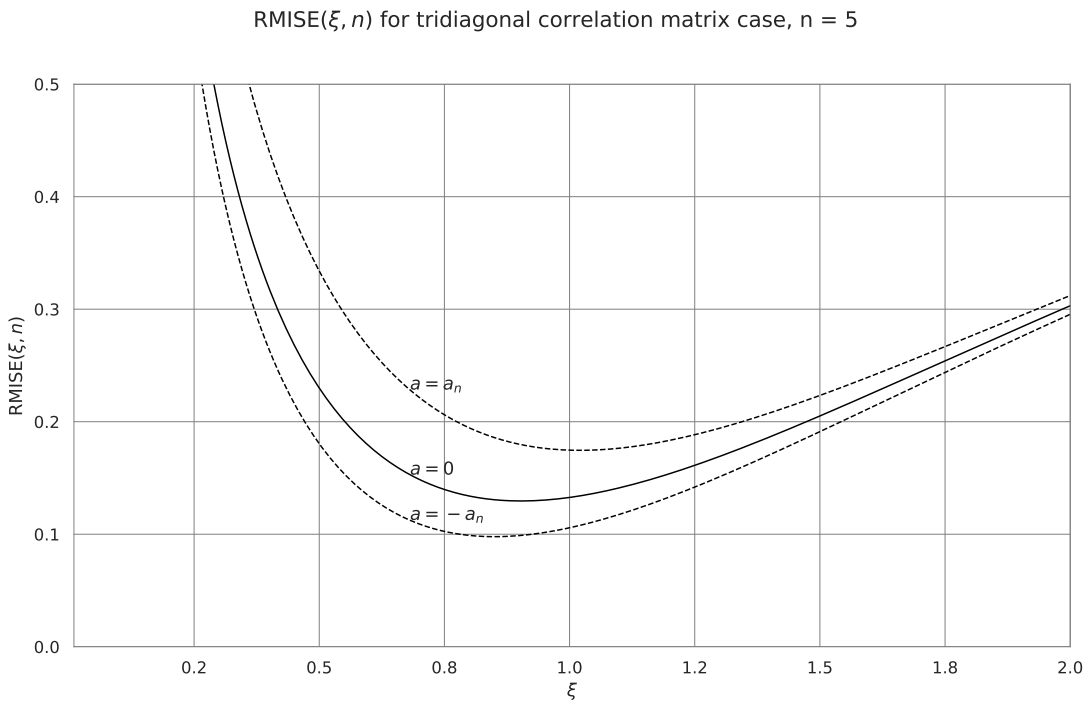

Рис. 4.8: Сплошной линией обозначена зависимость ОИСКО для случая независимой выборки, пунктиром — для зависимой выборки в граничных случаях с $a_n = \frac{1}{2\cos(\frac{\pi}{n+1})}$.

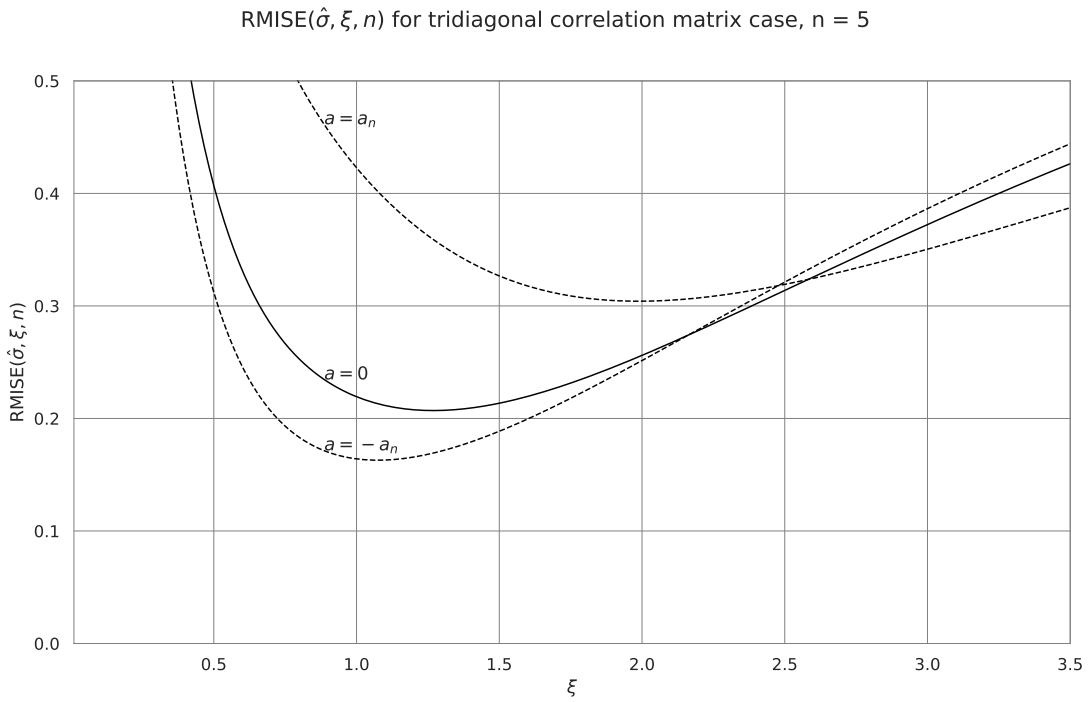

Рис. 4.9: Сплошной линией обозначена зависимость ОИСКО для случая независимой выборки, пунктиром — для зависимой выборки в граничных случаях с $a_n = \frac{1}{2\cos(\frac{\pi}{n+1})} - \delta$.

Как и следовало ожидать, кривые зависимостей ОИСКО для неавтоматической оценки оказались монотонными по a, что явно следует из вида аналитического представления (4.12). В частности, кривая соответствующая нижней границе множества допустимых

значений a лежит ниже кривой, соответствующей случаю независимой выборки.

В случае автоматической ядерной оценки нет монотонности по a для всех значений ξ, однако в случае минимумов наблюдается тот же эффект, что и для традиционной оценки. Легко заметить, что значения минимумов для $a = -a_n$ и $a = a_n$ отличаются приблизительно в два раза: $\mathrm{RMISE}(a_n) \approx 2\,\mathrm{RMISE}(-a_n)$. Интересно отметить, что оптимальный параметр для зависимой выборки с $a = -a_n$ оказался меньше, чем для независимой выборки, при том, что в предыдущем разделе соответствующий параметр всегда оказывался больше.

До сих пор мы сравнивали между собой результаты вычислений для теоретических результатов. Для того чтобы понять является ли замеченный эффект отрицательной корреляции «математическим артефактом» построенной теоретической модели или он соответствует действительности на практике, можно проверить теоретические результаты методом Монте-Карло. На рисунке 4.10 приведен результат реализации метода статистических испытаний для зависимой выборки с трехдиагональной матрицей и $a = -\frac{1}{2\cos(\frac{\pi}{n+1})} + \delta$, где $\delta > 0$ выбрано весьма малым ($\delta = 0.01$) для устойчивости вычислений.

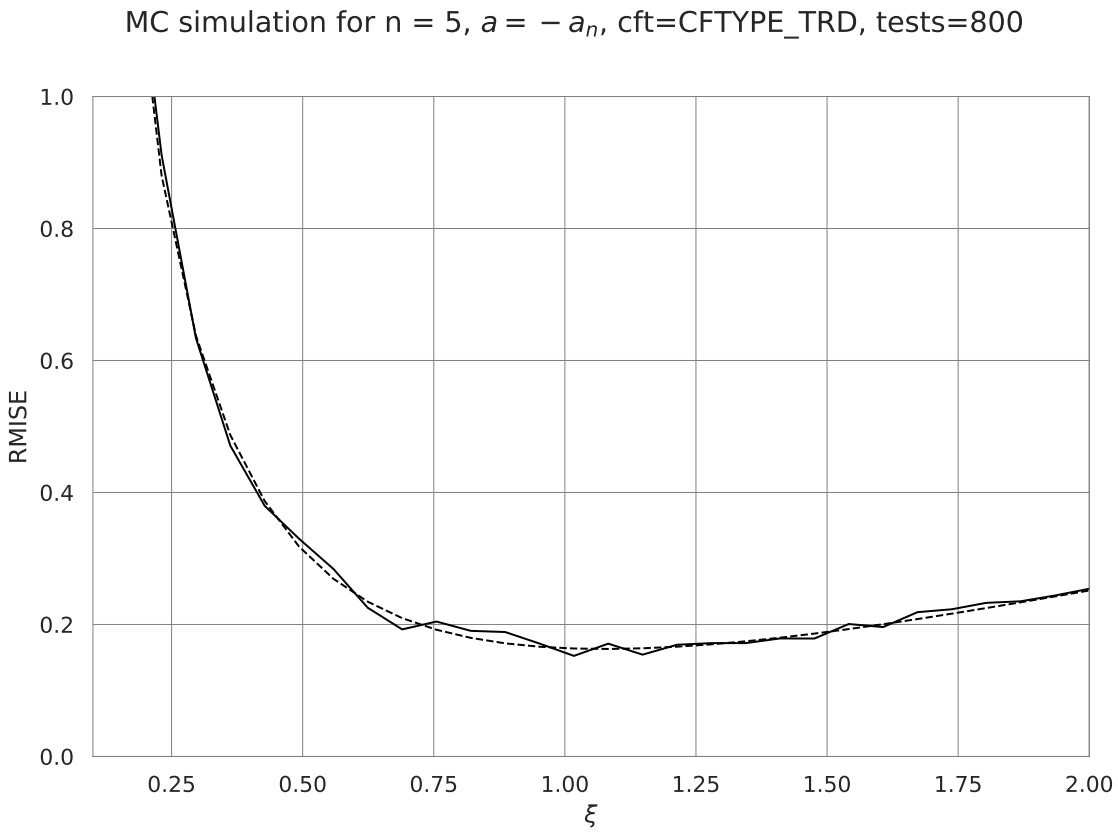

Рис. 4.10: Значения ОИСКО, полученные методом статистического моделирования (сплошная линия) и аналитическим методом (пунктир).

Полученные результаты свидетельствуют о том, что полученное выражение для ОИСКО действительно дает точное выражение для ошибки в рамках модели трехдиагональной

корреляционной матрицы для заданного значения a. Таким образом удалось установить, что построенные ядерные оценки более точно оценивают плотность в некоторых случаях зависимости между элементами.

Проведем исследование эффективности использования параметра неавтоматической оценки вместо оптимального параметра для автоматической. Обозначим оптимальный параметр для неавтоматической оценки как $\xi_1 = \arg\min_\xi \mathrm{RMISE}(f, K, n, \xi)$. Положим $h = \xi_1\hat{\sigma}$ или, другими словами, вместо точного значения параметра масштаба σ будем использовать его оценку $\hat{\sigma}$. Таким образом построенная оценка по определению является автоматической с параметром ξ_1, следовательно, будет выполнено следующее неравенство

$$\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi^*) \leq \mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi_1).$$

Для различных n, α можно вычислить величину эффективности такой оценки относительно ОИСКО

$$\delta = \frac{\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi_1) - \mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi^*)}{\mathrm{RMISE}(\hat{\sigma}, f, K, n, \xi^*)}. \tag{4.29}$$

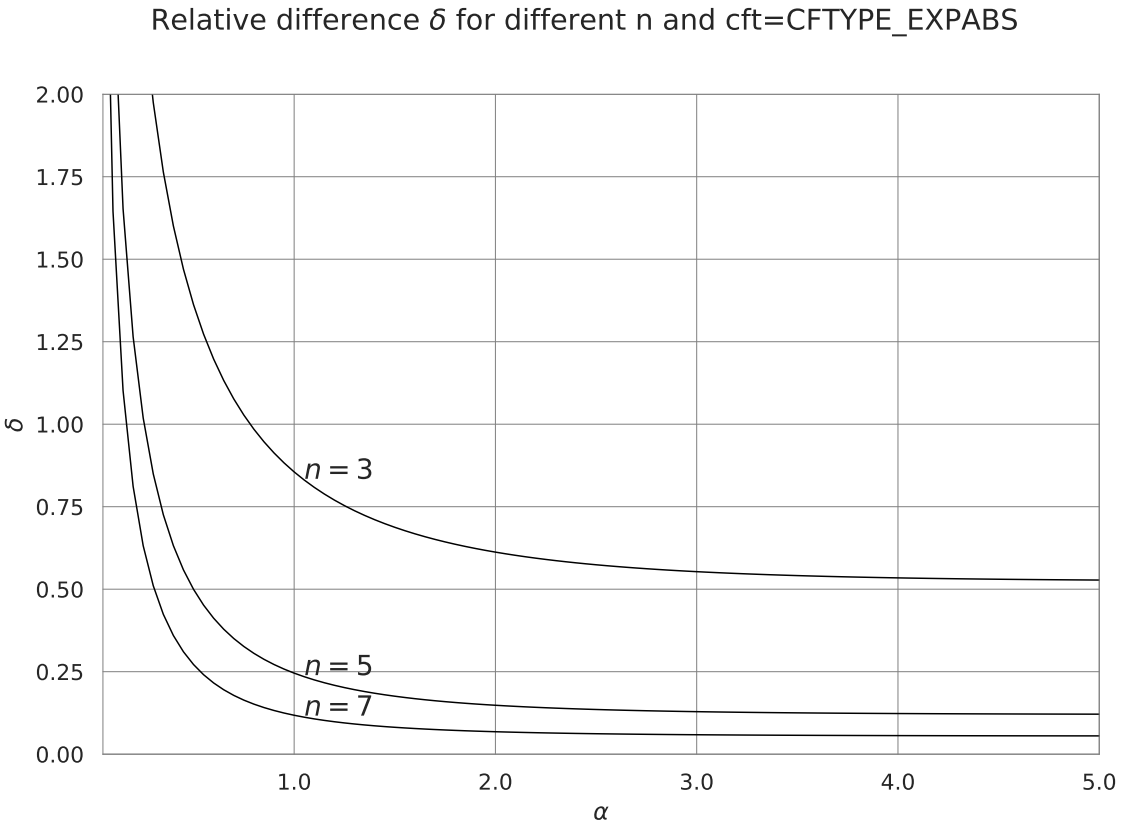

Рис. 4.11: Графики эффективности $\delta(\alpha)$ для различных n.

Как видно из графика при больших n разница становится меньше, так как при замене σ на $\hat{\sigma}$ мы делаем все меньшую ошибку. При этом при уменьшении α (увеличении радиуса корреляции) разница существенно растет. При увеличении α величина (4.29) приближается к значениям, точно соответствующим случаю независимой выборки.

Заключение

Данная работа посвящена сравнительному исследованию точности различных оценок плотности вероятности по малым выборкам. Наиболее подробно рассматривается класс ядерных оценок. В то же время, в контексте сравнения с ним разобраны и некоторые другие оценки.

В **первой главе** был проведен краткий обзор существующей литературы по теме диссертации, а также рассмотрены несколько базовых понятий, необходимых для дальнейшего изложения: лемма о безразмерном параметре, традиционная неавтоматическая оценка, детально изложен метод перехода к характеристическим функциям. Для случая независимой выборки и двух типов ядер, гауссовского и прямоугольного, рассмотрены существующие теоретические результаты. На основании численных экспериментов и аналитических исследований ОИСКО, установлен ряд универсальных свойств данных ядерных оценок в условиях малой выборки.

Во **второй главе** вводится центральное для всего исследования понятие автоматической оценки. К доказательству теоремы о явном представлении ОИСКО автоматической оценки независимой выборки из нормального распределения, полученной в работах [1, 32] был предложен новый подход, основанный на использовании леммы о многомерном гауссовском интеграле. Для полученных теоретических результатов были произведены численные расчеты оптимальных параметров и минимумов.

Третья глава целиком посвящена обзору результатов статьи [15], относящихся к оценкам максимального правдоподобия трех различных типов и гистограммам. Существующие результаты были согласованы и дополнены. Проведено сравнение точности этих оценок с ядерными оценками, разработанными в диссертации.

Основным результатом **четвертой главы** работы является разработанный автором новый подход к построению ядерной оценки по выборке с зависимыми элементами. Для выборки из стационарного гауссовского процесса с корреляционной функцией общего вида были построены два типа ядерных оценок плотности: традиционная и автоматическая. С помощью ортогональных преобразований специального вида удалось вывести точные аналитические выражения ОИСКО, пригодные для эффективного численного анализа с помощью компьютера. Дополнительно детально рассмотрен случай трехдиагональной корреляционной матрицы, основные характеристики которой приводятся в явном виде.

Полученные результаты согласованы со случаем независимой выборки при стремлении радиуса корреляции исследуемого случайного процесса к нулю. Результаты проверены путем сравнения с результатами статистического моделирования и проанализированы с помощью многочисленных численных экспериментов. В рамках исследования было рассмотрено несколько моделей корреляционной зависимости. Для всех рассматриваемых оценок были получены оптимальные параметры и вычислены точные минимумы ОИСКО.

Литература

[1] Адамович С.С. Исследование ядерных оценок в условиях малой выборки. Дипломный проект. — Ленинград: ЛГТУ, 1990. — 168 с.

[2] Бэйтмен Г., Эрдейи А. Таблицы интегральных преобразований. — М.:Наука, 1970. — 328 с.

[3] Бэйтмен Г., Эрдейи А. Высшие трансцендентные функции Бесселя, функции параболического цилиндра, ортогональные многочлены. — М.:Наука, 1974. — 296 с.

[4] Вержбицкий В. М. Основы численных методов. — М.:Высшая школа, 2009. — 840 с.

[5] Гантмахер Ф.Р., Крейн М.Г. Осцилляционные матрицы и ядра, и малые колебания механических систем. — Л.:Государственное издательство технической литературы, 1950. — 359 с.

[6] Гаскаров Д.В., Шаповалов В. И. Малая выборка. — М.:Статистика, 1978. — 248 с.

[7] Гардинер К.В. Стохастические методы в естественных науках. — М.:Мир, 1986. — 528 с.

[8] Градштейн И.С. Рыжик И.М. Таблицы интегралов, сумм, рядов и произведений. — М.:Государственное издательство физико-математической литературы, 1963. — 1108 с.

[9] Губарев В.В. Алгоритмы статистических измерений. — М.:Энергоатомиздат, 1985. — 272 с.

[10] Деврой Л., Дьерфи Л. Непараметрическое оценивание плотности. L_1-подход. — М.:Мир, 1988. — 408 с.

[11] Епанечников В.А. Непараметрическая оценка многомерной плотности вероятности // Теория вероятности и ее применения, 1969.— т.14, №1. — с.156-161.

[12] Ефимов А.В., Криворуков Е.В. Исследование эффективности оценок и «псевдооценок» среднего при малом числе наблюдений // Автометрия, 1983. — №1 — с.11-18.

[13] Зайцева Н.И. Оценка параметров гауссовского случайного поля по малому набору его реализаций, заданных в конечном множестве точек. Магистерская диссертация. — СПб: Санкт-Петербургский политехнический университет Петра Великого, 2016. — 61 с.

[14] Заяц О.И., Черменский В. Г. О применении методов статистики малой выборки к решению задач надежности причальных сооружений // Научно-технические проблемы надежности морских портовых сооружений. М.:Транспорт, 1988. — с.66-75.

[15] Заяц О.И., Адамович С.С., Адамович Е.Ю. Сравнительный анализ точности ядерных и классических оценок плотности в условиях малой выборки // Л.:ЛГТУ, 1991. — 53 с. — Депонировано в ВИНИТИ 04.02.92, №379-В92

[16] Ивченко Г.И., Медведев Ю.И. Математическая статистика. — М.:Либроком, 2014. — 352 с.

[17] Колмогоров А.Н., Фомин С.В. Элементы теории функций и функционального анализа. — М.:Наука, 1972. — 496 с.

[18] Ланкастер П. Теория матриц. — М.:Наука, 1973. — 280 с.

[19] Мартыщенко Л.А., Ташевский А.Г., Немчинов В.И. Подтверждение ТТХ сложных систем по малому числу наблюдений. — М.:Издательство МО СССР, 1985. — 48 с.

[20] Михайлов Г.А., Войтишек А.В. Численное статистическое моделирование. Методы Монте-Карло. — М.:Академия, 2006. — 368 с.

[21] Надарая Э.А. Непараметрические оценки плотности вероятности и кривой регрессии. — Тбилиси: Издательство ТГУ, 1983. — 194 с.

[22] Петров А.А. Проверка статистических гипотез о типе распределения по малым выборкам // Теория вероятностей и ее применения, 1956. — т.1, №2. — с.248-270.

[23] Прохоров Ю.В. (ред.) Вероятность и математическая статистика. Энциклопедия. — М.:Большая российская энциклопедия, 1999. — с.145

[24] Пугачев В.С. Теория случайных функций. — М.: Физматлит, 1960. — 883 с.

[25] Рытов С.М. Введение в статистическую радиофизику. — М.:Наука, 1976, т.1 — 496 с.

[26] Самойленко А.П., Горбунова Е.Б. Технология прогнозирования надежности РЭА при ограниченных объемах статистических данных. — Ростов: Издательство ЮФУ, 2014. — 153 с.

[27] Свешников А.А. Прикладные методы теории случайных функций. — СПб:Лань, 2012. —480 с.

[28] Сухорученков Б.И. Анализ малой выборки. Прикладные статистические методы. — М.:Вузовская книга, 2010. — 384 с.

[29] Ташевский А.Г. Метод оценки надежности сложных изделий энергомашиностроения при ограниченном числе испытаний // Труды Санкт-Петербургского института машиностроения, 1996. — №2 — 96 с.

[30] Тихонов В.И., Хименко В.И. Выбросы траекторий случайных процессов. — М.:Наука, 1987. — 304 с.

[31] Титчмарш Е. Введение в теорию интегралов Фурье. — Л.:Гостехиздат, 1948. — 418 с.

[32] Туник М.Ю. Автоматическая ядерная оценка плотности вероятности в условиях малой выборки. Бакалаврская работа. — СПб: Санкт-Петербургский политехнический университет Петра Великого, 2017. — 41 с.

[33] Хорстхемке В., Лефевр Р. Индуцированные шумом переходы: теория и применение. — М.:Мир, 1987. — 400 с.

[34] Чернова Н.И. Математическая статистика. — Новосибирск: РИЦ НГУ, 2014. — 150 с.

[35] Шалыгин А.С., Палагин Ю.И. Прикладные методы статистического моделирования. — Л.:Машиностроение, 1986. — 320 с.

[36] Шапиро Е.И. Непараметрические оценки плотности вероятности в задачах обработки результатов наблюдений // Зарубежная радиоэлектроника, 1976. — №2 — с.3-36.

[37] Яглом А.М. Корреляционная теория стационарных случайных функций. — Л.:Гидрометеоиздат, 1981. — 264 с.

[38] Bean S.J., Tsokos C.T. Developments in nonparametric density estimation // International statistical review, 1980. — vol.48, No.3. — p.267-287.

[39] Bochner S., Tenenbaum M., Pollard H. Lectures on Fourier Integrals. — Princeton: University Press, 1959. — 333 p.

[40] Deheuvels P., Hominal P. Estimation automatique de la densité // Revue de Statistique Appliquée, 1980.— vol.28, No.1.— p.25-55.

[41] Efromovich S. Nonparametric curve estimation. — N.Y.:Springer, 1999. — 423 p.

[42] Elliott J.F. The characteristic roots of certain real symmetric matrices, Master's Thesis. — Knoxville: University of Tennessee, 1953. — 50 p.

[43] Gramacki A. Nonparametric kernel density estimation and its computational aspects. — Berlin: Springer, 2018. — 197 p.

[44] Hoffman A. J., Wielandt H. W. The variation of the spectrum of a normal matrix // Duke Mathematical Journal, 1953. — vol.20, No.1. — p.37-39.

[45] Ghosh S. Kernel smoothing. Principles, methods and applications. — N.Y.:Wiley, 2018. — 267 p.

[46] Huang Y., Analytical inversion of general tridiagonal matrices // Journal of Physics A: Mathematical and General, 1997. — vol.30, No.22 — p.7919-7933

[47] Kamps U., Chebyshev polynomials and least squares estimation based on one-dependent random variables // Institut für Statistik und Wirtschaftsmathematik Aachen University of Technology, 1989. — vol.112. — p.217-230

[48] Kessy A., Lewin A., Strimmer K., Optimal whitening and decorrelation. // The American Statistician, 2016 — vol. 72, No.4. — p.309-314.

[49] Kronmal R.A., Tarter M.E. An introduction to the implementation and theory of nonparametric density estimation // The American statistician, 1976. — vol.30, No.1. — p.105-112.

[50] Nadaraya E.A. Nonparametric estimation of probability densities and regression curves. — Dordrecht: Kluwer publishers, 1989. — 222 p.

[51] Ng E.W., Geller M., A Table of integrals of the error functions // Journal of research — B. Mathematical Sciences, 1968. — vol.73B, No.1. — 20 p.

[52] Noschese S., Pasquini L., Reichel L. Tridiagonal toeplitz matrices: Properties and novel applications // Numerical Linear Algebra with Applications, 2012. — vol.20. — p.302-326

[53] Parlett B. N. The Symmetric Eigenvalue Problem. — Philadelphia: Society for Industrial and Applied Mathematics, 1998 — vol.20. — 398 p.

[54] Parzen E. On estimation of a probability density function and mode // Annals of mathematical statistics, 1962.— vol.33, No.3.— p.1065-1076.

[55] Pons O. Functional estimation for density, regression models and processes. — Singapore: World Scientific, 2011. — 205 p.

[56] Prigarin S.M., Hahn K., Winkler G. Variational Dimension of Random Sequences and Its Application // Sibirskii Zhurnal Vychislitel'noi Matematiki, 2009. — vol.12, No.4. — p.435–448

[57] Priestley M.B. Spectral Analysis and Time Series. — Academic Press, 1982. — 890 p.

[58] Rosenblatt M. Remarks on Some Nonparametric Estimates of a Density Function // Annals of mathematical statistics, 1956. — vol.27, No.3. — p.832-837.

[59] Silverman B.W. Density Estimation for Statistics and Data Analysis. — N.Y.:Chapman and Hall, 1986. — 184 p.

[60] Tapia R.H., Thompson J.R. Nonparametric probability density estimation. — Baltimore: Johns Hopkins university press, 1978. — 176 p.

[61] Wand M.P., Jones M.C. Kernel Smoothing. — N.Y.:Chapman and Hall, 1994. — 224 p.

[62] Wertz W. Statistical density estimation: a survay. — Gottingen: Vandenhoek und Ruprecht, 1978. — 108 p.

[63] Wertz W., Schneider B. Statistical density estimation: a bibliography // International statistical review, 1979. — vol.47, No.2. — p.155-175

Приложение А

Таблицы

Принятые обозначения: K_1 — ядро Гаусса, K_2 — нормированное прямоугольное ядро, $\xi_1 = \arg\min \mathrm{RMISE}(K_1),\ \xi_2 = \xi_{AMISE}$.

Таблица А.1: Оптимальные параметры ξ для выборки из нормального распределения для различных n.

n	$\arg\min \mathrm{RMISE}(K_1)$	$\arg\min \mathrm{RMISE}(K_2)$	$\arg\min \mathrm{RMISE}(\hat{\sigma})$	ξ_{AMISE}	ξ_H
2	1.1552010	1.0419154	-	0.9221079	2.2260731
3	1.0332186	0.9426740	2.5968493	0.8502830	1.9707547
4	0.9569969	0.8803282	1.5968426	0.8027416	1.8296985
5	0.9029403	0.8357672	1.2686330	0.7677039	1.7343278
6	0.8617127	0.8015228	1.1079422	0.7402143	1.6630905
7	0.8287465	0.7739501	1.0112470	0.7177416	1.6065505
8	0.8014943	0.7510144	0.9448543	0.6988271	1.5597915
9	0.7784027	0.7314716	0.8953428	0.6825575	1.5199524
10	0.7584604	0.7145091	0.8563895	0.6683251	1.4852343
11	0.7409752	0.6995687	0.8245912	0.6557061	1.4544392
12	0.7254544	0.6862518	0.7979278	0.6443940	1.4267328
13	0.7115356	0.6742643	0.7751085	0.6341603	1.4015134
14	0.6989456	0.6633833	0.7552616	0.6248304	1.3783339
15	0.6874734	0.6534364	0.7377718	0.6162678	1.3568546
16	0.6769530	0.6442877	0.7221909	0.6083643	1.3368118
17	0.6672517	0.6358278	0.7081836	0.6010325	1.3179975
20	0.6420785	0.6137689	0.6732874	0.5818108	1.2674113
50	0.5198765	0.5043733	0.5252254	0.4843884	0.9688201
100	0.4454725	0.4358110	0.4456202	0.4216846	0.7641664

Таблица A.2: Минимумы ОИСКО для выборки из нормального распределения при различных n.

n	$\min \mathrm{RMISE}(K_1)$	$\min \mathrm{RMISE}(K_2)$	$\min \mathrm{RMISE}(\hat{\sigma})$	$\mathrm{RMISE}(\hat{\sigma}, \xi_1)$	$\mathrm{RMISE}(\hat{\sigma}, \xi_2)$	RMISE_{ML-1}	RMISE_{ML-2}	RMISE_{ML-3}	RMISE_H
2	0.2111461	0.2616186	-	-	-	0.2111456	-	-	0.6624001
3	0.1713417	0.2056522	0.4314400	0.6575090	0.7498270	0.1483598	0.2780770	1.1065246	0.5116475
4	0.1466954	0.1726273	0.2735755	0.3324903	0.3784618	0.1143819	0.1718964	0.5375259	0.4255125
5	0.1295562	0.1503707	0.2070275	0.2319103	0.2612720	0.0930748	0.1224840	0.3494182	0.3689145
6	0.1167783	0.1341471	0.1702209	0.1834953	0.2042947	0.0784622	0.0944238	0.2567037	0.3284794
7	0.1067966	0.1216896	0.1467053	0.1547659	0.1704133	0.0678164	0.0765110	0.2019367	0.2979345
8	0.0987328	0.1117623	0.1301961	0.1354965	0.1477576	0.0597150	0.0641564	0.1659707	0.2739209
9	0.0920508	0.1036278	0.1178297	0.1215084	0.1314082	0.0533429	0.0551540	0.1406346	0.2544664
10	0.0864027	0.0968161	0.1081306	0.1107864	0.1189668	0.0481999	0.0483193	0.1218696	0.2383316
11	0.0815513	0.0910121	0.1002627	0.1022389	0.1091250	0.0439614	0.0429626	0.1074385	0.2246958
12	0.0773290	0.0859959	0.0937151	0.0952217	0.1011070	0.0404082	0.0386566	0.0960100	0.2129925
13	0.0736134	0.0816085	0.0881570	0.0893286	0.0944228	0.0373865	0.0351229	0.0867442	0.2028172
14	0.0703129	0.0777323	0.0833632	0.0842895	0.0887469	0.0347853	0.0321728	0.0790858	0.1938728
15	0.0673573	0.0742780	0.0791745	0.0799174	0.0838539	0.0325225	0.0296740	0.0726535	0.1859359
16	0.0646919	0.0711764	0.0754748	0.0760779	0.0795826	0.0305361	0.0275313	0.0671771	0.1788350
17	0.0622733	0.0683731	0.0721771	0.0726719	0.0758144	0.0287785	0.0256741	0.0624598	0.1724361
20	0.0561801	0.0613579	0.0640968	0.0643848	0.0667309	0.0245408	0.0213430	0.0515643	0.1564890
50	0.0308064	0.0328723	0.0331804	0.0331881	0.0336453	0.0099256	0.0079049	0.0186870	0.0912954
100	0.0191770	0.0202196	0.0201480	0.0201480	0.0202846	0.0049813	0.0038504	0.0090418	0.0602646

Приложение B

Дополнительные графики

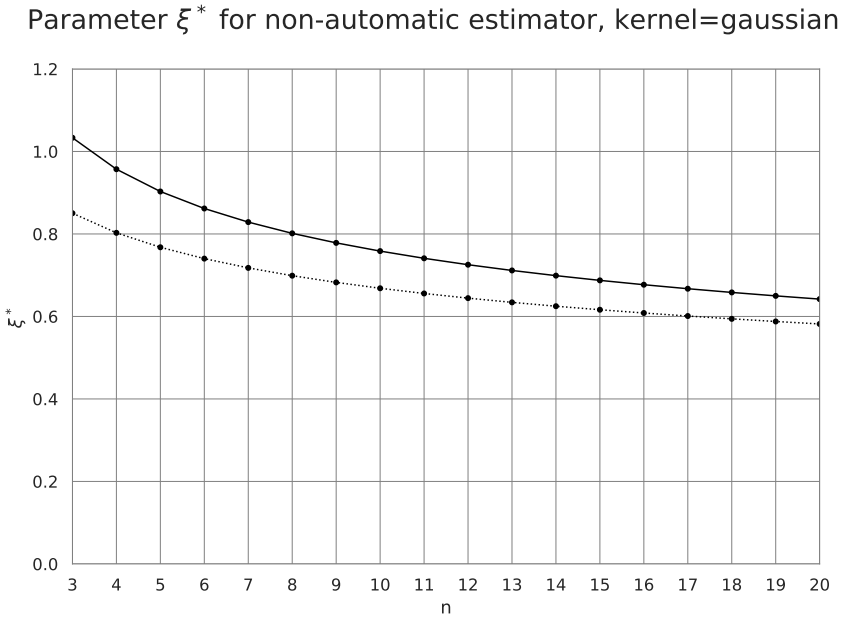

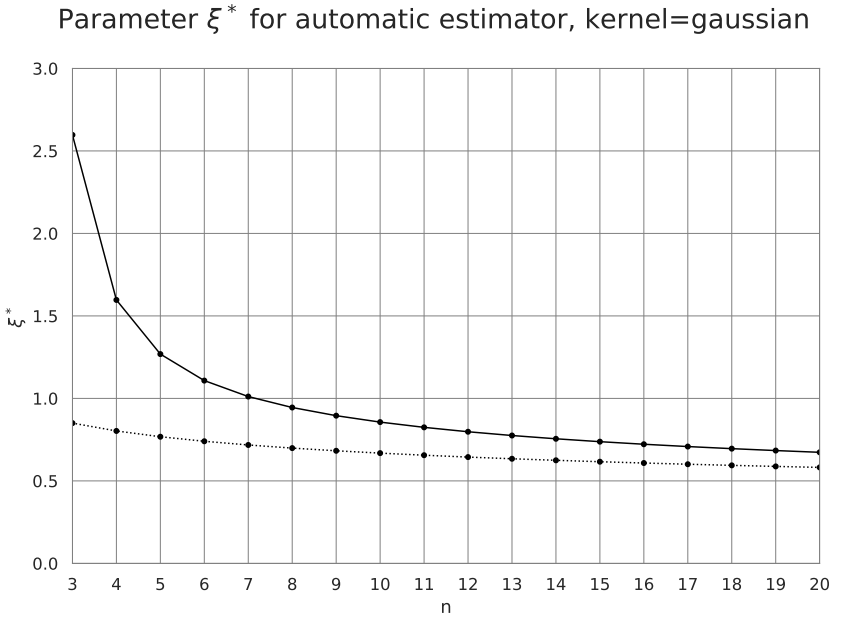

Рис. B.1: Оптимальные безразмерные параметры для неавтоматической (сверху) и автоматической (снизу) оценки с ядром Гаусса в случае выборки с независимыми элементами. Пунктиром на графиках обозначены асимптотически оптимальные параметры $\xi_{\text{AMISE}} = (\frac{4}{3n})^{\frac{1}{5}}$.

Приложение C

Алгоритм вычисления вспомогательных коэффициентов

Для численных расчетов по формулам для ОИСКО автоматической оценки в случае выборки с зависимыми элементами необходимо вычислить вспомогательные коэффициенты $\lambda_i, A_{ijk}, B_{ij}$. Вычисление всех коэффициентов можно оформить в виде алгоритма.

Вход: корреляционная матрица Σ и n, выход: коэффициенты $\lambda_i, A_{ijk}, B_{ij}$

procedure ComputeQuotients(Σ, n)
  $\Sigma_V \leftarrow H\Sigma H^T$
  $\Sigma_{\tilde{V}} \leftarrow cut(\Sigma_V)$ ▷ убрать нижнюю строку и правый столбец
  $\lambda, R \leftarrow SpectralDecomposition(\Sigma_{\tilde{V}})$ ▷ разложение матрицы $\Sigma_{\tilde{V}}$ по собственным числам и векторам
  $\hat{G} \leftarrow ext(R^T)$ ▷ добавить нижнюю строку и правый столбец, $\hat{G}_{nn} = 1$
  $\Sigma_W \leftarrow \hat{G}\Sigma_V\hat{G}^T$
  $\beta[i] \leftarrow \Sigma_W[n,i]/\lambda[i]$
  $\beta[n] \leftarrow \sqrt{\Sigma_W[n,n] - \sum_{j=1}^{n-1}(\beta[j])^2\lambda[j]}$
  for $r = 1 \dots n-1$ **do**
    $A[k,l,r] \leftarrow \sum_{s=1}^{n}(H[s,k] - H[s,l])(\hat{G}[r,s] + \beta[r]\hat{G}[n,s])$
  end for
  $A[k,l,n] \leftarrow \sum_{s=1}^{n}(H[s,k] - H[s,l])\hat{G}[n,s]\beta[n]$
  for $r = 1 \dots n-1$ **do**
    $B[k,r] \leftarrow \sum_{s=1}^{n} H[s,k](\hat{G}[r,s] + \beta[r]\hat{G}[n,s])$
  end for
  $B[k,n] \leftarrow \sum_{s=1}^{n} H[s,k]\hat{G}[n,s]\beta[n]$
  return λ, A, B
end procedure

Замечание 1. При вычислении $\beta[i], A[k,l,r], B[k,r]$ подразумеваются внешние циклы по индексам $i = 1 \dots n-1,\ k = 1 \dots n$ и $l = 1 \dots n$ соответственно.

Замечание 2. Из приведенного алгоритма ясно, что явные формулы для A_{klr}, B_{kr} получить трудно, даже зная собственные числа и собственные векторы исходной корреляционной матрицы $\mathbf{\Sigma}$. Все дело в том, что после умножения $\mathbf{H\Sigma H}^T$ собственные числа и векторы ищутся не у самой матрицы, а у ее блока размера $n-1$.

В случае трехдиагональной корреляционной матрицы $\mathbf{\Sigma}_a$ вида (4.5) вычисления все же можно несколько упростить. Заметим, что $\mathbf{\Sigma}_a = \mathbf{E}_n + a\mathbf{\Delta}$, где

$$\mathbf{\Delta} = \begin{pmatrix} 0 & 1 & \dots & 0 \\ 1 & 0 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 1 \\ 0 & \dots & 1 & 0 \end{pmatrix}.$$

В таком случае $\mathbf{H}\mathbf{\Sigma}_a\mathbf{H}^T = \mathbf{E}_n + a\mathbf{H}\mathbf{\Delta}\mathbf{H}^T$. Уберем нижнюю строку и правый столбец:

$$cut(\mathbf{E}_n + a\mathbf{H}\mathbf{\Delta}\mathbf{H}^T) = \mathbf{E}_{n-1} + a\, cut(\mathbf{H}\mathbf{\Delta}\mathbf{H}^T).$$

Пусть известно спектральное разложение матрицы $cut(\mathbf{H}\mathbf{\Delta}\mathbf{H}^T) = \mathbf{R}\mathbf{\Lambda}_{n-1}\mathbf{R}^T$, тогда

$$\mathbf{E}_{n-1} + a\,\mathbf{R}\mathbf{\Lambda}_{n-1}\mathbf{R}^T = \mathbf{R}(E_{n-1} + a\mathbf{\Lambda}_{n-1})\mathbf{R}^T.$$

Таким образом, для получения собственных чисел и векторов матрицы $cut(\mathbf{H}\mathbf{\Sigma}_a\mathbf{H}^T)$ достаточно произвести предподсчет для матрицы $cut(\mathbf{H}\mathbf{\Delta}\mathbf{H}^T)$.